

电子科技大学
UNIVERSITY OF ELECTRONIC SCIENCE AND TECHNOLOGY OF CHINA

专业学位硕士学位论文

MASTER THESIS FOR PROFESSIONAL DEGREE



论文题目 可信可解释时空表征学习
研究与实现

专业学位类别	电子信息
学 号	202222090638
作者姓名	杨凯
指导教师	周帆 教授
学 院	信息与软件工程学院

分类号 _____ 密级 _____ 公开 _____
UDC ^{注1} _____

学 位 论 文

可信可解释时空数据表征学习研究 with 实现

(题名和副题名)

杨凯

(作者姓名)

指导教师 周帆 教授
电子科技大学 成都
(姓名、职称、单位名称)

申请学位级别 硕士 专业学位类别 电子信息
专业学位领域 软件工程
提交论文日期 2025 年 3 月 21 日 论文答辩日期 2025 年 5 月 22 日
学位授予单位和日期 电子科技大学 2025 年 6 月
答辩委员会主席 _____
评阅人 _____

注 1: 注明《国际十进分类法 UDC》的类号。

Research and Implementation of Trustworthy and Explainable Spatial-Temporal Data Representation Learning

A Master Thesis Submitted to
University of Electronic Science and Technology of China

Discipline **Electronic Information**

Student ID **202222090638**

Author **Yang Kai**

Supervisor **Prof. Zhou Fan**

School **School of Information and Software Engineering**

摘 要

随着互联网、物联网和云计算的高速发展，数据爆炸引发的信息风暴正在变革我们的生活、工作和思维。在人类社会的核心数据流中，时空数据占据着主导地位：超过 80% 的数据具备地理编码和时间标签。准确挖掘时空数据不仅能便利人们出行，还对政府进行智慧城市规划、网络空间治理起到积极作用。当前，时空数据挖掘已引起研究者广泛关注，并针对时空数据提出了各种深度学习算法。

然而，传统的时空学习面临着以下问题：（1）人群流动趋中心化，造成时空数据的“长尾效应”，数据噪声或偏远地区的数据稀疏性使得模型学习潜在特征表征不充分，鲁棒性缺失，难以定位边缘地理位置；（2）人群自身存在多样性，其移动方式、位置偏爱和时间偏好等方面语义复杂性高，难以预测其未来轨迹；（3）深度时空模型的天然黑盒特性导致其缺失可解释性，面临用户信任度挑战，而传统可解释方法局限于提供后验可解释性，无法实时、端到端地解释模型推理过程。

因此，本文旨在通过时空表征学习来识别、预测人群移动性，并基于信息瓶颈理论设计了可解释时空学习框架。本文将从可信三要素——准确性、鲁棒性和可解释性的角度解决三个时空学习任务，即实体地理位置识别，人群移动轨迹预测和可解释时空学习框架。本文从以上角度出发：（1）为解决地理位置识别任务中鲁棒性差、精度低的问题，提出了实体地理定位模型，采用时空图神经网络、星型图架构和深度概率建模方法，允许模型聚合邻居节点信息的同时纳入数据不确定性来源，克服鲁棒性差和节点稀疏性问题；（2）为解决轨迹预测任务中的语义复杂性高，全局移动模式难发现的问题，提出了图增强轨迹预测模型，通过构建轨迹流图来发现全局转换模式，并将其与个性化偏好、时空上下文和时间感知类别嵌入整合到 Transformer 模型中预测轨迹；（3）最后，为解决模型面临的不可解释困境，设计了通用的可解释时空学习框架，通过改进变分信息瓶颈理论进行紧凑表示学习，不仅赋予了模型先验可解释性，还通过改善表示的质量提高了模型精度。

为验证本文提出模型的实际效果与性能，本文在多个真实世界的时空数据集进行实验。结果表明，本文提出的时空模型在地理定位、轨迹预测等时空学习任务的准确性相比基线模型有显著提升，其可解释性和鲁棒性也实现突破，其中可解释时空学习算法不仅实现了领域内后验可解释到先验可解释的突破，同时还实现了在“模型压缩”与“准确预测”间取得平衡。

关键词：时空学习，可解释性，可信人工智能，人群移动性预测

ABSTRACT

With the rapid advancement of the Internet, the Internet of Things (IoT), and cloud computing, the explosion of data has triggered an information revolution that is reshaping various aspects of human life, work, and cognition. Among the core data flows in human society, Spatial-temporal data hold a dominant position, as over 80% of data are associated with geographic coordinates and temporal attributes. The accurate mining of Spatial-temporal data not only facilitates mobility but also plays a crucial role in smart city planning and cyberspace governance. Consequently, Spatial-temporal data mining has garnered significant research attention, leading to the development of various deep learning algorithms tailored for Spatial-temporal analysis.

However, traditional Spatial-temporal learning faces several critical challenges: (1) The centralization tendency in human mobility leads to the "long-tail effect" in Spatial-temporal data, where data sparsity in low-population or remote regions results in insufficient feature representation learning, reduced robustness, and difficulties in localizing peripheral geographic locations. (2) The inherent diversity of human mobility, including variations in movement patterns, location preferences, and temporal behaviors, introduces high semantic complexity, making future trajectory prediction highly challenging. (3) The inherent black-box nature of deep Spatial-temporal models results in a lack of explainability, posing significant challenges to user trust. Existing explainability methods primarily focus on post-hoc explanations, failing to provide real-time, end-to-end explainability of model inference processes.

To address these challenges, this dissertation aims to develop a Spatial-temporal representation learning framework that facilitates the identification and prediction of human mobility while integrating the Information Bottleneck (IB) principle to enhance model explainability. This study systematically addresses three key Spatial-temporal learning tasks—geolocation identification, human trajectory prediction, and explainable Spatial-temporal learning—by focusing on three essential aspects of trustworthy AI: accuracy, robustness, and explainability.

Specifically, the contributions of this dissertation are as follows: (1) To improve the robustness and accuracy of geolocation identification, a network entity geolocation model is proposed, incorporating Spatial-temporal graph neural networks, star graph architec-

tures, and deep probabilistic modeling. This model enables the aggregation of neighboring node information while integrating uncertainty estimation, thereby mitigating the issues of low robustness and data sparsity. (2) To address the challenges posed by high semantic complexity and the difficulty of capturing global mobility patterns in trajectory prediction, a graph-enhanced trajectory prediction model is introduced. This model constructs a trajectory flow graph to capture global transition patterns and integrates it with personalized preferences, Spatial-temporal contextual information, and time-aware category embeddings within a Transformer-based framework. (3) Finally, to tackle the explainability issue of deep Spatial-temporal models, a generic explainable Spatial-temporal learning framework is developed. By refining the variational information bottleneck method, the proposed framework enables compact representation learning, providing ante-hoc explainability while simultaneously improving model accuracy through redundancy compression.

To validate the effectiveness and performance of the proposed models, extensive experiments are conducted on multiple real-world Spatial-temporal datasets. Experimental results demonstrate that the proposed Spatial-temporal models significantly outperform baseline approaches in terms of accuracy for geolocation identification and trajectory prediction tasks. Furthermore, the proposed models achieve notable advancements in both explainability and robustness. The interpretable Spatial-temporal learning framework introduced in this dissertation marks a substantial breakthrough in transitioning from post-hoc to ante-hoc explainability in the domain while striking a balance between model compression and predictive accuracy.

Keywords: Spatial-temporal learning, Explainability, Trustworthy AI, Human mobility prediction

目 录

第一章 绪论.....	1
1.1 研究工作的背景与意义.....	1
1.2 国内外研究历史与现状.....	2
1.2.1 时空数据挖掘.....	2
1.2.2 网络实体定位.....	4
1.2.3 时空轨迹预测.....	6
1.2.4 移动性表示学习.....	6
1.2.5 可解释深度学习.....	8
1.3 本文的主要研究内容.....	9
1.4 本文的主要贡献与创新.....	10
第二章 相关原理与技术	12
2.1 序列信息表征学习.....	12
2.2 时空图神经网络.....	13
2.3 可信人工智能.....	15
2.4 可解释人工智能.....	17
2.5 本章小结.....	18
第三章 基于时空图神经网络的可信实体地理定位	19
3.1 网络实体地理定位.....	19
3.2 术语及问题定义.....	21
3.3 StarGeo 模型设计	22
3.3.1 多源路由节点星型图.....	23
3.3.2 星节点表征学习.....	25
3.3.3 深度概率建模.....	26
3.3.4 StarGeo 训练与优化.....	28
3.4 实验验证与分析.....	29
3.4.1 基准模型.....	30
3.4.2 基本性能评估.....	31
3.4.3 稀疏性分析.....	33
3.4.4 消融实验分析.....	34
3.4.5 鲁棒性分析.....	35
3.5 本章小结.....	35
第四章 基于信息瓶颈理论的可解释轨迹预测	37
4.1 可解释轨迹预测.....	37
4.2 术语及问题定义.....	40

4.3 ExNext 模型设计	40
4.3.1 时空轨迹流图.....	41
4.3.2 移动模式发现.....	42
4.3.3 时空上下文嵌入.....	43
4.3.4 Pre-Next 优化目标	44
4.4 ST-Explainer 框架设计	47
4.4.1 信息熵约束.....	47
4.4.2 变分上下限推断.....	47
4.4.3 时空高维特征可解释.....	49
4.4.4 时空序列结构可解释.....	51
4.5 ExNext 训练及优化	52
4.6 实验验证与分析.....	52
4.6.1 数据集及实验设置.....	52
4.6.2 基准模型.....	53
4.6.3 基本性能评估.....	54
4.6.4 结构及特征可解释.....	55
4.6.5 冷启动性能评估.....	57
4.6.6 复杂度及敏感性分析.....	57
4.7 本章小结.....	58
第五章 可信可解释时空预测系统设计与实现	60
5.1 可信可解释时空预测系统需求分析	60
5.1.1 功能性需求分析.....	61
5.1.2 非功能性需求分析.....	63
5.2 架构设计.....	63
5.3 详细设计.....	65
5.3.1 时空轨迹分析模块.....	65
5.3.2 时空数据中心模块.....	67
5.3.3 网络实体定位模块.....	68
5.3.4 时空轨迹预测模块.....	69
5.3.5 可解释学习模块.....	70
5.3.6 用户管理模块.....	71
5.4 系统实现.....	73
5.5 系统测试.....	77
5.5.1 测试环境配置.....	77
5.5.2 单元测试与集成测试.....	77
5.5.3 功能测试.....	79
5.5.4 性能测试.....	79
5.6 本章小结.....	80

第六章 全文总结与展望	82
6.1 全文总结.....	82
6.2 后续工作展望.....	83
参考文献.....	84

第一章 绪论

1.1 研究工作的背景与意义

全球定位技术和移动互联网的飞速发展催生了大量的基于位置服务（Location-based Service, LBS）^[1-3] 的移动应用，例如，以高德地图、百度地图为代表的基于电子地图（Electronic Map）的移动导航应用，在全球定位系统（如北斗系统）的支持下，通过移动端电子地图为用户提供路径规划、实时导航等丰富功能；以微信、微博和抖音为代表的基于位置的社交网络（Location-based Social Network, LBSN）应用，为用户提供了丰富的文本分享、视频发布、社交交互等功能，用户可以发布含有地理位置标签的内容，并与其他人进行分享。这些应用一方面依赖于地理位置进行服务，另一方面又产生了大量时空数据，促进了人际之间突破传统地理空间约束下的交流互动，并且交互内容形式多样，例如通过视频、文本、图片等形式，对这些时空数据的管理和挖掘成为近年来研究人员关注的重点之一^[4,5]，探索数据中潜在的时空模式、关联关系及其随时间的演变趋势，对于发现社会和自然规律具有重要的科学价值。

时空数据具有两大特性：相关性和异质性。其中，相关性指数据在时间维度和空间维度上是自相关的；异质性指数据在不同时间或空间范围内表现出不同的模式。受相关性和异质性的影响，时空数据具有丰富的语义特征和动态关联性，传统的数据处理方法（如人工检索、规则匹配等）已经难以满足对海量规模时空数据进行深度分析和挖掘的需求。人工智能作为新一轮科技革命和产业变革的重要驱动力，其战略重要性已成为全球普遍共识。自 2015 年国务院正式把人工智能纳入“互联网+”的重点任务以来，我国对人工智能的重视程度逐年递增。2017 年政府工作报告第一次写入“人工智能”，标志着人工智能正式成为国家战略。同年国务院发布的《新一代人工智能发展规划》^[6] 中明确提出“2025 战略目标”：新一代人工智能将在智能制造、智能医疗、智慧城市、智能农业、国防建设等领域得到广泛应用。在这一背景下，利用深度神经网络进行时空数据挖掘成为一个备受关注的话题。深度神经网络作为一种强大的工具，能够有效地处理时空数据中的相关性和异质性，为相关研究者们提供了一种全新的分析视角和方法。

尽管国内外研究者已经从多个角度（例如自监督学习、图学习算子优化等）设计出提升神经网络预测性能的方法，但是在一些领域，预测性能并不是唯一关键指标。人工智能的飞速进步和应用带来了前所未有的机遇和挑战，也将可信人工智能推向产业发展的前沿。可信用于形容一个系统是值得被信任的，其描述了

信任发起者与信任接收者之间的信任关系。在可信时空神经网络的上下文中，信任接收者是时空神经网络系统，信任发起者可以是用户、开发者、监管部门甚至整个社会。可信神经网络被定义为兼顾可信和卓越性能的神经网络，其维度包括但不限于鲁棒性、泛化性、可解释性、隐私保护、公平性等。例如，时空数据异常检测系统需要具有强泛化性，从而适应各种复杂应用场景；基于神经网络的信用评分系统不应该因为用户的年龄、性别等因素拒绝其贷款申请；社会风险预测系统应向使用人员提供预测结果的全面解释。时空数据因其时序特性、动态性、高维复杂性、数据稀疏性和噪声等因素，使得时空模型的接收者对时空学习的可靠性提出了更高的要求。

本文重点研究面向时空数据的可信图学习框架下的准确性、可解释性、不确定性和泛化性。其中，准确性指的是模型预测结果的精确性，一个有应用价值的时空学习模型首先需要具备出色的性能。鲁棒性是机器学习中的一个重要概念，用来测试模型在未知数据上的表现能力，如果一个模型只在处理好的干净数据上表现良好，但在噪声扰动、干扰的数据上表现不佳，那么使用者就很难信任这个模型，从而限制了系统在真实、复杂环境下的应用效能。可解释性指的是使时空神经网络的预测过程能够被使用者理解的能力，如果其预测过程无法被人理解，那么使用者就无法信任神经网络的输出。信任的缺失会进一步限制其在涉及公平（如信用风险预测）、信息安全（如芯片设计）、生命安全（如疾病诊断）相关场景中的应用。目前，虽已有越来越多的研究人员关注可信学习领域，但仍没有面向时空数据的系统性可信学习研究成果，针对这一现状，本文旨在研究面向时空数据的可信学习技术，为构建可靠的时空学习系统奠定基础，推进时空神经网络在各个领域的安全应用。本研究有助于构建可靠的时空学习系统，探索时空数据中潜在的时空模式、关联关系及其随时间的演变趋势，帮助社交服务平台更好地理解用户的移动特征与个性化偏好（如社交、时间和位置等），而且可以基于数据分析为用户提供细粒度精准服务和个性化推荐；也为移动应用运营商的服务质量改进、精准信息推送等方面提供了支撑。此外，基于用户轨迹的可信时空学习还可以为城市管理者乃至公共安全部门提供城市规划、交通疏导、危险分子追踪等支撑依据，有助于提升其互联网空间治理能力。

1.2 国内外研究历史与现状

1.2.1 时空数据挖掘

时空数据挖掘（Spatial-Temporal Data Mining, STDM）已成为多个学科领域中的关键研究方向，广泛应用于气候科学、神经科学、社会科学、流行病学、交通管

理、犯罪预测及地理信息系统等领域。由于这些研究对象通常伴随时间和空间维度的动态变化，数据收集通常依赖于特定的时空标注策略，以构建结构化的时空数据集^[1]。在大数据技术的推动下，地图服务、遥感影像、人口普查数据、GPS 轨迹等大规模时空数据源不断涌现，极大地促进了时空数据分析的深入发展。STDM 在多个现实任务中具有重要价值^[7]，包括但不限于环境监测（如气象预测与空气质量分析）、公共安全（如犯罪时空分布建模）、智能交通（如道路通行模式建模与流量优化）、以及人群行为分析（如个体移动模式识别）等^[7,8]。然而，受限于时空数据的复杂性，传统数据挖掘方法在直接应用于 STDM 任务时面临诸多挑战。相较于常规离散数据（如交易记录或社交关系网络），时空数据通常表现出动态性和高维依赖性^[3,9]，且由于空间和时间的交互作用，其数据分布往往具有较强的非独立性，导致传统基于独立同分布（Independent and Identically Distributed, I.I.D）假设的学习方法在 STDM 场景下难以直接适用。当前，STDM 研究主要集中在以下几个方向：

（1）时间序列建模

在时间序列建模任务中，交通流量预测被广泛关注，其中道路通行数据可视为典型的时间序列问题。近年来，大量研究采用深度学习模型来提高流量预测的准确性^[10-12]。例如，一种基于时空对比学习的城市流量推断方法利用预训练和微调策略，通过构造时空对比学习目标提升粗粒度流量图的表示能力，并采用微调机制结合外部环境信息，从而有效优化流量预测模型的泛化能力。此外，研究者^[12]引入了自适应知识回放策略，使得模型能够在持续学习过程中有效保留历史知识，缓解数据分布变化导致的遗忘问题，从而在城市交通推断任务中取得了较优的性能。

（2）空间映射分析

空间映射分析通常涉及对城市区域或环境变量的建模，该任务通常可转换为类似图像处理的问题，因此卷积神经网络（Convolutional Neural Networks, CNN）在该领域得到广泛应用^[13,14]。例如，研究者提出了 UrbanFlow 系统，通过 CNN 处理城市人群流量分布，以实现实时预测^[15]。此外，针对网约车需求预测任务，有研究引入基于六边形网格的 H-CNN（Hexagonal Convolutional Neural Network）模型，通过六边形划分城市区域，以减少边界效应并增强空间关系建模能力，从而提高预测准确性。除人群流量分析外，CNN 还被应用于环境数据预测任务，例如风速预测问题^[16]，其中多个监测站点的数据被视为空间映射输入，CNN 模型通过同时建模多个站点的时间序列数据，实现对风速变化的精准预测。

（3）轨迹预测与人群移动性建模

在轨迹预测任务中, 循环神经网络 (Recurrent Neural Network, RNN) 及其变体, 如长短时记忆网络 (Long Short-Term Memory, LSTM), 被广泛用于建模个体移动轨迹。轨迹数据通常由一系列时空坐标点构成, 因而适用于序列建模方法。例如, 一项研究提出了一种无碰撞轨迹预测 LSTM 模型, 通过引入排斥池化机制以建模个体之间的动态交互, 从而提升轨迹预测的准确性。此外, 针对城市人群流动性预测任务, 研究者提出了一种基于深度序列学习的模型, 该模型结合 RNN 结构, 对个体的历史移动记录进行建模, 以预测未来出行目的地^[17-19]。另有研究提出 DeepTransport 模型, 专门用于从 GPS 轨迹数据中推断个体的交通方式 (如步行、乘坐公交、私家车出行等), 该模型采用多层 LSTM 结构^[20,21], 结合历史出行数据进行模式识别, 为智能交通系统提供精确的出行方式预测方案。轨迹预测分析的进展表明, 通过深入理解和分析个体的移动模式, 可以为城市规划、交通管理以及个性化推荐系统等领域带来重大的改进和创新。这些研究通过将深度学习模型应用于时空数据, 展现了在捕获复杂时空关系方面的巨大潜力。

随着深度学习方法的不断进步以及时空数据规模的持续增长, STDM 研究正迈向更精细化和智能化的方向。未来的研究趋势包括: (1) 多模态数据融合, 结合遥感影像、社交网络、传感器数据等异构信息, 以提升时空预测模型的泛化能力; (2) 强化学习在时空决策任务中的应用, 例如通过自适应策略优化城市交通控制; (3) 可信和可解释的 STDM 方法, 增强模型的可解释性, 以提高其在实际应用中的透明性和用户信任度。总体而言, STDM 在理论研究与实际应用层面均具有广阔的发展前景, 未来将有望推动更精准的时空信息挖掘技术, 为智能交通、环境监测、城市治理等领域提供更加智能化的数据支持。

1.2.2 网络实体定位

网络实体定位是一种基于互联网信息确定实体 (如服务器、用户或设备) 地理或逻辑位置的技术, 它广泛应用于内容分发、网络安全和地理限制服务, 以优化性能、提升安全性并增强用户体验, 其主要表现为基于 IP 地址进行地理定位。早期的 IP 地理定位系统通常依赖于网络挖掘技术来分析各种互联网数据, 例如网页内容^[22]、WHOIS 数据库^[23]、反向 DNS^[24]、邮政地址^[25]、用户的注册记录^[26]以及社交图谱^[27]。例如, NetGeo^[23] 通过直接查询由区域互联网注册管理机构提供的网络地址注册信息来推断 IP 地址的地理位置。Structon^[25] 首先使用正则表达式提取并聚合字段例如, 从网站的网页中提取城市、国家、邮政编码和区号等信息。接下来, 它基于这些数据生成地理信息向量。然后, 它利用这些向量根据已知的 IP 地址 (通过 DNS 查询服务获取) 推断其他未知的 IP 地址。推断的依据在于

IP 地址范围的聚类模式假设——前缀为 /24 的子网通常包含位于同一城市的 IP 地址。Checkin-Geo^[26] 发现用户会自愿在社交网络上分享签到记录，其中许多签到记录包含位置信息。因此，它将社交网络上的签到记录与用户的登录日志相结合，以建立 IP 地址与地理位置之间的对应关系。最近的一个系统，名为 GeoCAM^[22]，定期检查带有实时网络摄像头的网站以收集位置数据。总体而言，网络挖掘方法由于被动收集网络信息，面临数据不可靠和不完整的问题，这很容易导致地理定位不准确。

为克服被动式网络挖掘存在的问题，许多 IP 地理定位研究采用主动测量来实现精确的 IP 地理定位。这类方法的基本原理是网络延迟与地理距离之间存在正相关关系。例如，GeoPin^[24] 控制少量探测主机对目标 IP 进行 Ping 操作，并计算出一个延迟向量。该向量与已知的地标向量进行比较，计算相似度，从而将目标定位到最近的地标。CBG^[28] 在地标周围创建圆圈，并使用多边测量来推断目标位置。通过添加来自 traceroute 的拓扑测量，TBG^[29] 结合延迟和拓扑进行位置估计。SLG^[30] 利用网络服务器作为地标，并借助地理服务查找地图热点，先通过延迟测量缩小区域，然后再使用相对技术精确定位目标。Spotter^[31] 建立概率密度模型，根据最高概率密度来定位主机。这些方法遵循延迟-距离规则^[32]，这在很大程度上依赖于网络专家的经验，因此限制了其在不同区域的通用性^[33]。此外，由于地理绕路和集中化，网络测量结果往往不准确且不稳定——数据包沿非最优的地理路径传输，关键路径集中在某些区域。因此，网络测量结果与地理距离之间的关系动态变化且难以估计，极大地影响了 IP 地理定位的结果。

近年来，机器学习和深度学习技术在 IP 地理定位中得到了广泛应用。NN-Geo^[34] 构建了一个稳定的观察节点和地标节点网络，覆盖目标 IP 区域。观察节点发送诸如 ping 和 traceroute 等测量数据，而地标节点则是观察节点可到达的已知位置的 IP 地址。利用来自地标节点的测量结果以及观察节点到目标 IP 的延迟，训练一个两层神经网络来对 IP 进行地理定位。GraphGeo^[35] 是首个将图神经网络用于街道级 IP 地理定位的工作。它将 IP 主机特征和邻域关系整合到加权图结构中，以系统地提取常见知识和拓扑结构。它还采用了一种不确定性感知的 GNN 旨在通过持续且灵活的概率推理来处理网络拥塞和抖动带来的噪声和不确定性。GNN-Geo^[36] 是一种 GNN 框架，它将地标连接起来以利用周边信息来定位目标 IP。它将基于测量的 IP 地理定位表述为一个半监督属性图节点回归问题，利用 GNN 通过生成和优化节点及边嵌入来解决该问题。最后，通过基于规则的方法进行定位，在可能的粗略区域内预测，而非在整个空间内进行预测。

1.2.3 时空轨迹预测

时空轨迹预测是通过挖掘用户历史足迹来预测其未来移动趋势的一类任务，其通常表现为兴趣点（POI, Point of Interest）预测，POI 预测主要目的是预测用户最有可能前往的下一个地点。这类方法通常通过挖掘用户数据的时间-空间关联关系实现数据建模、预测和分析。实际应用中，兴趣点预测在旅行推荐、交通流量预测、用户画像分析与人类行为模式相关的场景中发挥重要作用，此外还可应用于犯罪追踪、社会治理等公共安全领域。

近期的深度学习解决方案激发了众多研究人员和从业者去学习人类周期性规律。从大量的历史签到数据中挖掘出的差异性特征。特别是，诸如长短期记忆网络^[37]和门控循环单元^[38]这样的深度（循环）神经网络在下一个兴趣点预测任务中受到了广泛关注，因为它们能够捕捉到移动模式理解中的序列依赖关系。例如，^[39]扩展了基本的 RNN 模型，并将时空影响整合到每个 RNN 单元中，在下一个位置预测方面取得了令人鼓舞的结果。赵等人提出了一种新颖的 ST-LSTM，它在标准 LSTM 中实现了时间门和距离门，旨在捕捉连续签到之间的时空关系^[40]。为了学习更多的上下文信息，吴等人^[41]提出了一种个性化长短期偏好学习方案，以学习特定用户的上下文，其中考虑了兴趣点的位置和类别对用户行为的不同影响。虽然大多数研究都集中在对基于 RNN 的模块进行剪枝或修改^[42-44]，但也有研究尝试采用其他流行的深度神经网络进行下一个兴趣点预测，例如基于注意力机制的神经网络^[45,46]和卷积神经网络^[47,48]。薛等人^[45]构建了 Transformer 架构作为移动性特征提取器，其中将历史轨迹和语义上下文作为输入，以处理诸如时间、地理上下文等多种因素。

1.2.4 移动性表示学习

兴趣点（POI）嵌入和轨迹嵌入作为时空数据表征学习的关键组成部分，在近年来的移动性预测研究中得到了深入探索。针对 POI 嵌入问题，早期方法^[39,49]主要依赖固定或可学习的矩阵表示，以降低高维空间中的计算复杂度。然而，这些方法难以充分捕捉兴趣点之间的语义关联，使得其在建模复杂移动行为时存在局限性。受自然语言处理（NLP）中词嵌入方法的启发^[50,51]，研究者引入了基于 word2vec 的方法^[52]，将兴趣点视为“单词”，签到轨迹视为“语句”，通过在签到序列上训练 word2vec 模型，获得兴趣点的低维表示。此类方法能够从历史签到序列中学习兴趣点的邻近性和语义相似性，并在一定程度上提高了 POI 表征的质量。然而，由于兴趣点签到数据往往稀疏，仅依靠 word2vec 进行嵌入学习可能无法捕捉到兴趣点之间的深层交互信息。为此，一些研究尝试结合地理因素，如 POI2Vec

[53] 通过引入空间约束,使得兴趣点嵌入能够在不同的地理环境下保持稳定性。然而,这些基于序列的兴趣点嵌入方法在面对复杂 POI 交互关系时仍然存在不足。

随着图神经网络 (Graph Neural Networks, GNNs) 的发展,基于图结构的 POI 嵌入方法逐渐成为研究热点。这类方法通过构建兴趣点交互网络,学习兴趣点之间的复杂时空关系 [54,55]。例如,一些研究 [55] 利用 GNN 处理兴趣点的签到数据,并结合时间和用户行为信息进行图结构化建模。这些方法能够有效捕捉 POI 之间的空间依赖关系,并挖掘签到数据中的潜在模式。然而,大多数 GNN-based 方法仅关注兴趣点之间的同质交互,而忽略了签到时间、用户类别、兴趣点功能等异质信息的作用。由于人群移动性通常受到多种因素影响,如个体兴趣、时间约束、社交关系等,仅基于 POI 之间的几何关系进行嵌入学习,难以有效建模复杂的移动行为。因此,如何在 GNN 框架下同时建模兴趣点的空间特征、时间模式和用户偏好,仍然是一个具有挑战性的问题。

在轨迹嵌入的研究方面,现有方法 [39,40] 大多基于历史轨迹数据进行学习,并以下一个兴趣点 (Next POI) 预测作为监督信号。然而,由于轨迹数据通常较为稀疏,单纯依赖监督学习可能会影响模型的泛化能力。为了解决这一问题,研究者 [52,56] 提出了多种无监督或自监督学习方法,以提升轨迹表征的稳定性和鲁棒性。例如,一些研究尝试将未标注的轨迹数据作为辅助信息,通过对比学习或数据增强策略,使模型能够从大量未标注数据中学习轨迹特征。

此外,生成模型在轨迹表示学习中的应用也受到广泛关注。一些研究利用变分自编码器 (Variational Autoencoder, VAE) 或对抗生成网络 (Generative Adversarial Networks, GAN) 来建模轨迹数据的潜在分布。例如, VANext 扩展了 VAE 模型 [57], 引入用户偏好建模的不确定性,对轨迹数据进行正则化学习,以提升轨迹嵌入的泛化能力。同时, METAODE 采用变分贝叶斯方法,将历史轨迹编码到隐变量空间,从而在有限的条件下有效提升轨迹预测的精度。这些方法的共同特点是利用生成式建模方式,在潜在空间中学习轨迹的分布特性。然而,大多数现有方法倾向于将轨迹的时空信息、用户偏好、环境因素等多种语义信息整合到同一嵌入空间中,而较少关注如何在表征学习过程中解耦不同的信息源。这导致模型在预测任务中难以明确区分不同因素的贡献,影响了模型的可解释性和泛化能力。因此,如何在轨迹嵌入中构建灵活的解耦表征机制,以同时提升预测性能和模型可解释性,是当前研究面临的重要挑战。

1.2.5 可解释深度学习

深度学习广泛应用于社交网络、金融、法律、医学、物理学等领域。在一些场景中，构建更准确的预测模型通常不是唯一的目标，从数据中发现引发某些预测的模式通常更为重要^[58]。例如，识别分子中产生其某些特性的官能团可能会为进一步的实验提供见解^[59]。然而，由于神经网络的高维度、非线性等黑盒特性，人类很难直观理解神经网络的信息传递模式，继而制约其在风险敏感场景的应用效能。深度学习的可解释性分为特征可解释性和模型可解释性^[60]。其中，特征可解释性指图神经网络的输入是人类可理解的，即输入特征具有明确的物理含义；模型可解释性指模型的信息交互机制是人类可理解的，即给定输入数据和神经网络，当神经网络输出某个结果时，研究人员需要理解为什么该神经网络会输出该结果。相比于特征可解释性，模型可解释性是研究人员关注的重点。模型可解释性主要包含两类研究方向：模型自我可解释以及模型后验可解释。无论哪种类型的可解释性方法，其本质任务均是寻找出关键节点特征和核心子结构。接下来，我们引入可解释性方法的两类定义，即模型先验可解释方法和模型后验可解释方法。

模型后验可解释 (Post-hoc Explainable)，是一种不改变现有模型内容的可解释性方案。该类型通常需要构建一个代理模型，要求代理模型尽可能少地利用节点属性、结构信息的同时，期望代理模型的输出逼近预训练神经网络的输出。在神经网络模型 f 中，事后解释模型旨在学习一个解释性函数 Γ 来识别对 f 的性能贡献最大的子图 G_s ：

$$G_s = \Gamma(G, Y, f) \text{ s.t. } \max I(Y, G_s) \quad (1-1)$$

这一方法由于其与模型的输出过程无关，解释不是直接从神经网络中获得，例如，例如，GNNExplainer^[61] 分别在节点属性和图结构上采用两个软掩码矩阵，它们在最大化互信息框架下进行端到端学习，PGExplainer^[62] 通过训练一个统一全局模型实现归纳环境部署，避免为每个要解释的实例从头开始重新学习。在这情况下生成的解释往往与模型解耦程度高，解释性函数 Γ 可能存在偏见甚至歪曲了真实解释。这些问题阻碍了事后可解释方法的可靠性和适用性。

模型先验可解释 (Ante-hoc Explainable)，也称作自我可解释，旨在对模型架构进行修改以赋予其可解释能力。注意力机制被认为是自我可解释的代表性工作^[63]，通过可视化注意力权重分布，研究人员可以直观发现哪些特征被赋予了更高的权重，从而解释模型的行为。与事后解释模型不同，内在解释的目标是学习

一个模型 f 来同时预测目标并识别对预测结果影响最大的子结构，定义如下：

$$\hat{Y}, G_s = f(G) \quad s.t. \min L(Y, \hat{Y}) \wedge \max I(Y, G_s) \quad (1-2)$$

在这一可解释实现方法中，模型不仅能够预测结果，还能够同时输出模型对于本次预测结果的解释。然而，自然语言处理领域的研究人员发现，由于神经网络中往往包含多层网络，且存在非线性激活函数，导致注意力机制不一定能够正常显式呈现那些真正主导模型结果的特征^[64]。近期一些文献^[65,66]引入信息压缩理论对信息进行压缩，通过增加与压缩率正相关的惩罚项，迫使模型在学习过程中仅使用最重要的信息。例如，IB-Subgraph^[65]添加空间约束，通过设定图尺寸相关的超参数迫使模型仅使用特定尺寸的子图完成任务。GSAT^[66]放松了对子图连通性的约束，提出了一种基于信息瓶颈理论的随机注意力机制实现信息压缩可解释。

1.3 本文的主要研究内容

本文旨在通过时空数据的可信深度学习来发现人群地理位置及其移动性偏好。针对目前时空学习遇到的问题，通过对人群轨迹进行深度建模来理解轨迹数据中的时空语义信息、时空依赖信息、社交属性信息等，并探索基于深度神经网络框架下的轨迹各要素融合和特征表征方法，如图 1-1。以轨迹产生者（用户）为研究主体，首先，建立用户与时空位置之间的关系即网络实体定位，并将数据不确定性纳入这一定位过程中的模型构建；其次，在网络实体定位深度学习解决方案基础上，继续研究轨迹产生者的下一步移动动向即人群时空轨迹预测；随后，尝试将这两个过程通过系统工程实现端到端的可视化的可信可解释时空表征模型应用。如图 1-1 所示，各部分研究内容如下：围绕面向时空数据的可信、可解释学习这一科学问题，本文旨在揭示时空神经网络的可信机制，着重从准确性、可解释性、不确定性的可信三要素展开研究，建立可信时空学习范式。具体的研究目标包括：

（1）构建可信位置预测方法：利用网络实体地理定位技术，结合深度学习模型，研究如何在高噪声、不确定性的环境下提升用户位置预测的准确性与稳定性。

（2）建立时空图数据中不同粒度的自我可解释范式，量化时空维度上图结构-特征重要性，解释时空图表示学习机制和原理；

（3）可信可解释时空预测系统的设计与实现：构建集实时位置预测、用户移动模式分析、可视化解释分析等功能于一体的可信可解释系统，并探索其在城市规划、公共安全等领域的应用价值。




图 1-1 本文研究内容

1.4 本文的主要贡献与创新

本论文围绕可信可解释的时空预测展开研究，聚焦于网络实体地理定位与人群移动轨迹预测问题，并提出了一系列创新性方法和系统。主要贡献与创新如下：

针对现有基于网络测量数据或用户属性知识的地理定位方法在数据稀疏性和噪声影响下的稳定性问题，本文提出了一种结合深度概率建模与星型图（Star Graph）架构的可信网络实体地理定位方法。具体而言：设计了一种不确定性感知的地理定位模型，利用深度概率建模方法对用户位置预测的不确定性进行估计，以提高模型的鲁棒性。引入星型图结构建模社交网络，利用中心化的表征学习方式增强网络中不同类型实体间的关联性，有效缓解数据稀疏问题。

为提高人群轨迹预测任务的可解释性，本文基于信息瓶颈理论，提出了一种同时优化预测准确性和解释性的轨迹预测模型，主要创新点包括：可解释时空轨迹表示学习：结合变分信息瓶颈，筛选轨迹中的轨迹关键子序列，提取时空数据的高效压缩表示并保留与目标变量最相关的信息，使预测模型能以更精简的输入获得同等甚至更优的预测效果，提升模型的可解释性。

本文进一步探索可信可解释时空预测的实际应用，设计并实现一套完整的可信可解释时空预测系统，支持实时位置预测、用户移动模式分析、可视化解释分析等功能。提出基于信息瓶颈约束的动态信息压缩机制，在不影响预测精度的前提下，减少冗余数据，提高模型推理效率，并使预测结果更具可解释性。

综上所述，本文围绕可信网络实体地理定位和可解释轨迹预测展开研究，主要创新点体现在：（1）为解决地理位置识别任务中鲁棒性差、精度低的问题，提出

了实体地理定位模型，采用时空图神经网络技术、星型图架构和深度概率建模技术，允许模型聚合邻居节点信息，高效学习表征信息，克服节点稀疏性问题和数据噪声引起的鲁棒性；（2）为解决轨迹预测任务中的语义复杂性高，全局移动模式难发现的问题，提出了图增强轨迹预测模型，通过构建轨迹流图来发现全局转换模式，并将其与个性化偏好、时空上下文和时间感知类别嵌入整合到 Transformer 模型中预测轨迹；（3）为解决模型面临的不可解释困境，设计通用的可解释时空学习框架，通过改进变分信息瓶颈理论进行紧凑表示学习，不仅赋予模型先验可解释性，还通过改善表示的质量提高了模型精度。（4）最后，设计开发可信可解释时空预测原型系统，集成动态信息压缩和不确定性量化，支持多场景应用。本文的研究成果在位置服务、智能交通、社交计算等领域具有重要的理论价值和实际应用意义。

第二章 相关原理与技术

2.1 序列信息表征学习

序列信息表征是深度学习在时空数据建模中的重要组成部分,其中循环神经网络(Recurrent Neural Network, RNN)^[67]因其能够捕捉数据之间的时序依赖性,被广泛应用于序列数据的建模任务。RNN 主要由输入层、隐藏层和输出层组成,旨在通过递归计算逐步提取输入序列中的特征信息。对于经过向量化处理的输入序列 $v(l_1), \dots, v(l_i), \dots, v(l_n)$, 假设 $v(l_i)$ 表示位置 l_i 的向量表示, 则其隐藏状态可通过以下递归公式进行计算:

$$h_i = f(v(l_i), h_{i-1}) \quad (2-1)$$

其中, h_{i-1} 代表前一时间步的隐藏状态, $f(\cdot)$ 通常是一个非线性变换函数。进一步地, 在深度神经网络框架下, 该计算过程可被形式化为:

$$h_i = f(W_x v(l_i) + W_h h_{i-1}) \quad (2-2)$$

其中, W_x 和 W_h 是神经网络的可训练参数, $f(\cdot)$ 为非线性激活函数。RNN 结构在序列数据建模中表现良好, 并在文本分析、语音识别及机器翻译等任务中取得了显著进展。然而, 由于梯度消失问题及长期依赖关系建模能力不足, 传统 RNN 存在性能瓶颈。因此, 长短期记忆网络(Long Short-Term Memory Network, LSTM)、门控循环单元(Gated Recurrent Unit, GRU)等改进型 RNN 相继被提出, 以增强模型对长期依赖信息的捕获能力。例如, Yang 等人提出了融合多种 RNN 结构的下一个兴趣点预测和社交关系建模方法^[68], Liu 等人设计了结合时空特征的 RNN 模型用于位置预测。这些研究表明, RNN 在序列信息学习任务中具有较强的建模能力, 一般情况下, 完整的序列可以通过隐藏状态序列进行表征, 其最终的全局表示可通过取隐藏状态的均值或最终时间步的隐藏状态来获得。

在实际应用中, 序列数据往往呈现出大量无监督样本, 因此如何在无标签数据上进行高效学习成为一个重要问题。基于 RNN 的自编码器为此类任务提供了一种端到端的无监督学习方案, 该模型由编码器和解码器构成^[63], 可用于学习序列数据的低维表征。其结构可归属于序列到序列(Seq2Seq)范式的一个特例, 即输入数据与输出数据保持一致。编码器首先将时序数据映射到一个低维潜在空间表

示 z ，然后解码器通过该表示重构输入数据。该过程可描述为：

$$z = \text{Encoder}(v(l_1), \dots, v(l_n)) \quad (2-3)$$

$$\hat{X} = \text{Decoder}(z) \quad (2-4)$$

其中， $\hat{X}$ 为解码后的重构数据。该方法已在机器翻译、语音识别等任务的预训练中发挥重要作用，并提升了模型训练效果。然而，在端到端学习过程中，不同时间步的输入对最终表征的贡献度可能存在差异。因此，为进一步提升模型的特征提取能力，Attention 机制被提出以衡量输入数据的重要性，使模型能够自动聚焦于序列中的关键信息，它可以更好地抽取序列数据中的重要或关键信息^[69]。

在 Attention 机制下，RNN 编码器首先对序列数据 $l_1, \dots, l_i, \dots, l_n$ 进行编码，得到隐藏状态序列 $h_1, \dots, h_i, \dots, h_n$ ，然后通过加权求和的方式计算全局表示：

$$z = \sum_{i=1}^n \alpha_i h_i \quad (2-5)$$

其中， α_i 代表隐藏状态 h_i 的注意力权重，该权重通常通过查询（query）与上下文向量的相似性计算得到。假设查询向量 q_i 由隐藏状态 h_i 经过一个非线性变换函数 $f(\cdot)$ 计算而得，则注意力权重 α_i 可表示为：

$$q_i = f(h_i) \alpha_i = \frac{\exp(q_i^\top u)}{\sum_{i=1}^n \exp(q_i^\top u)} \quad (2-6)$$

其中， u 为一个随机初始化的上下文向量， $\exp(\cdot)$ 为指数函数。Attention 机制的引入使得模型能够动态调整不同时间步的权重，提高了序列信息提取的有效性，进而提升了模型的表达能力和预测性能。近年来，该方法已广泛应用于文本理解、时间序列预测及轨迹建模等任务，并在各类深度学习框架中得到成功实践。

2.2 时空图神经网络

时空图神经网络 (Spatial-Temporal Graph Neural Network, STGNN)^[70] 作为一种强大的工具，在包括智能交通和公共安全在内的各种现实世界城市应用中能够有效地建模时空依赖关系，已经受到了广泛的欢迎。在时空图 (Spatial-Temporal Graph, STG) 预测中，往往使用 T 个时间步和代表地点的 N 个节点表示场景，使用 $G = (V, E, A, X)$ 表示时空图，其中 V 是 N 个节点的集合， E 是邻接矩阵 $A \in \mathbb{R}^{N \times N}$ 记录的边，而 $X \in \mathbb{R}^{T \times N \times F}$ 是与属性（如交通流量或犯罪发生率）相关联的特征矩阵，其中 F 代表特征维度， T 代表时间步。基于此，定义 STG 预测任务如下：在

STG 预测中，目标是学习一个被记为 f 的预测函数。给定前 L 个已知观察点，这个函数旨在预测下一个时间步 (L') 的时空图的特定属性：

$$Y_{t+L'/-1} = f(G(V, E, A, X_{t-L:t-1})) \quad (2-7)$$

其中 $X \in \mathbb{R}^{T \times N \times F}$ 是从时间步 $t-L$ 到 $t-1$ 具有 F 维特征的观察点。 $Y \in \mathbb{R}^{L' \times N \times F'}$ 是具有 F' 维特征的下一个时间步 (L') 的预测。

STGNN 结合图注意力机制来捕获时空依赖性。遵循文献^[71]，采用该 GNN 框架来捕获在相同的时空图结构 $A \in \mathbb{R}^{N \times T \times N}$ 上的时空依赖性。为避免 STG 学习巨大的时间复杂性，我们将联合图分解为时间图和空间图。首先，STG 特征矩阵 $X \in \mathbb{R}^{T \times N \times F}$ 被嵌入到维度为 d 的潜在空间中，通过一个全连接层：

$$X^{(0)} = X \cdot W^{(0)} + b^{(0)} \quad (2-8)$$

其中 $X^{(0)} \in \mathbb{R}^{T \times N \times d}$ 代表 STG 的初始嵌入， $W^{(0)} \in \mathbb{R}^{F \times d}$ ， $b^{(0)} \in \mathbb{R}^d$ 表示权重和偏置矩阵。此外，为了单独编码空间和时间动态，我们的 GAT， $X^{(0)}$ 转换为空间嵌入 $X^{(s)} = \{x_j^{(s)} \in \mathbb{R}^{d_s}, 1 \leq j \leq N\}$ 通过以下线性变换：

$$x_j^{(s)} = \sum_{i=1}^T X_{i,j}^{(0)} W_i^{(s)} + b^{(s)} \quad (2-9)$$

其中 $W^{(s)} \in \mathbb{R}^{T \times d \times d_s}$ 和 $b^{(s)} \in \mathbb{R}^{d_s}$ 表示权重和偏置参数。在这一阶段，我们使用 G 中的空间子图，其定义为 $G^{(s)} = (V^{(s)}, E^{(s)}, A^{(s)}, X^{(s)})$ ，其中 $A^{(s)} \in \mathbb{R}^{N \times N}$ 表示记录空间节点间相关性的空间邻接矩阵。关于空间图推理，采用了堆叠的多头图注意力网络 (GAT)，其中 K 头图注意力层定义如下：

$$h_j^{(s)} = \sum_{k=1}^K \sum_{j' \in N(j) \cup \{j\}} \alpha_{jj'}^k \cdot W^k x_{j'}^{(s)}$$

$$\alpha_{jj'} = \frac{\exp(\sigma(\mathbf{a}^\top [W x_j^{(s)} \| W x_{j'}^{(s)}]))}{\sum_{j'' \in N(j) \cup \{j\}} \exp(\sigma(\mathbf{a}^\top [W x_j^{(s)} \| W x_{j''}^{(s)}]))} \quad (2-10)$$

其中 $N(j)$ 表示第 j 个区域按 $A^{(s)}$ 所记录的邻居集合， $\mathbf{a} \in \mathbb{R}^{d_s}$ 表示权重向量， $W \in \mathbb{R}^{d_s \times d_s}$ 表示权重参数， $\sigma(\cdot)$ 表示 LeakyReLU 激活函数。通过多层 GAT，我们获得了提取的空间嵌入 $H^{(s)} = \{h_j^{(s)} \in \mathbb{R}^{d_s}, 1 \leq j \leq N\}$ 。然后我们将 $H^{(s)}$ 转换为时空嵌入空间 $H^{(s)} \in \mathbb{R}^{T \times N \times d}$ ，利用带有权重矩阵 $W(1) \in \mathbb{R}^{d \times d_s}$ 和偏置参数 $B(1) \in \mathbb{R}^{T \times d}$ 的全连接层，如下所示：

$$H_{i,j}^{(s)} = W_i^{(1)} \cdot h_j^{(s)} + B_i^{(1)} \quad (2-11)$$

STGNN 遵循相似的时间关系学习范式来建模时间图 $G^{(t)} = (V^{(t)}, E^{(t)}, A^{(t)}, X^{(t)})$, 其中 $A^{(t)} \in \mathbb{R}^{T \times T}$ 是时间邻接矩阵, 揭示了时间步骤之间的相关性, $X^{(t)} = \{x_i^{(t)} \in \mathbb{R}^d, 1 \leq i \leq T\}$ 代表时间特征矩阵。 $X^{(t)}$ 是通过利用与公式 2-9 相似的全连接层从 $H^{(s)}$ 转化而来的。为模拟时间动态, 我们使用定义类似于公式 2-10 的堆叠多头 GAT 层来生成时间特征矩阵 $H^{(t)} = \{h_i^{(t)} \in \mathbb{R}^d, 1 \leq i \leq T\}$ 。最终, 我们将时间特征 $H^{(t)}$ 转化为最终的时空嵌入矩阵 $H = H^{(t)} \in \mathbb{R}^{T \times N \times d}$, 采用与公式 2-11 相似的转化函数。因此, 我们可以总结构造空间和时间图的方法如下:

(i) 空间图 $A^{(s)}$: 空间图代表空间单元之间的相关性。对于两种常见的时空预测类型, 即基于图和基于网格的预测^[72], 可以使用阈值化的高斯核^[73]并考虑邻近区域作为邻居^[5, 74]来构建空间图。

(ii) 时间图 $A^{(t)}$: 时间图代表不同时间步骤的时间表示之间的相关性。形式上, 如果历史时间步长是 T , 我们有时间图 $A^{(t)} \in \mathbb{R}^{T \times T}$ 并且对于任意的 i, j , $A_{ij}^{(t)} = 1$, 这意味着我们假设每个时间步骤最初都相互影响。应用 GAT 进行信息传递在时间图上等同于现有的利用自注意力机制捕获时间相关性的工作^[75]。

为增强 STGNN 模型推理阶段对时空上下文的建模, 我们将空间和时间嵌入注入到 STG 关系嵌入 H 中。具体来说, STGNN 利用了多种自由形式的嵌入: 区域表示 $E^{(s)} \in \mathbb{R}^{N \times d}$, 一天中时间的嵌入 $E^{(ToD)} \in \mathbb{R}^{T \times d}$, 以及一周中某天的嵌入 $E^{(DoW)} \in \mathbb{R}^{T \times d}$ 。在实现上, 我们随机初始化一个张量 $E^{(s)} \in \mathbb{R}^{N \times D}$, 并且该张量的值可以在反向传播过程中更新 (即, 可学习的)。关于时间位置嵌入, 我们随机初始化一个时间的张量 $E_{\text{all}}^{(ToD)} \in \mathbb{R}^{288 \times D}$ 和一个星期的张量 $E_{\text{all}}^{(DoW)} \in \mathbb{R}^{7 \times D}$, 其中 288 表示一天有 288 个时间步 (每 5 分钟一个间隔), 7 表示一周有 7 天。STG 查询的输入时间和星期的索引用于获取时间位置嵌入的张量。然后 STExplainer 按照如下方式进行预测:

$$Y = \text{MLP}_1([H \| E^{(s)} \| E^{(ToD)} \| E^{(DoW)}]) \| \text{MLP}_2(X) \quad (2-12)$$

其中 $\|$ 表示连接, $\text{MLP}_1(\cdot)$ 和 $\text{MLP}_2(\cdot)$ 表示两个多层感知器, 用于做出最终预测并利用低级特征 X , 分别。 Y 表示使用位置感知的 STG 嵌入预测未来的 STG 属性。

2.3 可信人工智能

欧盟提出了值得信赖的人工智能系统的指导方针^[76], 概述了值得信赖的人工智能应遵循的四项关键伦理原则: 尊重人类自主权、防止伤害、公平和可解释性。考虑到人机交互的独特性质, 值得信赖的概念此后得到了重新定义^[77]。在这个新的框架中, 人工智能系统应具备技术上的稳健性, 并防范恶意使用 (稳健性和隐

私)。还应确保个人和群体免受不公平偏见的影响(公平性),并且人工智能系统的决策过程应透明且可解释(可解释性)。遵循这些更新后的指导方针,本文所提出的可信可解释人工智能的目标是构建一个可靠的人工智能系统,同时优化准确性、可解释性和可靠性。该系统基于信息瓶颈和不确定性理论,从而在保持高精度预测准确性的同时,提供可解释性和可靠性。

深度学习中的可解释性。可解释机器学习近来备受关注。简明且全面的解释对于简洁地传达重要信息以及解释黑箱决策系统是必要的。然而,现有的可解释机器学习方法未能同时兼顾简洁性和全面性,导致解释冗余。变分信息瓶颈(VIB)^[7]是一种与系统无关的可解释方法,能够提供简明而全面的解释。VIB利用信息论中的信息瓶颈理论来提供解释。对于每个实例,VIB选择关于输入最大压缩(简洁性)且对黑盒模型在该输入上的决策具有信息量(全面性)的关键特征。

深度学习中的不确定性。传统的回归和分类学习算法通常无法考虑模型固有的不确定性。深度学习中不确定性估计的最新进展旨在通过增强模型预测自身置信度的能力来弥补这一不足^[78]。神经网络通常表现出两种主要的不确定性形式:偶然不确定性(或数据不确定性)和认知不确定性(或模型不确定性)。前者源于固有的数据不确定性,比如网络波动和内在方差,而后者则源于模型参数的不确定性,并与对所学模型的信心有关^[79]。

为了对偶然不确定性进行建模,有人提出了直接从数据中学习的方法,即训练模型直接根据现有数据估计不确定性。这通常是通过分布学习来实现的。即,该模型经过训练能够预测目标变量的整个概率分布。这使得模型能够捕捉数据中的变异性,并表达对模型预测的不确定性^[80]。

另一方面,诸如贝叶斯神经网络、敏感性分析、Dropout以及集成学习等方法已被开发出来用于估计知识不确定性。例如,贝叶斯神经网络^[81]为模型不确定性推理提供了数学基础,但其计算成本较高。蒙特卡罗 Dropout^[82]利用具有Dropout层的神经网络进行训练,这可以近似为执行变分推断——通过在训练和测试时都激活Dropout来计算预测不确定性。尽管易于实现且与网络无关,但与贝叶斯方法相比,Dropout方法往往过于自信,并且在处理分布外输入时低估了知识不确定性。集成学习^[83]在相同数据上训练多个模型以反映知识不确定性,这是一种经过充分研究的技术,且可以并行训练。然而,它需要训练和存储多个模型,并且由于不同模型之间缺乏多样性,仍然会低估不确定性。更重要的是,集成方法不是贝叶斯方法,因此无法对参数执行贝叶斯推断。

证据深度学习^[80,84]是一种利用邓普斯特-谢弗理论和信任函数来对深度神经网络中的认知不确定性进行建模的框架。这种方法通过表示分布上的分布,为直

接在模型中参数化不确定性提供了一种途径。通过明确建模认知不确定性所实现的一些关键能力包括：检测输入数据与训练数据相比是否属于分布外数据，以及提高模型对对抗性攻击的鲁棒性。通过量化不确定性，证据深度学习使模型能够更好地处理不熟悉或异常的输入。最近的研究在通过证据深度学习量化不确定性方面取得了令人鼓舞的成果，不过要解决在扩展到更大、更复杂的模型和数据集时所面临的挑战，仍需开展更多工作。更重要的是，证据深度学习为量化模型不确定性提供了一个基于贝叶斯原理的框架，从而提高模型的可靠性和鲁棒性。与诸如随机失活或模型集成等其他不确定性建模方法相比，能够表示预测结果的分布这一灵活性是一个显著的优势。

2.4 可解释人工智能

在时空数据挖掘的任务背景下，可解释人工智能（XAI）旨在提供透明和人类可理解的解释（参照人类认知理论，解释通常呈现为影响决策的关键因素），提高黑盒模型的可信度，并帮助用户有效利用时空模型。巧妙的是，信息论允许我们可以计算在满足一定失真量度的限制下，信道输入输出间互信息量的最小值。这一理念在机器学习中进一步发展为信息瓶颈理论（Information Bottleneck Theory）^[85]。信息瓶颈理论是信息论和机器学习中的一个理论框架，旨在找到数据压缩与预测准确性之间的最佳平衡，目标则变为找到输入数据的最优表示形式，即保留最相关的信息，同时尽量减少冗余和噪声。此外，它能够为黑箱模型生成简洁的解释，突出对预测影响最大的元素^[61,65]。形式上，给定输入数据 X ， X 的表示 Z 以及目标 Y ，对于满足马尔可夫链 $\langle Y-X-Z \rangle$ 的 (X, Y, Z) ，信息瓶颈（IB）学习的最小充分表示 Z 为：

$$Z = \arg \min_Z -I(Z; Y) + \beta I(Z; X), \quad (2-13)$$

其中 β 是拉格朗日乘子，用于权衡充分性和最小性。直观地说，第一项 $-IZY$ 可以被视为预测项。其目的是促使模型保留下游任务所需的关键信息。第二项 $I(Z; X)$ 是压缩项，它迫使模型消除冗余和与标签无关的信息。受先前信息瓶颈理论的启发，近年来研究者提出基于图 G 和真实标签 Y 的子图 G_S 的图信息瓶颈（Graph Information Bottleneck, GIB）^[86] 技术，用以增强 GNN 的可解释性：

$$G_S = \arg \max_{G_S} I(Y, G_S) = H(Y) - H(Y|G_S) \quad (2-14)$$

其中 $I(\cdot)$ 表示互信息函数， $H(\cdot)$ 代表信息熵。 (V_S, E_S, A_S, X_S) 代表 G 的子图，具有子节点集 V_S ，子边集 E_S ，子邻接矩阵 A_S 和子特征矩阵 X_S 。该模型的优化目标是

找到对模型 f 作用下预测贡献最大的子图 G_S ，这有助于用户直观地理解黑盒 GNN 模型。

GIB 技术旨在将图结构数据压缩成低维度的表示，这些表示与下游标签强相关。这些压缩的表示捕捉了原始信息的一个子集，同时有效地对下游任务中的标签进行予考虑。因此，GIB 作为某些文献中的可解释模型而受到认可，例如文献 [66,87]。GIB 的基本原理是通过最小化下目标来优化嵌入：

$$\min_{P(Z_X|G)} -I(Y, Z_X) + \beta I(G, Z_X) \quad (2-15)$$

其中 Z_X 是图特征矩阵 X 的隐藏表示， $Z_X = \mathbf{J}X_G$ 。虽然传统的 GIB 生成可捕捉下游标签背后推理的低维表示，但这些密集隐藏嵌入对人类来说通常难以理解，这一特性极大地限制了使用传统 GIB 进行模型解释的适用性。

2.5 本章小结

本章回顾了时空数据挖掘中的序列信息表征学习、时空图神经网络、可信人工智能和可解释人工智能等关键技术，为后续研究提供理论基础。

首先，我们介绍了序列信息表征学习，回顾了循环神经网络、长短时记忆网络、门控循环单元及自注意力机制在建模时间序列数据中的应用，并探讨了如何通过注意力机制增强关键特征的表达能力。其次，我们详细介绍了时空图神经网络，包括时空图的数学建模、图卷积网络和图注意力网络的应用，以及空间和时间依赖关系的建模方法。我们分析了邻接矩阵的构建方式，并总结了 STGNN 在时空预测任务中的应用。随后，我们探讨了可信人工智能的核心概念，介绍了不确定性建模方法，包括偶然不确定性和认知不确定性，并回顾了贝叶斯神经网络、蒙特卡罗 Dropout 和证据深度学习在量化不确定性方面的应用，分析了其在提升时空预测稳健性方面的作用。最后，我们介绍了可解释人工智能，重点讨论了信息瓶颈理论及其在优化模型压缩性和可解释性中的应用。我们回顾了互信息的计算，并探讨了图信息瓶颈在图神经网络中的可解释性建模方法。

本章系统性地回顾了序列信息表征学习、时空图神经网络、可信人工智能和可解释人工智能的相关理论，为后续可信可解释时空预测模型的研究提供了理论支持。接下来的章节将结合深度概率建模、信息瓶颈理论，进一步优化模型的时空预测能力，并通过实验验证所提出方法的有效性。

第三章 基于时空图神经网络的可信实体地理定位

3.1 网络实体地理定位

许多基于位置的应用程序，例如频谱分配^[88]、智慧城市^[89]、地理网络^[90]^[94]以及其他众多应用^[91,92]，都需要互联网主机的准确地理位置。目前流行的定位方法依赖于通过全球定位系统、蜂窝网络和无线互联网网络等来源收集位置信息。这些技术依赖于用户自愿启用定位服务并分享其位置数据（即服务器只有在用户明确报告的情况下才会获取地理位置数据）。然而，并非所有用户都愿意这样做，原因可能是出于隐私考虑或其他原因。此外，客户端依赖型系统需要具备特定硬件功能的设备来确定位置。不具备这些功能的设备，例如基本的物联网设备或某些嵌入式系统，无法参与客户端依赖型地理定位。而且，客户端依赖型地理定位系统在室内定位时可能会遇到困难，因为室内可能无法接收到 GPS 信号，而 Wi-Fi 或蜂窝网络信号也可能因多径效应而不太可靠。

另外，许多不依赖客户端的方法（例如 IP 地理定位）已被提出用于估算地理位置。这些方法并不依赖用户自愿分享其位置数据，而是采用其他方法在没有客户端直接输入的情况下确定位置。早期的研究^[23,24]利用从互联网收集的各种信息来对特定 IP 进行地理定位。另一些研究^[28,30]则依赖主动网络延迟测量，采用多边测量技术，并结合预定义的延迟到距离转换函数来确定地理地址。后来，研究者们引入神经网络建模方法，用于减少由网络专家制定的派生规则所导致的经验错误。例如，一些研究^[34,93]使用神经网络自动学习从目标主机的属性信息到地理位置的映射，而近期的研究^[35,36,94]则引入图神经网络（GNN）来建立目标主机与周边坐标之间的联系。目前，以路由器为中心的基于图的 IP 地理定位方法^[35,94]受到了更多关注，因为它们在 IP 地理定位方面展现出了最先进的性能。

尽管地理定位的准确性有所提高，但现有的基于图的网络实体地理定位系统在实际应用中仍面临关键的信任度问题，这削弱了地理定位系统的重要性，从而阻碍了其在关键应用（例如网络空间治理和互联网犯罪定位）中的部署。本研究的目标是探究基于神经网络的网络实体地理定位系统在可信度方面的两个关键方面——准确性和鲁棒性，并试图回答、解决以下研究问题：

- (1) 如何设计一种新型网络实体地理定位算法，在定位精度方面达到 SOTA？
- (2) 如何确保用户处于边疆、乡村等偏远位置情况下依然保证模型的预测精度？
- (3) 如何为网络实体地理定位系统定义鲁棒性，又通过什么策略提高鲁棒性？

准确性。在提高 IP 地理定位的准确性方面，首先对现有的方法进行了全面分析，研究了它们各自的局限性。通常，基于属性学习的方法^[23,24]将 IP 知识和测量值视为独立的数据，忽略了与 IP 主机地理定位密切相关的有价值结构化信息。基于全局图的方法^[36]虽然有效，但随着主机数量的增加，其计算需求大幅增加，可扩展性较差。基于区域图的方法^[27,35,95]面临路由器级子图中拓扑约束不足的挑战^[96]，仅依赖不准确的相对距离估计，导致预测性能欠佳。此外，路由信息往往难以获取^[35]，使得目标主机难以从相邻节点获取信息。鉴于基于 GNN 的地理定位方法的前沿性能，本研究提出了一种基于区域图的地理定位方法，利用周边主机来丰富目标 IP 的表示。具体而言，本文提出了一种新颖的星型图模型，将目标网络节点表示为中心节点，将共享路由器和地标作为卫星节点。StarGeo 的星型图采用了一种“多管齐下”的技术，同时考虑已知属性和测量数据，同时还能识别 IP 网络中有用的结构。

鲁棒性。提高模型鲁棒性的最主要方法之一是采用对抗学习，这是一种用于增强模型处理对抗样本和适应不同数据分布能力的技术。虽然对抗学习能够增强神经网络对某些类型噪声的抵御能力，但并不能保证在所有情况下都能完全防止噪声的影响。因此，本研究不采用对抗学习来预防所有类型的噪声，而是寻求一种替代且更简便的方法，即让模型能够检测噪声。首先对网络实体地理定位系统所面临的各種不稳定性进行了全面分析，这些不稳定性包括：（1）来自互联网的过时属性知识；（2）由于网络变化导致的不准确测量知识；（3）在农村地区应用地理定位算法时遇到的图稀疏性问题。为了解决这些问题，本研究设计了一种基于深度概率建模的创新算法，该算法考虑了数据的完整性以及 IP 网络连接的动态变化，同时提高了现实世界中网络实体定位服务的可靠性。

总的来说，本研究做出了以下贡献：

（1）提出了 IP Geolocation 模型 Star-Geo，这是一种新颖的网络实体地理定位方法，不仅显著提高了地理定位的准确性，还确保了地理定位模型在面对噪声数据情况时的可靠性。

（2）考虑到边疆、乡村等偏远地区网络节点的稀疏性问题，提出了一种新颖的以目标节点为中心的星型图架构，并严格证明了其合理性和有效性。

（3）深入探究了导致街道级 IP 地理定位系统不稳定的两个关键因素——来自互联网的过时属性知识、由于网络变化导致的不准确测量知识。基于这些发现，提出了一种新颖的深度概率建模算法纳入数据中的不确定性学习，以提高系统的可靠性。

（4）在大规模的真实世界 IP 数据集上对 Star-Geo 进行了全面评估。结果表明，

Star-Geo 显著提高了街道级 IP 地理定位的准确性和鲁棒性, 并且比最先进的基准方法更高效。

3.2 术语及问题定义

IP 地理定位是一种通过目标设备的互联网协议 (IP) 地址来确定其精确地理位置的技术, 从而估算出该设备所在的位置。鉴于算法的通用性, 遵循先前的设置^[35,36], 借助一组已知位置的参考主机 (即地标) 来定义地理定位任务。某些地标被归类为活动地标, 能够主动对其他地标发起网络测量。还有一些地标是被动的 (已知位置), 可由活动地标进行探测。在执行目标定位时, 文献中普遍假设其余目标的位置已知, 因此研究人员可以将它们视为被动地标。

IP 地理定位的目标是利用一组测量数据以及已知其他 IP 主机的位置属性来估算特定 IP 地址的地理位置。通过这一街道级别的 IP 地理定位目标, IP Geolocation 旨在借助测量数据和更广泛 IP 地址集合的地理知识来推断目标 IP 地址的地理位置。

定义 1 (主动/被动地标): 为了初始化系统, 模型需要已知位置的参考主机作为地标。地标有两种类型。主动地标是能够对其他被动地标/目标进行网络测量的参考节点。被动地标自身无法进行测量, 但可以被主动地标探测。

这些已知位置的参考主机为系统提供了一组初始数据, 系统可在此基础上估算目标设备的位置。

定义 2 (网络测量): 在 IP 地理定位系统中使用的网络测量可分为两大类: 互联网延迟测量和路由测量。这些测量数据是通过在不同地理区域战略性部署的活动地标上执行诸如 ping 和 traceroute 之类的探测命令来收集的。

通过这些活跃地标节点向其他地标节点和目标 IP 地址运行探测程序, 可以收集有关互联网不同部分之间延迟和路由的数据。这些测量数据来自已知的活跃地标节点。地标提供了关键输入, 这些输入随后可用于估算目标被动地标的所在位置。

定义 3 (属性知识): 本研究将依照^[35]中的方法, 利用来自 WHOIS 数据库的域名注册数据作为关于 IP 主机的属性知识。具体而言, 可以从 WHOIS 记录中提取诸如 IPv4/IPv6 地址、自治系统 ID 以及国家、州/省和城市级别的地理信息等 IP 地址的相关信息。在本研究中, 使用了与先前研究^[35,94]相同的 14 种不同的属性知识。聚合 WHOIS 数据能够构建一个知识库, 将各种属性与特定的 IP 地址关联起来。尽管 WHOIS 中的位置信息可能不够全面或准确, 但它提供了 IP 地址与地理属性之间的初步关联。然后, 系统可以在 IP 地理定位过程中使用这些基于

WHOIS 的初步关联，WHOIS 知识库为未知 IP 地址的位置估计提供指导。实际上，WHOIS 知识库为将 IP 地址与位置相连接提供了一个起点，之后可以利用其他数据源对其进行完善，因为多样化的 WHOIS 属性信息施加了约束条件，有助于缩小未知 IP 地址的候选位置范围。

应当指出的是，WHOIS 信息可能存在潜在的不准确或过时的情况。此外，在网络拥堵或波动的情况下，诸如 ping 和 traceroute 等网络测量可能会不够精确。然而，考虑到所收集数据中可能存在不准确的情况，因为这反映了现实世界信息中存在的复杂性和不完美性。属性知识和测量中的不确定性本质上起到了内在噪声的作用，这突显了对偶然不确定性进行建模以定量估计和处理这些不准确性的必要性。在本研究中，并非将数据的不确定性视为不利因素，而是将其视为可以通过概率建模解决的固有复杂性。

定义 4 (IP 地理定位): 给定 N 个地标 $\{l_i\}_{i=1}^N$ 其知识 $\{x_i\}_{i=1}^N$ (从互联网中提取)，网络测量值 $\{m_i\}_{i=1}^N$ 和由经度和纬度标记的位置 $\{y_i\}_{i=1}^N$ ，随后通过数据驱动模型确定具有其自身知识 x_T 和网络测量 m_T 值的目标 IP，如公式 3-1:

$$\hat{y}_T = f(\{x_i\}_{i=1}^N, \{m_i\}_{i=1}^N, \{y_i\}_{i=1}^N, x_T, m_T; \Theta) \quad (3-1)$$

其中， $\hat{y}_T = (\widehat{\text{lon}}_T, \widehat{\text{lat}}_T) \in \mathbb{R}^2$ 表示目标 IP 的预测地理位置， Θ 表示所有可学习的参数。即回归模型 f 利用地标 IP 的知识、测量数据以及已知位置，连同目标属性，来估算目标 IP 地址的经度和纬度。

3.3 StarGeo 模型设计

本节将详细阐述所提出的 StarGeo，如图 3-1，主要有三个阶段构成，(1) 首先是星型图构建，构建过程中模型将四个路由器及其附属节点视为卫星节点，将




图 3-1 StarGeo 的总体模型架构

表 3-1 符号及其描述

Symbol	Description
x	输入变量
y	输出变量 (Lat, Lon)
y'	真实标签 (Lat, Lon)
$f(x)$	函数 f 作用于 x
$\mathbf{X}$	矩阵 $\mathbf{X}$
$\mathcal{D}$	集合 $\mathcal{D}$
ϑ	模型参数

目标节点视为中心节点，详见 3.3.1；（2）其次是图学习和深度概率建模，这一阶段模型进行表征学习和不确定性建模，详见 3.3.2 及 3.3.3；（3）最后是模型训练及优化，这一阶段涉及损失函数构建及模型参数优化，详见 3.3.4。StarGeo 是一种综合性的 IP 地理定位方法，能够同时实现准确性和可靠性。具体而言，为使地理定位系统在偏远地区仍保持定位精度，提出一种克服稀疏性的以目标节点为中心的星型图架构，它可以有效地整合来自多源邻近主机的知识，同时避免相对距离估计不准确的弱点。为进一步提高系统在复杂场景下的可靠性，设计一种新颖的偶然不确定性动态图学习算法。本文所用符号总结在表 3-1 中。

3.3.1 多源路由节点星型图

在图神经网络学习过程中，构建拓扑图架构是核心。本研究中，确定目标 IP 属于哪个图是首要挑战，构建 IP 节点图需要回答两个问题：

- (1) 图中任意两个 IP 主机之间是否存在直接或间接的拓扑关联？
- (2) 图中 IP 主机在现实世界中是否彼此靠近？

前者提供了节点之间的结构化信息，这为后续的图分析提供了可行性。后者有助于逐步缩小地理定位范围，并为最终的地理位置识别提供了粗粒度信息。

先前的方法是基于地标与目标 IP 之间的“Ping”响应延迟进行聚类，采用拓扑方法或无监督技术如 k 近邻算法。然而，像通信延迟这样的长距离测量容易受到网络条件波动的影响，从而导致估计不准确且误差范围较大。依照先前的方法^[27]，通过共同的最后一个跃点连接 IP 主机，使用“traceroute”工具探测位于不同城市的主机，并确定最后一个跃点路由器。如果存在多个最后一个跃点路由器，则选择延迟最小（即最可忽略不计）的那个路由器，这是出于双重考虑：（1）由于区域互联网管理策略，共享同一个最后一个跃点路由器的 IP 主机通常物理距离较近^[30]；（2）利用共同的路由器作为桥梁，建立目标 IP 与地标之间的拓扑连接。近期，利用地标节点和目标主机构建图方法^[35,94]受到了关注。这些方法将节点与路由器之间

的通信时间差视为延迟。然而，这种延迟计算方式由于网络时延的波动，导致预测性能欠佳。为解决这一问题，研究者引入了星型图的概念。具体而言，星型图由一个中心星节点和多个卫星节点组成，星节点与所有卫星节点相互连接，便于消息传递。由于普通路由器可以与目标 IP 及其周围地标进行通信，因此将普通路由器指定为星型节点，而将目标 IP 和地标视为卫星节点。然而，尽管这一构图方式提高了地理定位的准确性，却面临边疆、乡村等偏远区域普遍存在带来的节点稀疏性挑战，这限制了图学习的有效性。

在本研究中，提出了一种简单却有效的图节点增强方法来应对上述挑战。具体而言，StarGeo 将目标主机指定为中心节点，并聚合多个最后一跳路由器来构建以目标为中心（Target-centric）的 IP 图，而非像以往研究那样仅依赖于一个具有最小时延的最后一跳路由器。这一简单的修改大幅降低了孤立节点（邻居节点仅有 1 个）的比例，从 9.73% 降至 4.46%，并将稀疏度（邻居节点少于 10 个）从 14.24% 降至 8.64%，从而进一步提高了地理定位的准确性。具体步骤如下：

(1) 构建网络拓扑星型图

与之前的研究不同，他们通过以路由器为中心对 IP 进行聚类来构建网络拓扑，将目标主机制定为中心节点，并聚合利用多个最后一跳路由器构建以目标为中心的 IP 图。值得注意的是，这些路由器的统计数据（及其相连的地标）是由多个战略性部署在不同地区的探测主机通过“traceroute”收集得到的。利用地标节点的地理坐标、主机之间的往返时间（RTT）数据以及公共路由器，可以直接建立网络拓扑连接，其边权重与公共路由器和主机之间的延迟成反比，如公式 3-2：

$$A_{T,*} = \exp(-\gamma \cdot (\alpha \cdot \text{RTT}(*, T) + \beta)) \quad (3-2)$$

其中，* 表示任意卫星节点（地标），T 表示星节点（路由器）， α 、 β 、 γ 是可训练参数。

(2) 构建属性拓扑星型图

假设路由器的地理位置为 $\mathbf{y}_R$ ，根据路由器与其周边节点之间的拓扑结构，依据拓扑测量的约束条件——即目标 $\mathbf{y}_T$ 的地理位置位于以路由器位置 $\mathbf{y}_R$ 为中心、半径为 $d(T, R)$ 的圆上。文献 [35] 中指出，地理位置相近的节点通常具有相似的属性。这一观察结果使得我们能够借助图结构，利用目标 IP 和地标节点的属性知识以及拓扑关系来分析其精确地理位置。

对于每个 IP 图 $G = (X, A)$ ，将节点特征定义为属性知识（从 WHOIS 网站提取的 6 维数据）、网络测量（24 维的 ping 和 traceroute 数据）以及坐标（经度和纬度各 2 维）的组合，总计 32 维。由于已经掌握了目标 IP 和地标节点的属性知识，

所以可以建立节点之间的属性拓扑连接，并采用注意力机制计算属性相似度来动态学习地标和目标节点之间的边权重。

给定目标网络实体“T”和地标“l”的属性知识，通过它们的特征向量的点积来计算它们的相似度，如公式 3-3：

$$A_{T,l} = \exp \left(v^T \sigma (W_1 [x_T, m_T] + W_2 [x_l, m_l] + b) \right) \quad (3-3)$$

其中，“.”是连接操作， σ 表示 sigmoid 函数， $W_1, W_2 \in \mathbb{R}^{(d_x+d_m) \times (d_x+d_m)}$ ， $b, v \in \mathbb{R}^{d_x+d_m}$ 分别是可训练矩阵和向量。因此，公式 (3-3) 通过语义相似性 $A_{T,l}$ 将目标主机与其周围的地标连接起来。

3.3.2 星节点表征学习

对于星型图 $G = (X, A)$ ，每个节点 $v \in X$ 将与一个表示 h_v 相关联，该表示初始化为 $h_v^0 = \{x_v, m_v\} \in \mathbb{R}^{d_x+d_m}$ 。然而，路由器的属性信息缺失。为了初始化这些路由器，对卫星节点的表示应用平均池化。在第 i 次迭代期间，每个 h_v^i 根据节点 v 的邻域信息进行更新，具体方式如公式 3-4：

$$h_v^{(i)} = \text{Update}^{(i)} \left(h_v^{(i-1)}, \text{Agg}^{(i)} \left(h_u^{(i-1)}, A_{u,v} \right) \right) \quad (3-4)$$

其中， $u \in \mathcal{N}_v$ ， $\text{Agg}^{(i)}$ 是一个可训练的函数，将节点表示的集合映射为一个聚合向量， $\text{Update}^{(i)}$ 是另一个可训练的函数，它将节点 v 的当前表示和聚合向量映射到来更新节点 v 的表示。经过公式 (3-4) 两次迭代后，目标网络实体的更新节点表示为公式 3-5：

$$z = \text{Concat} \left(\{h_v^i\}_{i=0}^2 \right) \quad (3-5)$$

其中节点 v 是目标节点。因此，可从三个角度学习目标 IP 的表示：(1) 零阶自信息，(2) 通过属性相似性从邻居获得的一阶聚合信息，以及 (3) 通过测量信息从邻居获得的二阶聚合信息（使用多个公共路由器作为过渡节点）。

至此，通过星型图学习更新了目标网络实体节点的表示。通常，可以将网络实体地理定位任务视为一个确定性的回归任务，此类任务通常通过优化估计值 $\hat{y}$ 与真实值 y 之间的平方误差来构建损失函数。因此理论上，已经更新到了目标实体的潜在表示，只需要通过均方误差（MSE）损失函数优化预测值 $\hat{y}$ 与真实值 y 之间的平方误差均值，再使用解码器多层感知机（MLP）来对这一表示进行解码就可以得到预测结果。然而，这一学习过程没有显式、明确地建模任何潜在噪声或者不确定性。而在现实世界的场景中收集到的时空数据通常是高度稀疏且可能

存在缺失的, 由这些多源信息定义的图结构也自然存在噪音。此外, 由于无法收集到全部时空数据进行训练, 所以大多数训练好的时空图神经网络其实并没有学到完整的现实世界知识。因此, 在下节中, 我们将属性知识不确定性纳入图神经网络以突破这一限制, 实现更稳健和准确的地理定位。

算法 3-1 星型图学习

- 1: 输入: $\{x_i\}_{i=1}^N, \{m_i\}_{i=1}^N, \{y_i\}_{i=1}^N, x_T, m_T$;
- 2: 可训练参数: Θ ;
- 3: 输出: 更新后的目标 IP 表示 z ;
- 4: 从目标 IP 地址获取零阶信息 h_0^v ;
- 5: 通过公共路由器匹配邻居节点;
- 6: 通过公式 (3-2)、(3-3) 计算得邻接矩阵;
- 7: 通过属性相似度从邻居节点获取一阶聚合信息 h_1^v ;
- 8: 通过网络测量信息从邻居节点获取二阶聚合信息 h_2^v ;
- 9: 通过公式 3-5 更新目标 IP 节点的表示。

3.3.3 深度概率建模

加州理工学院计算与数学科学布伦教授阿妮玛·阿南德库马尔 (Anima Anandkumar) 表示: “工程师们会从数学角度测试人工智能系统的稳健性: 即这些人工智能模型在面对所收集数据中的噪声或不完美之处时会如何反应。” 如果要信任这些人工智能模型, 它们就不能脆弱。也就是说, 少量的噪声不应影响其决策。神经网络的不确定性可沿两个轴建模: (1) 数据本身的不确定性, 称为偶然不确定性; (2) 预测中的不确定性, 称为认知不确定性。偶然不确定性反映了观测数据中固有的噪声。例如, 网络的不确定性以及波动会导致即使收集更多数据也无法降低的不确定性。另一方面, 认知不确定性反映了模型参数的不确定性, 可用于描述模型学习内容的置信度。本文提出的地理定位模型由于其属性知识极易过时、网络测量波动大, 故其不确定性主要来自于偶然不确定性。在这种背景下, 本文主要从数据的角度考虑不确定性, 即偶然不确定性。

回到 3.4.3 小节中的星型图学习, 经过基于节点表征学习后, 图中的各个 IP 节点都已通过 `Update()` 函数对其邻居的知识进行了加权聚合并更新了自身表示。然而, 所有表示都无法摆脱网络环境带来的不稳定性。因此, 需要引入随机噪声并构建概率分布来建模数据本身存在的不确定性, 并保持地理位置结果的准确性和鲁棒性。

通常, 网络实体地理定位任务被视为回归任务。因此, 可以假设观测到的结果 y_T 是从一个高斯分布中抽取的独立同分布变量, 而这个高斯分布具有未知的

均值和方差 (μ, σ^2) ，而学习的目标就是要预估这个未知的均值 μ 和方差 σ^2 。为实现该目标，拟通过建模 (μ, σ^2) 的一个先验分布来预估数据的不确定性。受文献启发，假设未知的均值服从一个高斯先验分布，未知的方差 σ^2 符合一个逆伽马 (Inverse-Gamma) 的先验分布，如公式 3-6、3-7：

$$y_T \sim \mathcal{N}(\mu, \sigma^2) \quad (3-6)$$

$$\mu \sim \mathcal{N}(\gamma, \sigma^2 \nu^{-1}), \quad \sigma^2 \sim \Gamma^{-1}(\alpha, \beta) \quad (3-7)$$

其中， $\Gamma(\cdot)$ 是一个伽马函数， $\Gamma^{-1}(\cdot)$ 是一个逆伽马函数，且 $\gamma \in \mathbb{R}^2, \nu > 0, \alpha > 1, \beta > 0$ 。这里的目标是要构建一个关于 μ 和 σ^2 的联合后验分布 $p(\mu, \sigma^2 | y_T)$ ，为得到该后验分布的一个近似形式，假设该分布的参数 μ 和 σ 是相互独立的，则可以将该后验分布分解为公式 3-8：

$$q((\mu, \sigma^2) | y_T) = q(\mu | y_T) q(\sigma^2 | y_T) \quad (3-8)$$

因此，可以采用高斯共轭先验和正态逆伽马分布作为近似，如公式 3-9：

$$p((\mu, \sigma^2) | \Omega) = \frac{\beta^\alpha \nu}{\Gamma(\alpha) \sqrt{2\pi\sigma^2}} \left(\frac{1}{\sigma^2}\right)^{\alpha+1} \exp\left(-\frac{2\beta + \nu(\gamma - \mu)^2}{2\sigma^2}\right) \quad (3-9)$$

其中， $\Omega = \{\gamma, \nu, \alpha, \beta\}$ 。数据不确定性被用来计时空数据中的数据缺失情况、内在噪音等。如上，给定一个正态逆伽马分布，便可以算出时空图神经网络的预测结果、时空图学习模型的偶然不确定性，如公式 3-10：

$$\mathbb{E}[\mu] = \gamma, \quad \mathbb{E}[\sigma^2] = \frac{\beta}{\alpha - 1} \quad (3-10)$$

上述分析被称为证据性分布。在建立了使用证据性分布来解释偶然不确定性和认知不确定性后，接下来的任务是探索如何训练时空图模型以产生上述分布的超参数。拟构建的时空图模型训练过程可被分为两个单独的过程：(1) 通过增加模型获得的证据来支持观测值，(2) 当预测不正确时减少证据（增加不确定性）。不确定学习将过程 (1) 视为时空图模型拟合观测数据的一种方式，而过程 (2) 则被用于强制执行先验以消除错误预测的证据并增加不确定性。下面拟对上述两个过程进行详细的理论推导：

(1) 极大似然拟合

根据贝叶斯概率理论，“模型的证据”或者说是边际似然函数被定义为时空数据观测值 y_T 出现的概率，给定证据性分布的参数 Ω ，上述概率值可通过边际似然函数的参数 (μ, σ^2) 来计算，如公式 3-11：

$$p(y_T|\Omega) = \int_{\sigma^2=0}^{\infty} \int_{\mu=-\infty}^{\infty} p(y_T|\mu, \sigma^2) p(\mu, \sigma^2|\Omega) d\mu d\sigma^2 \quad (3-11)$$

评估模型证据是一项极具挑战性的任务，因为它需要集成模型参数上的潜在依赖。但是，若将一个正态逆伽马的证据性先验分布应用于高斯概率函数时，就可以推导出一个解析解，如公式 3-12：

$$p(y_T|\Omega) = \text{St}\left(y_T; \gamma, \frac{\beta(1+\nu)}{\nu\alpha}, 2\alpha\right) \quad (3-12)$$

其中 $\text{St}(y_T; \mu_{\text{St}}, \sigma_{\text{St}}^2, \nu_{\text{St}})$ 是学生 t 分布在 y_T 处的估计，位置为 μ_{St} ，尺度为 σ_{St}^2 ，自由度数为 ν_{St} 。模型证据的负对数将会被作为训练目标 $\mathcal{L}^{\text{NLL}}$ ，如公式 3-13：

$$\mathcal{L}^{\text{NLL}}(\Theta) = \frac{1}{2} \log\left(\frac{\pi}{\nu}\right) - \alpha \log(\omega) + \log\left(\frac{\Gamma(\alpha)}{\Gamma(\alpha + \frac{1}{2})}\right) + \left(\alpha + \frac{1}{2}\right) \log\left((y_T - \gamma)^2 \nu + \omega\right) \quad (3-13)$$

其中 $\omega = 2\beta(1 + \nu)$ 。该损失项会引导时空图神经网络输出正态逆伽马分布的参数，通过最大化模型证据来拟合时空数据的观测值。

(2) 最小化错误证据

现在应用不正确证据惩罚（即高不确定性先验）来正则化训练，并减少错误预测上的证据。当预测偏离真实值时，正则化项将减少证据权重，而当预测接近真实值时，证据预测几乎不会受到影响或影响很小。为此，构造了一个证据正则化项 $\mathcal{L}^R$ ，其依据预测误差进行缩放，如公式 3-14：

$$\mathcal{L}^R(\Theta) = |y_T - \mathbb{E}[\mu]| \cdot \varphi = |y_T - \gamma| \cdot (2\nu + \alpha) \quad (3-14)$$

该损失项在预测错误时会施加惩罚，并随着推断后验的总证据值变化而缩放。反之，即使预测证据量较大，只要预测接近真实值，该损失项也不会被惩罚（或者受到的影响很小）。

3.3.4 StarGeo 训练与优化

StarGeo 的优化目标由两部分组成：(1) 最小化预测地理位置与真实值之间的损失；(2) 最小化公式 3-13、3-14 中的不确定性损失项，用于最大化和正则化证据，并通过正则化系数 λ 进行缩放，以获得更好的抗噪声能力。Star-Geo 的训练损失可以表示为公式 3-15：

$$\mathcal{L}(\theta) = \mathcal{L}_{\text{mse}}(\hat{y}_T; y_T) + \mathcal{L}^{\text{NLL}}(\theta) + \lambda \mathcal{L}^R(\theta) \quad (3-15)$$

算法 3-2 深度概率建模

- 1: 输入: $z = \text{Concat}(\{h_v^i\}_{i=0}^2)$;
- 2: 可训练参数: Θ ;
- 3: 输出: (μ, σ^2) ;
- 4: 将表示 z 拆分为两部分, 即自信息视角 h_v^0 和图学习视角 $\{h_v^1, h_v^2\}$;
- 5: 设计两个正态逆伽马 (Γ^{-1}) 分布, $\Gamma^{-1}(y_1, v_1, \alpha_1, \beta_1)$ 和 $\Gamma^{-1}(y_2, v_2, \alpha_2, \beta_2)$;
- 6: 通过求和操作生成融合后的 Γ^{-1} 分布 $\Gamma^{-1}(\gamma, v, \alpha, \beta)$;
- 7: 定义证据不确定性损失函数, 该函数包括两种视角损失和融合分布损失;
- 8: 优化模型参数, 直到收敛;
- 9: 获取估计值 $\Omega = \{\gamma, v, \alpha, \beta\}$;
- 10: 通过公式 (3-8)、(3-9) 计算 (μ, σ^2) 。

其中 λ 是一个平衡系数, 用于平衡模型拟合和不确定性的膨胀。当 $\lambda = 0$ 时, 会产生过度自信的预测值, 而太大则会导致不确定性的过高估计 (膨胀)。

通过这项损失函数, 时空图神经网络就能够赋予不确定性感知的能力, 这种不确定性感知的时空图神经网络将 $\mathbf{f}(\theta)$ 作为每个目标样本输出一个 Ω ($\Omega = \{\gamma, v, \alpha, \beta\}$)。其中, 均值 γ 被用来作为目标预测值, 方差 $\frac{\beta}{\alpha-1}$ 将被作为偶然不确定性。现在, StarGeo 通过将星型图学习和数据不确定性感知相结合, 并通过多层感知机 (MLP) 输出目标 IP 的经度和纬度。使用随机梯度下降 (SGD) 和 Adam 优化器来训练模型框架。

3.4 实验验证与分析

为全面评估 StarGeo 模型性能, 本研究在三个大城市——纽约、洛杉矶和上海的真实世界 IP 地理定位数据集上进行了实验。这些数据集分别包含 91,808、92,804 和 126,258 个 IP 地址。与现有研究一样, 本文将数据按 80/20 的比例划分为训练集和测试集。在训练集中, 70% 的 IP 地址被指定为地标, 30% 为测试目标, 遵循常见的方法。在测试阶段, 训练集中的 IP 地址作为地标来定位测试集中保留的其余 IP 地址。本文对这些划分采用交叉验证以减少变异性。这种实验设置使我们能够评估 StarGeo 在大量基准 IP 地理定位数据上的实际性能。数据的详细统计信息以及地标特征见表 3-2。

此外, 本文还分析了地标密度并进行了可视化展示, 即每平方公里面积内的 IP 节点数量, 对这三个城市的 IP 数据库进行了研究, 如表 3-2 及图 3-2。这一特征表明, 在这三个城市中, 洛杉矶的 IP 地标密度最高。相比之下, 上海的地标密度较低, 这可能是由于其地理面积较大所致。这项初步分析量化了各数据库中 IP 地址密度的差异, 洛杉矶的可测量 IP 地标覆盖密度最大。密度的差异凸显了各城市数据的潜在变化性, 这可能会影响地理定位的准确性。

表 3-2 数据统计及其编码维度、方式

数据集属性	纽约	洛杉矶	上海
IP 地址数	91,808	92,804	126,258
路标密度（节点数/平方公里）	116	76	20
探测主机数	4	8	4
节点属性	(6 维)	(6 维)	(27 维)
IPv4 地址	4 维（分类型编码）	4 维（分类型编码）	4 维（分类型编码）
区域自治系统编号	1 维（分类型编码）	1 维（分类型编码）	1 维（分类型编码）
英特网服务提供商	1 维（分类型编码）	1 维（分类型编码）	1 维（分类型编码）
区域自治系统名字	-	-	7 维（独热型编码）
物理地址	-	-	6 维（独热型编码）
组织名	-	-	5 维（独热型编码）
英特网服务商（中国）	-	-	3 维（独热型编码）
网络测量属性	(24 维)	(24 维)	(24 维)
Ping 命令响应时延	4 维（连续型编码）	4 维（连续型编码）	4 维（连续型编码）
Traceroute 步数	4 维（离散型编码）	4 维（离散型编码）	4 维（离散型编码）
最后一跳时延	16 维（连续型编码）	16 维（连续型编码）	16 维（连续型编码）




图 3-2 纽约、洛杉矶和上海地标分布及其区域密度

实验设置与验证指标。本文为纽约和洛杉矶的数据集将学习率配置为 0.002，为上海的数据集配置为 0.001，同时所有三个数据集中保持 δ 值恒定为 0.001。GNN 层（不包括最后一层）的隐藏层大小设置为 32。StarGeo 使用 PyTorch 库实现，并在 GeForce RTX 4060 GPU 上运行。为了全面评估 StarGeo 的性能，本文采用了三个标准评估指标，与之前的研究^[35,94]一致：均方根误差（RMSE）、平均绝对误差（MAE）和中位误差。

3.4.1 基准模型

各基准模型的实现方式和设置如下所述。除非另有说明，否则采用原始论文中建议的设置。

GeoPing^[24]: 利用地理距离与网络延迟之间的相关性, 根据与固定探测点的网络延迟相似度来估算位置。

CBG^[28]: 采用多边测量技术和自校准算法, 动态地将 IP 地址与地理位置相关联, 并使用开源实现进行实验。在实验中使用了开源的 CBG 实现。

TBG^[29]: 基于路由器与地标之间的接近程度, 将拓扑结构和通信延迟转化为用于对路由器和互联网主机进行地理定位的约束条件。

NCRGeo^[95]: 采用拓扑发现来查找最近的公共路由器, 利用基于相对延迟和已知位置的多边测量法来估算目标 IP 的位置。

XLBoost-Geo^[27]: 从网页中提取位置线索以创建地标, 然后估计目标 IP 的位置基于最近的地标, 无需通过网络挖掘获取数据集。

NN-Geo^[34]: 收集往返时间 (RTT), 用于两层神经网络方法, 首先确定大致区域, 然后细化至街道级地理定位。

LightGBM^[97]: 是一个开源的梯度提升框架, 适用于各种机器学习任务, 在这里用于属性探索, 使用的是其公开的代码。为了进行公平的比较, 我们采用了在评估数据集上取得最佳平均绝对误差 (MAE) 的超参数集。

MLP-Geo^[93]: 与 NN-Geo 类似, 但结合了更多路由器信息以对目标进行地理定位。本文根据论文中的设置重现了 MLP-Geo。

TabNet^[98]: TabNet 是一种使用顺序注意力机制进行特征选择的深度学习架构, 本文使用公开代码实现了属性探索。为进行公平比较, 采用在评估数据集上取得最佳 MAE 的超参数集。

GNN-Geo^[36]: 将 IP 地址及其连接转换为图结构, 通过一系列预处理、编码、消息传递和解码操作来映射 IP 位置。

GraphGeo^[35]: 仅考虑目标主机和地标来构建图, 利用延迟差值和连续归一化流, 采用概率图神经网络方法。此外, 它还引入了连续归一化流来呈现概率图神经网络。

RIPGeo^[99]: 侧重于数据质量因素, 将两种对抗训练策略融入多任务中。

TrustGeo^[94]: 通过不确定性感知动态图学习, 在街道级 IP 地理定位方面实现了更高的准确性和可靠性, 并提供了对结果不确定性的评估。

3.4.2 基本性能评估

模型表现分析。表4-2总结了 Star-Geo 和基准的地理定位性能, 从中得出以下观察结果:

(1) 纯基于延迟的方法, 如 GeoPing 和 CBG, 往往效果不佳, 尤其是在街道级

表 3-3 街道级 IP 地理定位的性能比较。最好的结果用粗体表示，第二好的结果用下划线表示。所有结果都以公里（km）为单位进行测量。

Type	Method	Year	New York			Los Angeles			Shanghai		
			RMSE	MAE	Median	RMSE	MAE	Median	RMSE	MAE	Median
Delay Measurement	GeoPing	2001	14.25	11.66	10.24	18.19	13.40	9.450	29.23	24.84	22.23
	CBG	2006	18.74	14.89	11.97	21.05	17.77	13.93	34.60	28.77	24.28
	TBG	2006	16.20	13.15	10.57	17.98	15.60	12.32	27.24	22.53	19.97
	NCRGeo	2018	3.252	2.518	2.110	7.006	5.684	5.012	9.839	6.746	5.240
	XLBoost-Geo	2020	3.005	2.179	1.572	6.820	4.577	4.129	9.990	6.850	5.242
Attribute Learning	NN-Geo	2016	7.740	6.369	5.654	11.19	9.322	8.672	10.25	7.178	5.148
	LightGBM	2017	3.356	2.963	2.827	6.968	5.878	5.119	9.924	6.431	4.898
	MLP-Geo	2020	7.127	5.858	5.077	10.54	8.651	7.567	10.03	7.017	5.107
	TabNet	2021	3.985	3.272	3.198	7.252	6.262	5.189	9.986	6.722	5.012
Graph Learning	GNN-Geo	2021	3.014	2.135	1.618	6.807	4.655	4.039	9.645	6.026	4.482
	GraphGeo	2022	2.681	1.614	1.118	6.621	3.778	2.269	9.051	5.981	3.982
	RIPGeo	2023	2.286	1.328	0.876	5.134	2.887	1.788	8.419	5.554	3.665
	TrustGeo	2023	2.283	1.316	0.888	5.025	2.793	1.786	8.389	5.457	3.619
Ours	StarGeo	–	2.257[↓]	1.302[↓]	0.862[↓]	5.018[↓]	2.748[↓]	1.720[↓]	8.346[↓]	5.413[↓]	3.588[↓]

任务中，因为它们依赖于与理想分布的地标之间的接近程度，而互联网路径的迂回和不规则性使得这种条件难以实现。另一方面，整合路由信息或其他拓扑指标的方法，如 NCRGeo 和 XLBoost-Geo，则表现出更高的有效性。同时，纳入全面的属性信息，如 LightGBM 和 TabNet 所采用的自治系统和 WHOIS 数据，极大地减少了地理定位的不准确性，其表现优于仅依赖往返时间（RTT）和路由器 ID 的模型，如 NN-Geo 和 MLP-Geo。这种丰富属性数据与基于测量的模型的协同作用有效地解决了路由器级图的固有结构局限性，突显了多样化数据整合在提高 IP 地理定位准确性方面的关键作用。

(2) 丰富的属性信息可以显著提高地理定位的准确性。在属性学习方法中，NNGeo 和 MLP-Geo 表现最差，因为它们仅使用 RTT 和路由器 ID 作为特征。LightGBM 和 TabNet 探索更多信息（自治系统 (AS) 和 WHOIS 数据），从而大大减少地理定位错误。这些结果表明，外部属性信息可以帮助基于测量的模型克服路由器级图中结构约束不足的问题。

(3) 包括 StarGeo 在内的基于图学习的方法通常可以实现最佳的地理定位性能。例如，最佳属性学习方法 LightGBM 在纽约市的误差约为 3 公里，但最差的图学习方法 GNN-Geo 可以将距离误差降低到小于 2 公里。这种现象可以用信息熵原理来解释：利用邻居关系有机会丰富有关目标主机的信息，从而在提高地理定位准确性的同时降低预测不确定性。值得注意的是，StarGeo 在相同的 NN 架构设计下，我们的方法优于 TrustGeo，具备了提升 IP 地理定位准确性的能力，StarGeo 的星型 GNN-based 方法可以将纽约数据集中的中值误差降低到 0.866 公里，这是一个

令人鼓舞的结果，验证了构建星型图的动机，即整合更多邻居可以有效缓解图稀疏性问题。

3.4.3 稀疏性分析




图 3-3 稀疏性分析。(a) 邻居数量对预测结果的影响；(b) 从路由器中心图到目标中心图的稀疏性降低。

为更好地分析本文提出的星型图架构，本文首先探究了不同数量的邻居节点对网络实体地理定位性能的影响。如图3-3(a)所示，当邻居数量超过10时，丰富的邻居节点带来的信息增益可以极大程度上缓解图的稀疏性问题，并提升模型的预测精度。具体来看，随着邻居数量的增加，纽约（NY）、洛杉矶（LA）和上海（SH）这三个城市的数据集均表现出显著的MAE（Mean Absolute Error）下降趋势，表明网络实体定位的误差随着邻居信息的增强而降低。此外，不同城市的数据趋势也表明了地理环境和网络结构对定位精度的影响，例如，上海的数据稀疏性较高，因此即使增加邻居数量，其MAE下降幅度仍然受限，而纽约和洛杉矶的MAE下降更为明显。在这种情况下，为了兼顾计算成本和定位性能，本文没有采用以目标节点为中心的IP图构建方式，而是提出了一种混合星型图策略，即对于邻居数量少于10的目标节点，我们使用以目标为中心的星型图架构；而对于邻居节点数量超过10的目标，则继续采用以路由器为中心的星型图架构。这种策略在降低计算复杂度的同时，确保了在高稀疏性情况下的定位精度。

此外，如图3-3(b)所示，进一步分析了不同城市中采用目标中心星型图架构对图稀疏性问题的缓解效果。具体而言，分别统计了在不同数据集中，以路由器中心（RC）和目标中心（TC）为构造方式的图结构的数量分布。可以观察到，在纽约数据集中，目标中心星型图（TC）所占比例较低，仅为2.95%，说明该城市的网络结构较为紧密，不需要额外增强邻居连接。而在洛杉矶和上海数据集中，TC的占比分别达到12.22%和9.86%，表明这些城市的数据更加稀疏，采用目标中心星

型图架构能够有效缓解稀疏性，提高网络实体地理定位的可行性。因此，StarGeo 所提出的星型图混合策略能够动态地调整邻居构造方式，在不同数据稀疏性水平下自适应地优化网络实体定位的精度和计算效率。

3.4.4 消融实验分析




图 3-4 训练时间（损失收敛）和消融实验。

本文分析了所提出的 StarGeo 模型主要模块的时间复杂度，如图 3-4。Star-Geo 的主要计算开销在于三个部分：（1）以目标为中心的星型图构建；（2）星型图表示学习；（3）不确定性学习。星图学习应用图神经网络传递邻居消息并更新节点表示。特别是，构建星型图需要遍历所有邻居，并通过一个图构建函数聚合信息，这需要 $\mathcal{O}(N(d_x + d_m)^2)$ 的时间复杂度。为了更新节点表示，另一个可训练函数（线性层）明确地对聚合信息与原始信息之间的交互进行建模，这会产生 $\mathcal{O}((d_x + d_m)^2)$ 的时间复杂度。最后，直接返回两个可学习变量作为 IP 地理位置的传统确定性方法相比，深度概率建模过程使用一个线性层将节点表示转换为 Ω ，其复杂度为 $\mathcal{O}(5(d_x + d_m))$ 。尽管与先前以路由器为中心的图表示学习相比，以目

标节点为中心的星型图的集成可能会导致训练时间略有增加（参见图3-4），但它为模型的准确性带来的显著提升远远超过了这一微小的代价。

3.4.5 鲁棒性分析




图 3-5 洛杉矶、纽约、上海的数据不确定性估计

为了证实 StarGeo 能够应对网络环境的变化，本文对测量噪声下的不确定性分布进行了可视化，如图 3-5，考虑了由网络抖动和拥塞引起的测量噪声的一般情况。由于先前的研究表明网络路径上的随机抖动大致遵循正态分布，因此使用高斯噪声扰动生成测试集的模拟数据。请注意，此实验的目的并非提出针对潜在波动的防御措施，而是要证明证据模型能够在不稳定的网络场景下准确捕捉到预测不确定性的增加。图3-5显示，即使不添加额外的模拟噪声，不确定性得分在整个区间内也是平滑分布的。如图所示，三个数据集的整体不确定性依次为：纽约 < 洛杉矶 < 上海。上述现象证实，尽管真实世界数据集中存在固有的测量噪声，但证据不确定性学习能够从网络环境中捕捉到此类统计信息。此外，随着噪声水平的提高，噪声样本的不确定性也随之增加，这证实了所提出的方法能够检测网络中的噪声强度，并通过认知不确定性及时做出相应反馈。

3.5 本章小结

在本章节中，本文提出了 StarGeo，它结合了以目标为中心的星型图架构和深度概率建模方法，以同时提高地理定位系统的准确性和鲁棒性。

首先，进一步改进了 IP 图的构建。具体来说，提出了以目标为中心的星型图表示学习框架，它能以更自然的方式纳入 IP 主机的特征信息和邻居关系。星形图由一个星形节点和多个卫星节点组成，其中星形节点与所有卫星节点都有连接，可以向它们传递信息。由于普通路由器可以与目标 IP 及其周围的地标进行通信，因此将普通路由器视为枢纽节点，而将目标 IP 视为中心节点，将已知地理位置的路标 IP 视为卫星节点。

针对网络测量数据搜集过程中存在的噪声干扰现象，StarGeo 实现鲁棒性的核

心是利用对噪声进行深度概率建模将不确定性来源纳入学习过程，并将基于图的 IP 地理定位视为多视角决策融合任务。首先定义用于地理定位的知识主要来自两个方面：目标 IP 本身的信息和来自其邻居的协作信息。然后，计算每个视图的不确定性，并以这些不确定性为标准，自适应地融合来自不同视图的信息。这种方法可以确保地理定位系统在具有噪声干扰的情况下依然有效。

在三个大规模真实 IP 数据集上进行了广泛的实验。结果表明，该系统显著提高了街道级 IP 地理定位的准确性和可靠性，而且比最先进的基线系统更高效。要强调的是，用户可以从本文提出的可信 IP 地理定位系统中获得一些具体的好处：（1）StarGeo 结合了不确定性学习和图神经网络，以提高 IP 地理定位的准确性，获得更精确的位置估计。这对于依赖基于位置的服务的业务（如定向广告、电子商务）具有重大意义；（2）StarGeo 在设计上更能抵御“各种噪音”，这是 IP 地理定位中的一个关键挑战。通过应对这一挑战，本文提出的方法提高了可信度，这对于与网络空间治理、欺诈检测和公共安全相关的应用尤为重要。

第四章 基于信息瓶颈理论的可解释轨迹预测

神经网络天然缺乏可解释性,这主要是由于数据的高维复杂性所致,人类难以理解神经网络如何从众多特征中学习语义联系以进行预测。本文从近期关于人类认知理论的研究中汲取灵感,即人类在记忆中选择性地保留最关键的信息以高效完成任务,设计了一种基于信息瓶颈理论的可解释自我可解释轨迹预测模型,命名为 ExNext。本文提出的 ExNext 包括两个部分,分别是用于预测轨迹的基础模型 Pre-Next 和用于端到端解释的时空学习可解释框架 ST-Explainer。具体地,针对时空数据本身的语义复杂性,为轨迹预测任务提出了包括轨迹流图、全局移动模式发现等机制在内的基础模型 Pre-Next;对于时空学习任务的可解释困境,提出一种新颖的变分信息瓶颈策略(VIB),并将其引入轨迹预测任务提出可解释框架 ST-Explainer,力求在压缩(使表示更简单)和保留相关信息(使表示更丰富)之间取得平衡。VIB 策略能够有效地去除不必要的节点特征和拓扑邻域,同时保留对结果输出最相关的信息。

值得注意的是,ST-Explainer 通过对模型底层核心网络架构进行结构性修改并加入额外的 Kullback-Leibler (KL) 散度损失来实现可解释性,这意味着 ST-Explainer 作为一种模型不可知的算法可以从时空学习的底层网络中解耦。换句话说,ST-Explainer 可被视为一种适用于大多数时空学习任务的通用性可解释框架。为便于展示理论性,本文结合时空学习中常见的人群移动轨迹预测任务进行理论推导,并进行充分的实验验证与分析,严格证明了 ST-Explainer 框架的准确性和可解释效果。本文所提出的 ST-Explainer 框架能够在不改动模型架构的前提下,为模型生成简洁解释的同时通过强化关键特征、压缩冗余表示提高其预测精度。

4.1 可解释轨迹预测

随着社交网络服务(Social Network Service, SNS)的普及,微信、微博、小红书等带有地理标签的社交媒体的迅速发展,使众多用户能够发布有趣的地方、报告日常活动以及结交志同道合的朋友,从而积累了大量的上下文数据(例如签到记录)。这些平台汇集了大量的地理标记社交媒体数据,这些数据封装了用户的活动轨迹(例如,带有地理定位的签到等),丰富的地理空间数据为兴趣点推荐开辟了新的可能性。这反过来又为探索人类丰富多样的生活体验(例如移动模式)提供了前所未有的机会,并促进了各种以用户为中心的下游应用的发展,如轨迹识别^[100]、兴趣点推荐/预测^[40]、行程预测^[101]等等。作为挖掘签到数据的一项基

本任务，预测人类移动性（通常表现为下一个兴趣点的预测/推荐）对于研究人员和从业者探索人类签到背后的信息语义和相互作用至关重要^[102]。例如，它能够精准地确定用户的未来意图，并为新业务吸引更多的潜在客户。时空签到序列（即轨迹）反映了人类在一系列兴趣点（POI）上的日常活动，其中可能包含某些（周期性）规律。人类移动性预测领域的大多数开创性工作旨在对人类的连续行为进行建模时考虑时空偏好。例如，为了预测某个用户在不久的将来会去何处，传统的诸如马尔可夫链^[103,104]和基于张量分解的方法^[105,106]等依赖数据驱动范式的方法，试图纳入个人的访问偏好并探索连续模式。然而，这些方法严重依赖于手工设计的特征，并且在理解海量人类轨迹所蕴含的丰富语义方面面临挑战，这反过来又导致在揭示用户历史签到中隐含的交互提示/信号方面存在局限。

早期的兴趣点推荐工作依赖于使用特征工程和传统机器学习方法预测未来的行为，例如基于马尔可夫链的随机模型和矩阵分解方法。尽管取得了进展，但这些方法仍面临着兴趣点语义复杂性带来的挑战。最近的研究转向了先进的深度学习技术，诸如循环神经网络（RNN）之类的深度学习技术在从人类轨迹中学习有价值的签到信息方面取得了令人鼓舞的成果，并已成为解决各种移动性学习任务的广泛流行的方法^[39,40,107,108]。例如，Wu 等人^[41]提出了 PLSPL 模型，该模型利用长短期记忆（LSTM）神经网络来建模人类的短期序列偏好，同时通过注意力机制学习人类历史签到背后兴趣点的上下文特征。为了考虑下一个兴趣点推荐的空间和时间影响，Kong 等人将连续签到之间的空间和时间间隔纳入循环隐藏状态，以缓解人类轨迹的数据稀疏性。由于模型效率更高，并且能够量化给定轨迹中每个签到的贡献，因此出现了诸如自注意力和时空 Transformer 等几种注意力机制来处理长的人类历史轨迹^[109,110]。这些方法旨在使用机制从历史签入中提取见解以辨别时空关联关系，同时更准确地推断用户意图。

尽管在建模用户偏好和估计下一个兴趣点方面取得了进展，但主流技术在实践中面临着核心的可信度问题——准确性和可解释性，示例见图 4-1。这削弱了推荐系统在实际应用中的意义，并阻碍了其在智能城市规划和犯罪预测等关键应用的部署。虽然之前的一些研究转向提高推荐系统的可解释性，但这些方法只提供了对结果的事后解释，或者只是基于注意力分数的粗略解释。这种与神经网络解耦的事后解释是有偏见的，并且歪曲了真实的解释，进一步阻碍了推荐系统的可靠性和适用性。因此，为值得信赖的兴趣点推荐建立通用的、事前的、自我解释的框架仍然是一个亟待解决的研究空白。

为了解决上述局限性，本研究专注于在兴趣点推荐系统中实现可信度的两个关键方面——准确性和可解释性，并提出了一种用于下一个兴趣点推荐的事前自




图 4-1 POI 推荐示例，模型基于历史轨迹预测其下一个想去的地点，但却无法告知用户为何有这样的决策结果。

解释框架，命名为 ExNext。与以往的后验可解释学习不同，ExNext 以事前可解释的方式共同学习预测和解释预测结果，即在训练过程中学习到预测结果的解释，而不是现有研究中普遍使用的事后解释方法。具体来说，ExNext 通过信息瓶颈理论的视角，通过学习一种紧凑的表示来赋予推荐系统的可解释性，其目标是在知识压缩（产生简洁的解释）和保留相关信息（提供深刻的表示）之间实现平衡。更进一步地，ExNext 的目标是通过对骨干网进行战略性的架构修改和加入额外的 Kullback-Leibler (KL) 散度损失来实现的。这意味着 ST-Explainer 可以从推荐学习的底层骨干网络中解耦，从而使其能够发挥深远的影响。总之，本文贡献可以总结如下：

- (1) 引入了一种新颖的变分信息瓶颈策略，旨在实现知识压缩（提供简洁的解释）和保留相关信息（提供信息丰富的表示）之间的平衡。
- (2) 提出了一个通用且有效的人类移动学习模型 ExNext，它以事前的方式共同学习预测和解释推荐（即在训练过程中学习解释，而不是当今流行使用的事后可解释性方法）。
- (3) ExNext 中的 ST-Explainer 框架与模型解耦，具有易于优化且稳定的易处理的变分优化上下限。将轨迹预测基础模型 Pre-Next 插入 ST-Explainer 框架就足以提高其性能。
- (4) 在三个真实世界的数据集上进行了大量实验，以评估所提出的 ExNext 的性能。实验结果表明，ExNext 优于最先进的方法，可以有效提高准确率，剔除不必要的 POI（历史签到记录）和特征，保留最相关的 POI 和特征。

4.2 术语及问题定义

定义 3.1 (集合) : 本文定义用户集合为 $U = \{u_1, u_2, \dots, u_M\}$, 兴趣点集合为 $P = \{p_1, p_2, \dots, p_N\}$ (例如特定的餐厅、酒店), 时间戳集合为 $T = \{t_1, t_2, \dots, t_K\}$, 其中 M, N, K 均为正整数。

定义 3.2 (兴趣点, Point of Interest) : 兴趣点 $p \in P$, 由一个四元组 (纬度, 经度, 类别, 签到频率) 表示, 分别对应纬度、经度、类别和签到频率。特别是, 类别 cat 取自一个固定的兴趣点类别列表 (例如, “火车站”、“酒店”)。

定义 3.3 (签到, Check-ins) : 签到是一个三元组 $(u, p, t) \in U \times P \times T$, 表示用户 u 在时间戳 t 访问了兴趣点 p 。用户 u 创建的所有签到序列形成一个签到序列 $Q_u = (q_u^1, q_u^2, q_u^3, \dots)$, 其中 q_u^i 是第 i 次签到记录。将所有用户的签到序列定义为 $Q = \{Q_u1, Q_u2, Q_u3, \dots\}$ 。

定义 3.4 (下一个兴趣点推荐, Next POI Recommendation) : 下一个兴趣点推荐是通过学习当前轨迹以及用户所有历史签到记录, 为用户推荐一份其接下来可能访问的兴趣点列表。更正式地说, 给定一组用户历史轨迹 $\mathcal{S}_u^{\text{ien}, \text{new}}$ 以及特定用户 $u_i \in U$ 的当前轨迹 $\mathcal{S}' = (q_1, q_2, \dots, q_m)$, 预测该用户接下来最有可能访问的未来兴趣点 $(g_{m+1}, g_{m+2}, \dots, g_{m+k})$, 其中 k 是一个小于等于 1 的整数 (通常 $k = 1$)。

4.3 ExNext 模型设计

图4-2展示了 ExNext 模型的整体设计。ExNext 融合了几个关键组件, 首先, 构建了一个用于 POI 预测的 Transformer 基础模型, Pre-Next, 它包括一个通用性的 transformer 编码器, 以及用于发现全局移动模式的轨迹流图和上下文轨迹嵌入器。轨迹流图通过神经网络 (GNN) 在轨迹流图上进行训练, 以生成兴趣点 (POI) 嵌入, 这些嵌入编码了用户在每个兴趣点的一般移动模式, 同时结合了兴趣点的类




图 4-2 ExNext 的总体模型架构

别、位置和签到频率。然后，定义了上下文嵌入模块来获取用户嵌入、POI 类别嵌入以及时间编码，并将用户嵌入向量与相应轨迹中的兴趣点嵌入向量相结合，以实现更好的个性化服务。兴趣点类别嵌入和时间编码也被结合起来，以捕捉用户对不同兴趣点类别在不同时间段的偏好（例如，高峰时段的火车站）。轨迹流图使我们能够通过统一签到记录中的用户、POI 类别、时间戳和 POI 信息来生成单个签到嵌入向量。然后，每条轨迹都可以编码为这样的签到嵌入向量列表。接下来，采用一个 Transformer 编码器和多层感知机（MLP）头来生成 POI 预测，并通过残差连接利用学习到的转移注意力图对预测的 POI 进行调整。至此，实现了简单的 POI 预测，然而这一黑盒预测模型带来的可解释困境给用户造成不信任挑战。因此，本文将变分信息瓶颈理论引入 ExNext，并对其进行结构性的改善，它对历史轨迹进行压缩以学习到质量更高、冗余性更少的表示，这一可解释框架本文将其称为 ST-Explainer，如图4-2所示。它主要由概率 $p=0.5$ 的预定义先验分布、模型学习的后验分布和约束这两项一致的 KL 散度构成。

4.3.1 时空轨迹流图

本文注意到，不同的个体可能共享某些相似的轨迹片段，而同一个人也可能多次重复相同的轨迹。为了利用历史签到记录中的这些共同模式，构建了一个轨迹流图，以提供用户在兴趣点之间通用移动的全局视图。给定历史轨迹集 $\mathcal{S}_u^{\text{ien}, \text{new}}$ ，轨迹流图是一个带权有向图 $G = (V, E, \ell, w)$ ，满足以下条件：

节点的集合为 $V = P$ ，即兴趣点的集合。对于集合 P 中的每个点 p ，其属性 $\ell(p)$ 包含（纬度、经度、类别、出现次数），其中（纬度、经度）是点的坐标，类别是点的类别，出现次数是点在集合 $\mathcal{S}$ 中的轨迹中出现的次数。如果轨迹 $\mathcal{S}$ 中出现 $(p_1, p_2, \dots)$ ，即 p_1 和 p_2 是连续访问的，则从 p_1 到 p_2 存在一条边。任何边 (p_1, p_2) 的权重 $w(p_1, p_2)$ 等于 $T(p_2)$ 在 $\mathcal{S}$ 中任何轨迹中出现的次数。

除了表明用户在兴趣点之间的移动情况外，轨迹流图还隐含地揭示了某些兴趣点之间的空间邻近性。其直观原因是，如果两个兴趣点相距较远，用户连续在它们之间签到的可能性就较小。

给定轨迹图 G ，下一步是学习一个向量化的 POI 表示，该表示能够编码常见的 POI 迁移模式以及 POI 的属性。为此，本文利用图卷积网络（GCN）。为了充分利用 G 的拓扑信息，我们使用谱 GCN。具体来说，设 $A \in \mathbb{R}^{N \times N}$ 表示 G 的邻接矩阵，首先计算归一化拉普拉斯矩阵，如公式 4-1：

$$\tilde{L} = (D + I_N)^{-1}(A + I_N) \quad (4-1)$$

其中, D 为度矩阵, I_N 为图 G 的单位矩阵。接下来, 设 $H^{(0)} = X \in \mathbb{R}^{N \times c}$ 为输入节点特征矩阵, 可定义 GCN 层之间的传播规则为公式 4-2:

$$H^{(l)} = \sigma(\tilde{L}H^{(l-1)}W^{(l)} + b^{(l)}) \quad (4-2)$$

其中, $H^{(l-1)}$ 表示第 l 层的输入信号 (对于任意 $l > 0$), $W^{(l)} \in \mathbb{R}^{c \times \Omega}$ 表示第 l 层的模型权重矩阵, 相应的偏差 $b^{(l)} \in \mathbb{R}^{\Omega}$, 而 σ 是用于非线性的带泄漏率 0.2 的泄漏型 ReLU 激活函数。

从空间角度来看, 在每次迭代中, GCN 层通过将节点自身的嵌入与其邻域信息聚合在一起, 来更新节点的嵌入。本研究堆叠 t^* 层 GCN 以增强模型的表达能力。在最后一层之前使用了随机失活 (Dropout)。GCN 模块的输出可以表示为公式 4-3:

$$e_p = \tilde{L}H^{(t^*)}W^{(t^*)} + b^{(t^*)} \in \mathbb{R}^{N \times \Omega} \quad (4-3)$$

最后, 兴趣点 p_i 的嵌入 e_{p_i} 是 $N \times \Omega$ 矩阵 e_p 的第 i 行。粗略地说, 兴趣点 p 的嵌入表明了 p 在所有用户历史轨迹中的位置, 从而捕捉到了 p 处的一般移动模式。它将被送到下游的 Transformer 中, 以对用户的访问行为进行建模。注意到, 尽管当前优化较缓, 兴趣点嵌入仍然为预测模型提供了丰富的信息。

4.3.2 移动模式发现

从图 G 学习到的 POI 嵌入仅隐式地捕获了通用的移动模式。为了放大集体信号的影响, Pre-Next 应用了一种转换注意力图, 以显式地建模从一个 POI 到另一个 POI 的转换概率。如上所述, 这些转换概率将用于调整最终预测。给定输入节点特征和 G , 计算注意力图 Φ 如公式 4-4、4-5、4-6:

$$\Phi_1 = (X \times W_1) \times a_1 \in \mathbb{R}^{N \times 1} \quad (4-4)$$

$$\Phi_2 = (X \times W_2) \times a_2 \in \mathbb{R}^{N \times 1} \quad (4-5)$$

$$\Phi = (\Phi_1 \times 1^T + 1 \times \Phi_2^T) \odot (\tilde{L} + I_N) \in \mathbb{R}^{N \times N} \quad (4-6)$$

其中, $W_1, W_2 \in \mathbb{R}^{c \times h}$ 是两个可训练的特征变换矩阵; $a_1, a_2 \in \mathbb{R}^h$ 是两个可学习的向量。通过广播操作构建一个 $N \times N$ 的注意力矩阵; 1 是一个形状为 $\mathbb{R}^{N \times 1}$ 的全 1 向量; I_N 是单位矩阵。 $\odot$ 表示逐元素乘法。对归一化拉普拉斯矩阵的范围从 $[0, 1]$ 迁移至 $[1, 2]$ 进行平移, 以避免出现零值。

转换注意力图的第 i 行表示从兴趣点 p_i 移动到每个兴趣点 s (未归一化的) 概率。给定当前轨迹中的最后一个兴趣点, 查找存储在 Φ 对应行的转换概率, 并使用这些概率来调整由后续 Transformer 模块生成的推荐结果。

4.3.3 时空上下文嵌入

时空背景和用户偏好是个性化下一个兴趣点 (POI) 推荐的关键因素。接下来, 本文将介绍用于融合包括用户嵌入、兴趣点嵌入、兴趣点类别嵌入和时间编码在内的背景信息的上下文嵌入模块。

POI-用户嵌入融合. POI 嵌入是从轨迹流图中学习得到的, 忽略了特定用户的模式。为了捕捉特定用户 u 的一般行为, 训练一个嵌入层; 将每个用户投影到一个低维向量。每个用户的嵌入是从其历史签到序列中学习得到的。形式上, 用户 u 的嵌入为:

$$e_u = f_{\text{embed}}(u) \in \mathbb{R}^{\Omega} \quad (4-7)$$

为了构建每个签到活动的表示, 一个直接的解决方案是将兴趣点嵌入和用户嵌入进行拼接。将拼接后的向量输入到一个全连接层中, 以嵌入融合后的嵌入并增强其表示能力。输出可以表示为公式 4-8:

$$e_{p,u} = \sigma(W_{p,u}[e_p; e_u] + b_{p,u}) \in \mathbb{R}^{\Omega \times 2} \quad (4-8)$$

其中, $W_{p,u}$ 和 $b_{p,u}$ 分别是权重向量和偏差; $[:]$ 表示拼接。输出嵌入的维度是 POI 嵌入与用户嵌入的两倍。换句话说, 融合后嵌入向量的大小保持不变。

时间类别嵌入融合. 用户的访问行为自然具有时间依赖性。例如, “火车站”在早晚高峰时段 (约 8 点和 18 点) 有两个明显的高峰。相反, “酒吧”则呈现出截然相反的模式, 其大部分签到活动发生在 18 点之后。这些观察结果促使研究者考虑兴趣点类别的时间模式, 以用于下一个兴趣点的推荐。例如, 在 8 点时推荐火车站而非酒吧。

值得注意的是, 单个兴趣点的签到也可能呈现出某些时间模式。然而, 由于签到数据的稀疏性和数据中的噪声, 单个 POI 的时间模式远不如类别清晰和稳定。以纽约市的数据集为例, 该数据集包含 22.7 万条签到记录、3.8 万个 POI 和 400 个类别。平均而言, 每个 POI 只有不到 6 次签到。相比之下, 每个类别的签到次数超过 570 次。因此, 本文探索 POI 类别的时间模式, 而非单个 POI 的时间模式。

与 POI-用户嵌入融合模块类似, 首先对 POI 类别和时间进行编码。时间嵌入采用 **time2vector**, 这是一种先进的时间编码模型。具体来说, 将一天中的 24 小时

划分为 48 个时间窗，每个时间窗为 30 分钟。本文将一个（标量）时间值映射到其中一个时间窗。时间窗的嵌入，记为 $\mathbf{e}_t$ ，是一个长度为 $k+1$ 的向量。第 i 个元素定义为公式 4-9：

$$e_t[i] = \begin{cases} \omega i t + \phi_i, & \text{if } i = 0, \\ \sin(\omega i t + \phi_i), & \text{if } 1 \leq i \leq k. \end{cases} \quad (4-9)$$

其中， ω 和 ϕ 是可学习的参数，且使用正弦激活函数来捕捉周期性模式，Pre-Next 为兴趣点类别采用了另一个嵌入层，类别 c 的嵌入为公式 4-10：

$$\mathbf{e}_c = f_{\text{embed}}(c) \in \mathbb{R}^{\Psi} \quad (4-10)$$

其中 Ψ 是嵌入维度。接下来，通过一个全连接层将时间嵌入 $\mathbf{e}_t$ 和类别嵌入 $\mathbf{e}_c$ 融合，形成一个单一的分类-时间表示为公式 4-11：

$$\mathbf{e}_{c,t} = \sigma(w_{c,t}[\mathbf{e}_t; \mathbf{e}_c] + b_{c,t}) \in \mathbb{R}^{\Psi \times 2} \quad (4-11)$$

其中， $w_{c,t}$ 是一个可学习的权重向量，而 $b_{c,t}$ 是偏差。

最后，签到 $q = \langle p, u, t \rangle$ （其中兴趣点 p 属于类别 c ）的嵌入是 $\mathbf{e}_q = [\mathbf{e}_{p,u}; \mathbf{e}_{c,t}]$ 的拼接。因此，每个输入轨迹 $(q_1, q_2, \dots, q_s)$ 都由签到列表表示。随后将嵌入向量 $(\mathbf{e}_{q_1}, \dots, \mathbf{e}_{q_s})$ 传递给 Transformer 编码器。

4.3.4 Pre-Next 优化目标

Pre-Next 采用 Transformer 模型来进行下一个兴趣点的推荐；因为这是一个自然的序列预测任务。由于目标是仅根据签到序列预测下一个紧邻的兴趣点，所以 Pre-Next 仅采用 Transformer 编码器，并在其后接入多个多层感知机（MLP）头（不使用 Transformer 解码器）。对于编码器，堆叠了几个带有位置编码的标准 Transformer 编码器层。每个层都由一个多头自注意力模块后接一个位置全连接网络组成，残差连接和归一化同时应用于这两个模块。

形式上，给定输入轨迹 $S_u = (q_u^1, q_u^2, \dots, q_u^k)$ ，要预测下一次签到活动中的兴趣点 q_u^{k+1} ，Pre-Next 首先获取每个历史签到 q_u^i ($1 \leq i \leq k$) 的签到嵌入，如 4.2 节所定义。然后将这些签到嵌入堆叠起来，形成第一层编码器的输入张量，可表示为 $X^{[0]} \in \mathbb{R}^{k \times d}$ ，其中 d 表示每个签到记录的嵌入维度。特别地， d 等于 $\mathbf{e}_q$ 的长度，即 $d = 2 \times (\Omega + \Psi)$ 。值得注意的是，所有编码器层的嵌入长度 d 保持不变，以方便残差连接和层归一化。换句话说，忽略填充，编码层 l 的输出形状与输入形状一致，即 $X^{[l+1]} \in \mathbb{R}^{k \times d}$ 。

对于层自注意力模块，输入 $X^{[l]} \in \mathbb{R}^{k \times d}$ 首先经过一个多头自注意力模块转换（在本文实验中，头的数量为 2）。对于第一个注意力头，输出为：

$$S = X^{[l]} W_q \left(X^{[l]} W_k \right)^T \in \mathbb{R}^{k \times k} \quad (4-12)$$

$$S'_{ij} = \frac{\exp(s_{ij})}{\sum_{j=1}^k \exp(s_{ij})} \quad (4-13)$$

$$\text{head}_1 = S' X^{[l]} W_v \in \mathbb{R}^{k \times d/h} \quad (4-14)$$

其中， $W_q \in \mathbb{R}^{k \times d/h}$ ， $W_k \in \mathbb{R}^{k \times d/h}$ 和 $W_v \in \mathbb{R}^{k \times d/h}$ 分别是与“查询”、“键”和“值”相对应的可学习权重矩阵。这里忽略方程中的偏置项。点积注意力，即 S'_{ij} 表示第 i 次和第 j 次签到活动之间的相关性。接下来，应用 softmax 函数以确保注意力权重之和为 1。通过 W_v 将输入数据投影到输出特征空间后，使用学习到的注意力矩阵来调整每个签到记录的贡献。最后，将不同的注意力头堆叠起来，并使用另一个线性变换 $W_o \in \mathbb{R}^{k \times d}$ 来合并来自不同注意力空间的表示：

$$\text{Multihead}(X^{[l]}) = [\text{head}_1; \dots; \text{head}_h] \times W_o \in \mathbb{R}^{k \times d} \quad (4-15)$$

此外，层归一化和残差连接应用于注意力模块。因此，注意力模块的最终输出可以表示为公式 4-16：

$$X_{\text{attn}}^{[l]} = \text{LayerNorm} \left(X^{[l]} + \text{Multihead}(X^{[l]}) \right) \quad (4-16)$$

在每个编码器层中，注意力模型之后都连接了一个全连接（FC）网络。设多头注意力的输出为 $X_{\text{attn}}^{[l]}$ 。FC 网络可以表示为公式 4-17：

$$X_{\text{FC}}^{[l]} = \text{ReLU} \left(W_1 X_{\text{attn}}^{[l]} + b_1 \right) W_2 + b_2 \in \mathbb{R}^{k \times d} \quad (4-17)$$

其中 W_1, W_2 是可训练的权重矩阵， b_1, b_2 是偏差。同样地，第 l 层编码器的输出为公式 4-18：

$$X^{[l+1]} = \text{LayerNorm} \left(X_{\text{attn}}^{[l]} + X_{\text{FC}}^{[l]} \right) \in \mathbb{R}^{k \times d} \quad (4-18)$$

Pre-Next 利用 Transformer 编码器层将输入轨迹签到嵌入中的有用信息提炼到特征空间中。为了预测用户的下一步行动，Pre-Next 将 Transformer 解码器替换为多个多层感知机（MLP）解码器。具体而言，采用三个 MLP 头分别预测下一个兴趣点（POI）、访问时间和 POI 类别。设编码器的输出为 $X^{[l]*}$ ，则 MLP 头分别可以表示

为公式 4-19、4-20 及 4-21:

$$\hat{Y}_{poi} = X^{[l]*} W_{poi} + b_{poi} \quad (4-19)$$

$$\hat{Y}_{time} = X^{[l]*} W_{time} + b_{time} \quad (4-20)$$

$$\hat{Y}_{cat} = X^{[l]*} W_{cat} + b_{cat} \quad (4-21)$$

其中 $W_{poi} \in \mathbb{R}^{d \times N}$, $W_{time} \in \mathbb{R}^{d \times 1}$, $W_{cat} \in \mathbb{R}^{d \times \Gamma}$ 是在 MLP 中的权重, “ Γ ” 代表类别的个数。对于 POI 注意力头 $\hat{Y}$ 的输出 $\hat{Y}_{poi} \in \mathbb{R}^{d \times N}$, Pre-Next 只关注最后一行, 对应于未来移动的 POI 预测。此外, 将此预测结果与第 4.3.2 节中定义的迁渡注意力图相结合。最终的预测结果如公式 4-22:

$$\hat{Y}_{poi} = \hat{Y}_{poi}^{(k)} + \Phi^{(p_k)} \in \mathbb{R}^{1 \times N} \quad (4-22)$$

其中, $\hat{Y}_{poi}^{(k)}$ 表示 $\hat{Y}_{poi}$ 的第 k 行, 而 $\Phi^{(p_k)}$ 是迁渡注意力图 Φ 的第 p_k 行, p_k 表示签到记录 q_u^k 所对应的兴趣点。

除了 POI 注意力头之外, Pre-Next 还添加了时间注意力头和类别注意力头。所以在预测兴趣点的同时预测下一个签到时间, 主要原因如下: 两次签到之间的时间间隔波动很大 (例如, 从半小时到长达 6 小时不等)。这是合理的, 因为用户在不同兴趣点停留的时间长短不一, 或者忘记记录某些签到。然而, 这种波动对预测有相关性影响。实际上, 用户在下午 5 点时, 对于接下 1 小时和接下来 5 小时的推荐应有特定期望。因此, Pre-Next 不仅推荐下一个兴趣点, 还推荐下一个签到时间, 并使用时间头来校准时间建模。此外, 类别头用于调节下一个兴趣点的预测, 因为预测下一个兴趣点的类别比精准预测兴趣点要容易。

损失函数构建过程中, 解码器中的所有多层感知机 (MLP) 头都纳入训练考虑范围, 其中时间和类别头的输出作为正则化项。换句话说, Pre-Next 计算所有 MLP 头损失的加权和, 交叉熵用于兴趣点自身及其类别预测的损失函数, 均方误差 (MSE) 用于时间预测的性能评估。

此外, 由于 Pre-Next 将一天 24 小时归一化到了 $[0, 1]$ 区间, 因此时间损失的量级明显小于其他两项。为了平衡时间损失与其他损失项的梯度大小, 将时间损失放大了 10 倍, 则最终的损失为公式 4-23:

$$\mathcal{L}_{pre} = \mathcal{L}_{poi} + 10 \times \mathcal{L}_{time} + \mathcal{L}_{cat} \quad (4-23)$$

至此, Pre-Next 通过轨迹流图与 Transformer 机制构建了 Pre-Next 实现了 POI

预测，但由于深度学习模型的天然黑盒特性，Pre-Next 的决策过程对用户而言是不透明的，这一限制给模型在关键领域的应用带来了不信任困境。因此，在下一章节中，本文将着重介绍一种基于信息瓶颈理论的可解释时空框架——ST-Explainer。

4.4 ST-Explainer 框架设计

4.4.1 信息熵约束

在 ST-Explainer 框架中，信息熵约束是实现时空数据可解释性的核心理论基础之一。信息熵作为衡量随机变量不确定性的指标，能够帮助模型量化时空数据中的信息量，并通过信息瓶颈理论提取出最相关的子序列和特征。信息熵是信息论的核心概念，香农信息论提出“信息的本质是消除不确定性”，并将信息熵定义为随机变量不确定性的指标。对于离散随机变量 $\mathbf{X}$ ，其信息熵定义为公式 4-24：

$$H(X) = - \sum_{x \in \mathcal{X}} P(x) \log P(x) \quad (4-24)$$

其中 $P(x)$ 是随机变量 $\mathbf{X}$ 取值为 x 的概率。信息熵越大，表示随机变量的不确定性越高。在时空数据分析中，轨迹数据通常包含大量的不确定性，例如用户移动模式的随机性、环境变化的不可预测性等。通过信息熵，模型可以度量这些不确定性，并识别出对任务最相关的部分。

通过信息熵可以衡量一个随机变量所包含的信息量，而要衡量两个随机变量间相关性则需要引入互信息。互信息 $I(X; Y)$ 是衡量两个随机变量 $\mathbf{X}$ 和 $\mathbf{Y}$ 之间相关性的指标，定义为公式 4-25：

$$I(X; Y) = H(X) - H(X|Y) \quad (4-25)$$

其中 $H(X|Y)$ 是在已知 Y 的条件下 X 的条件熵。互信息越大，表示 X 和 Y 之间的相关性越强。在 ST-Explainer 框架中，互信息被用于衡量子轨迹 T_{IB} 与任务标签 $\mathbf{Y}$ 之间的相关性，以及子轨迹 T_{IB} 与输入轨迹 T 之间的冗余信息。

4.4.2 变分上下限推断

ST-Explainer 实现可解释性的关键在于学习一条时空子轨迹及其稀疏特征矩阵。该过程能有效剔除不必要的历史足迹和冗余属性，仅保留最相关的时空轨迹子序列和关键特征。根据信息瓶颈理论，对于时空轨迹及其标签 $\mathbf{Y}$ ，由信息瓶颈找到的最优子序列 T_{IB} 表示为公式 4-26：

$$T_{IB}^* = \arg \min_{T_{IB}} -I(T_{IB}; Y) + \beta I(T_{IB}; T) \quad (4-26)$$

其中 T_{IB} 为与任务相关的特征集。根据式 4-26，最小化 T_{IB} 等同于最大化第一项互信息 $I(T_{IB}; Y)$ ，同时最小化第二项互信息 $I(T_{IB}; T)$ 。然而直接估计这两项互信息由于其高阶计算复杂性在实际操作中存在困难。为解决这一问题，本文采用变分推断对公式 (4-26) 进行优化。接下来将推导如何优化这两个目标。

最大化第一项互信息 $I(T_{IB}; Y)$ 等价于找到该互信息的变分下限，将 $I(T_{IB}; Y)$ 完整展开有公式 4-27：

$$I(T_{IB}; Y) = \int Q(Y, T_{IB}) \log \frac{Q(Y, T_{IB})}{Q(Y)Q(T_{IB})} dY dT_{IB} \quad (4-27)$$

其中 $Q(Y|T_{IB})$ 由模型和马尔可夫链定义如下：

$$I(T_{IB}; Y) \geq \int Q(Y, T_{IB}) \log \frac{Q(Y|T_{IB})}{Q(Y)} dY dT_{IB} \quad (4-28)$$

由于 $Q(T_{IB}|T)$ 和 $Q(T_{IB})$ 的复杂性，无法直接估计 $Q(Y|T_{IB})$ 。依据文献 [111] 中的方法，用先验分布 $P(T_{IB}|T)$ 变分近似真实的后验概率 $Q(T_{IB}|T)$ 。利用 Kullback-Leibler 散度总是非负这一事实，有公式 4-28：

$$KL(Q(Y|T_{IB}), P(Y|T_{IB})) \geq 0 \quad (4-29)$$

其中 $P(Y|T_{IB})$ 代表给定 T_{IB} 时 Y 的任意分布。因此：

$$I(T_{IB}; Y) \geq \int Q(T_{IB}; Y) \log P(Y|T_{IB}) dY dT_{IB} + H(Y) \quad (4-30)$$

其中 $H(Y)$ 是 Y 的常数，故不纳入模型计算。表达式 $\log P(Y|T_{IB})$ 代表 $Q(Y|T_{IB})$ 的变分近似，可以使神经网络在端到端框架内进行建模。具体来说， $\log P(Y|T_{IB})$ 旨在通过子轨迹 T_{IB} 预测结果。它与模型输入数据的潜在表示学习最终预测结果具有相同的学习参数分布，通常可以根据特定时空预测任务使用不同的损失函数（例如在上文提出的用于网络实体定位的均方误差 $\mathcal{L}_{MSE}$ ，及用于轨迹预测的交叉熵损失 $\mathcal{L}_{CE}$ ）来代替这一项互信息约束。

现在，考虑第二项 $I(T_{IB}; T)$ 的变分上限，如公式 4-31：

$$I(T_{IB}; T) = \int Q(T_{IB}; T) \log \frac{Q(T_{IB}|T)}{Q(T_{IB})} dT dT_{IB} \quad (4-31)$$

由式 (4-29) 可知 $KL(Q(T_{IB}|T), P(T_{IB})) \geq 0$ 成立，有：

$$\int Q(T_{IB}) \log Q(T_{IB}) dT_{IB} \geq \int Q(T_{IB}) \log P(T_{IB}) dT_{IB} \quad (4-32)$$

因此得到公式 4-33 中的变分上限：

$$I(T_{IB}; T) \leq \int Q(T_{IB}, T) \log \frac{Q(T_{IB}|T)}{P_2(T_{IB})} dT dT_{IB} \quad (4-33)$$

其中 $P(T_{IB})$ 是 $Q(T_{IB})$ 边缘分布的变分近似。现在可以使用模型 $P_\theta(T_{IB}|T)$ 来估计 $Q(T_{IB}|T)$ ，那么 $I(T_{IB}; T)$ 的最小化可以通过降低 KL 散度损失来优化，如公式 4-34：

$$\min I(T_{IB}; T) := \min \mathcal{L}_{KL}(P_\theta(T_{IB}), P(T_{IB})) \quad (4-34)$$

其中将 $P(T_{IB})$ 初始化为伯努利分布，其概率参数 $P = 0.5$ 。这表明历史时空轨迹之间的联系被保留或预测的可能性在初始阶段是均等的。因此，根据公式 4-33，可以将损失函数定义为：

$$\mathcal{L}_{IB} = \frac{1}{N} \sum_{i=1}^N \left[- \int Q(T_{IB}|T_i) \log P(Y_i|T_{IB}) dT_{IB} + \beta \int Q(T_{IB}|T_i) \log \frac{Q(T_{IB})}{P(T_{IB})} dT_{IB} \right] \quad (4-35)$$

其中 $P(Y_i|T_{IB})$ 是后验分布 $Q(Y_i|T_{IB})$ 的变分近似，而 $P(T_{IB})$ 是先验分布 $Q(T_{IB})$ 的变分近似。因此，只需 $KL(Q(T_{IB}), P(T_{IB}))$ 逼近于 0，便可实现 $I(T_{IB}; T)$ 最小化。可以将 ST-Explainer 总损失视为在任务准确性约束下的精度损失与最小化 KL 散度损失之和：

$$\mathcal{L}_{total} = \mathcal{L}_{task}(Y, P_\theta(\hat{Y}|T_{IB})) + \beta \mathcal{L}_{KL}(Q(T_{IB}|T), P(T_{IB})) \quad (4-36)$$

值得注意的是，这里设计了拉格朗日算子用于平衡特征压缩与模型预测。

尽管用于训练神经网络的分析训练目标（公式 4-36）已得到充分验证，但定义现实世界数据的先验分布 $P(T_{IB})$ 颇具挑战性。为应对这一挑战，受信息瓶颈理论的启发，不相关的特征和结构均都有在有害信息，ST-Explainer 将生成过滤为特征选择和结构学习。对于给定的轨迹 T ，可将其分解为序列 Seq 和特征 X ，二者的信息压缩过程是相互独立的，因此最小化 $I(T_{IB}; T)$ 等价于联合最小化 $I(Seq_{IB}; Seq)$ 和 $I(X_{IB}; X)$ 。相应的，公式 4-36 中的 $\mathcal{L}_{KL}(Q(T_{IB}|T), P(T_{IB}))$ 可以分解为两部分： $\mathcal{L}_{KL}(Q(Seq_{IB}|Seq), P(Seq_{IB})) + \mathcal{L}_{KL}(Q(X_{IB}|X), P(X_{IB}))$ 。

4.4.3 时空高维特征可解释

时空数据特征类型存在高度异构性——这些特征是从互联网上收集（处理）的，因此可能同时包含离散特征和连续特征，部分特征以连续型编码方式进行编码，而部分特征以离散型方式进行编码。现有的信息瓶颈理论实现方法假设节点特征的先验分布为高斯分布，无法满足模型的需求。为解决这一问题，本文提供了一种替代的优化目标，通过变分逼近来实现可压缩性。具体来说，本文设计了

一种特征分离掩码方案来离散地删除与下游任务无关的特征，其公式为：

$$X_{IB} = \{X_i \odot M_X, i = 1, \dots, |X|\} \quad (4-37)$$

其中 $M_X \in \mathbb{R}^{d_X}$ 是一个可学习的二进制特征矩阵。 $\odot$ 表示哈达玛积。现在需要证明为何 X 与 M 间的互信息可以作为 X 与 X_{IB} 的变分上界。证明如下：

从马尔可夫链 $X - (X, M) - X_{IB}$ 中，可得出： $I(X; X_{IB}) \leq I(X; X, M)$ ，根据互信息的链式法则^[112]，有公式 3-38：

$$I(X; X, M) = I(X; M) + I(X; X|M) \quad (4-38)$$

其中 $I(X; X|M)$ 进一步可写为公式 4-39：

$$I(X; X|M) = H(X|M) + H(X|M) - H(X, M) \quad (4-39)$$

鉴于条件化永远不会增加熵^[112]，有 $H(X|M) \leq H(X)$ 。因此，公式 4-38 可以改写为：

$$I(X; X|M) \leq H(X) \quad (4-40)$$

其中熵 $H(X)$ 是一个常数。将式 (4-40) 代入式 (4-39)，得到公式 4-41：

$$I(X; X_I) \leq I(X; M) + C \quad (4-41)$$

基于此，可以得出推论如下：

推论 1: 通过信息论的互信息计算公式，可推断： $I(X; X_{IB}) \leq I(X; M) + C$ ，其中 C 是一个常数。

根据这一推论，可得到一个关于 $I(X; X_{IB})$ 的替代优化目标，即最小化公式 4-42：

$$\mathcal{L}_{KL}(Q(M_{IB}|M), P(M_X)), \quad (4-42)$$

ST-Explainer 将 $P(M_X)$ 设为先验伯努利分布，其概率参数设为 0.5，表示节点之间的连接被保留或被预测的可能性相等。对于 $Q(M|X)$ ，ST-Explainer 将所有掩码矩阵建模为一组相互独立的伯努利随机变量，这些随机变量由学习到的注意力权重 $\pi \in \mathbb{R}^d$ 参数重整化：

$$M_X = \cup_{i \in \{1, \dots, d\}} \{M_{X,i} \sim \text{Ber}(\pi_i)\} \quad (4-43)$$

其中 π 是一个可训练的向量。二进制特征掩码从伯努利分布 $\text{Ber}(\pi)$ 中采样得到。

4.4.4 时空序列结构可解释

为了从原始序列 T 中提取有影响力的子序列结构 Seq_{IB} , ST-Explainer 在实例化网络中加入随机性。具体地, 通过使用最基础的编码器来嵌入时空序列 T , 这个过程中生成时空节点表示, 如公式 4-44:

$$H^{(s)} = \{h_i^{(s)}\} \in \mathbb{R}^{d_s}. \quad (4-44)$$

接下来, ST-Explainer 使用连接操作符 $\parallel$ 和参数为 θ 的 MLP F_θ 来编码时空边表示。这一编码步骤定义如公式 4-45:

$$\hat{h}_{uv} = F_\theta(\hat{h}_u \parallel \hat{h}_v), \quad s.t., u \in N(v) \quad (4-45)$$

其中, $N(v)$ 表示节点 v 的邻居集合 $\mathcal{N}$ 。之后, ST-Explainer 使用 *Tumble-Softmax* 对学习到的注意力模型参数重整化技巧来计算每个边的时空概率 ρ_{uv} , $\rho \in \mathbb{R}^{N \times N}$, 从而以可微的方式进行:

$$\rho_{uv} = \sigma \left(\frac{\hat{h}_{uv} + g}{\tau} \right) \quad (4-46)$$

其中, g 是从 $Tumble(0,1)$ 分布中抽取的一组 i.i.d. 样本, τ 是控制结果分布平滑性的温度参数。ST-Explainer 将所有可能的连接建模为一组相互独立的伯努利随机变量, 通过概率形式呈现时空轨迹点 (u, v) 间相关性程度, 如公式 4-47:

$$M_{seq} = \bigcup_{u,v \in \mathcal{E}} \{M_{seq,u,v} \sim \text{Ber}(\rho_{uv})\} \quad (4-47)$$

对于每一对时空轨迹点, ST-Explainer 结合表征学习优化连接采样概率 ρ_{uv} 。较小的 ρ_{uv} 表示记录 (u, v) 之间的连接更容易是噪声, 应赋予较小的权重甚至丢弃。基于此, 特征选择过程类似, ST-Explainer 采用连接掩码方案, 以离散方式舍弃对下游任务无关的历史轨迹, 获得了时空可解释子图结构 Seq_{IB} , 如公式 4-48:

$$Seq_{IB} = Seq_{u,v} \odot M_{seq} \quad (4-48)$$

其中, 符号 $\odot$ 表示元素级乘积。

在实际应用中, 往往会遇到从伯努利分布中采样的问题, 由于该分布的离散性使得模型训练过程不可微。为解决这一问题, 我们采用针对离散分布优化的连续松弛方法来近似采样过程。此外, 在应用连续松弛法之后, 所得到的序列变成了加权全连接序列, 这在计算上代价高昂。因此, ST-Explainer 通过对小于非负阈值 ($\eta = 0.5$) 的元素进行掩码处理, 得到对称稀疏邻接矩阵。

4.5 ExNext 训练及优化

在 ST-Explainer 理论框架中, 推导得出只需要使 $\text{KL}(\mathbb{Q}(T_{IB}|T), \mathbb{P}(T_{IB}))$ 逼近于 0。也就是说模型通过从输入数据 T 中学习后验分布 $\mathbb{Q}(T_{IB}|T)$, 并使其逐渐接近预先定义的先验分布 $\mathbb{P}(T_{IB})$, 便可实现 $I(T_{IB}; T)$ 最小化。而对于第一项 $I(T_{IB}; Y)$ 的最大化, ST-Explainer 将其视为与模型从输入数据的潜在表示中学习最优预测结果具有相同的可学习参数分布, 故可以根据特定的空间预测任务使用不同的损失函数。

为了推断下游标签 Y , 使用可解释子轨迹 T_{IB} , ST-Explainer 根据特定时空预测任务使用不同的损失函数。例如, 在预测人群未来的移动轨迹时, 使用基于注意力机制的交叉熵 (Cross-Entropy) 损失, 见公式 4-23。ExNext 框架的优化目标是最小化二者的联合训练目标, 如公式 4-49:

$$\mathcal{L}_{total} = \mathcal{L}_{pre}(Y, \mathbb{P}_{\theta}(\hat{Y}|T_{IB})) + \beta \text{KL}(\mathbb{Q}(T_{IB}|T), \mathbb{P}(T_{IB})) \quad (4-49)$$

通过时空特征可解释和时空序列结构可解释的学习, 最终得到目标掩码矩阵 M_X 和 M_{seq} , 将此掩码矩阵与公式 4-18 得到的注意力权重矩阵 $A_{\text{attn}}^{(l)}$ 做哈德曼乘积采样得到经过信息瓶颈筛选的注意力权重矩阵。这个矩阵保留了对预测结果起重要作用的关键节点, 过滤掉了冗余的不关键节点。

至此, ExNext 通过变分信息瓶颈理论实现了模型输出结果的可解释性。实现可解释性后, 我们将得到的注意力权重矩阵用于时空学习模型中传递信息并更新预测目标特征。

4.6 实验验证与分析

4.6.1 数据集及实验设置

表 4-1 数据集统计

城市/地区	用户	兴趣点	签到记录	轨迹	短轨迹	长轨迹
纽约 (NYC)	1,075	5,099	104,074	14,160	3,504	1,618
东京 (TY)	2,281	7,844	361,430	44,315	15,306	6,671
加利福尼亚 (CA)	4,318	9,923	250,780	32,920	10,467	4,892

数据集统计。本文在从基于位置的服务平台 FourSquare 和 Towalla 收集的三个公开数据集上进行实验: FourSquare-NYC, FourSquare-TKY 和 Towalla-CA。FourSquare-NYC 数据集于 2012 年 4 月至 2013 年 2 月期间在纽约市收集, FourSquare-TKY 数据集则是在同一时期从东京收集的。Towalla-CA 数据集包含 2009 年 2 月至 2010 年 10 月期间在加利福尼亚州和内华达州的签到记录, 这些数

据来自 Towalla。每条记录包含用户、兴趣点 (POI)、POI 类别、TPS 坐标和时间戳。对于这三个数据集,本文排除了签到记录少于 10 次的不受欢迎的 POI,同时也过滤掉了签到历史少于 10 次的用户。接下来,将每个用户的完整签到序列按照 24 小时的间隔拆分为轨迹。在极少数情况下,轨迹中仅包含一次签到;这些情况从数据集中剔除。然后按照时间顺序将数据集划分为训练集/验证集/测试集。前 80% 的签到记录作为训练集,用于构建轨迹流图 G ,中间 10% 作为验证集,剩余 10% 构成测试集。如果用户或兴趣点未出现在训练集中,但在测试集中出现,那么在衡量预测性能时,跳过该用户或兴趣点。数据集的关键统计信息如表 4-1 所示。

实验设置。ExNext 将学习率设为 $1e^{-4}$,同时所有数据集中将 β 超参数保持在 $1e^{-2}$ 。在训练过程中应用了学习率衰减策略以防止过拟合。对于 Transformer,ExNext 堆叠了两个编码器层,训练过程中的批处理大小设置为 64。所有签到特征的嵌入维度从 {32, 64, 128, 256} 中搜索得到,并且使用了四个注意力头。基线模型的其他参数遵循原始论文中的推荐设置。

评估指标。为全面评估 ExNext 的性能,采用了两个标准评估指标,与先前的研究保持一致:Top- k 准确率 ($\text{Acc}@k$, $k = 1, 5, 10$) 和平均倒数排名 (MRR)。这两个指标在下一个兴趣点推荐任务中被广泛使用。 $\text{Acc}@k$ 表示真实兴趣点出现在 Top- k 预测兴趣点中的比率。由于准确率 $\text{Acc}@k$ 将前 k 个推荐视为无序列表,而忽略了正确预测的排序,因此采用了 MRR。它衡量的是在有序结果列表中正确推荐的兴趣点索引。对于包含 m 个样本 (轨迹) 的数据集,定义如公式 4-50 及 4-51:

$$\text{Acc}@k = \frac{1}{m} \sum_{i=1}^m 1(\text{rank} \leq k) \quad (4-50)$$

$$\text{MRR} = \frac{1}{m} \sum_{i=1}^m \frac{1}{\text{rank}} \quad (4-51)$$

其中 1 是指示函数。如果条件成立则返回 1,否则返回 0。Rank 表示推荐有序列表中真实下一个兴趣点的次序。通常来说,对于提及的这些指标,值越大性能越好。

4.6.2 基准模型

本文将 ExNext 与以下 11 个基线模型进行比较:

(1) MF^[105] 是许多推荐问题中的经典方法。它通过矩阵分解来学习用户和兴趣点 (POI) 的潜在表示。

(2) FPMC^[103] 将矩阵分解与马尔可夫链相结合,以同时对用户的长期偏好和序列行为进行建模。

(3) 长短期记忆网络 (LSTM)^[113] 是循环神经网络 (RNN) 模型的一种变

体，能够同时处理短期和长期的序列模式。

(4) PRME^[114] 提出了一种名为个性化排序度量嵌入的成对嵌入方法，用于捕捉用户偏好以及兴趣点之间的序列转换。

(5) ST-RNN^[39] 除了采用 RNN 捕获用户的序列模式外，还采用了时间、距离转移矩阵来建模局部的时间和空间上下文。

(6) STGN^[40] 在传统的长短期记忆网络 (LSTM) 基础上进行了扩展，通过添加空间门和时间门来捕捉用户在空间和时间维度上的偏好。

(7) STGCN^[40] 是 STTN 的更新版本，它采用了耦合的输入门和遗忘门。

(8) PLSPL^[41] 通过注意力机制学习用户的长期偏好，并利用长短期记忆网络 (LSTM) 学习短期偏好，然后通过个性化线性层将两者结合起来。

(9) STAN^[115] 利用轨迹中签到的时空信息以及自注意力层来捕捉非相邻签到之间的点对点交互。

(10) GETNext^[109] 是一种 Transformer 模型，结合轨迹概率图来增强预测。

(11) STHGCN^[110] 开发了利用超图卷积网络 (Hyper-GCN) 的超图 Transformer 层来建模用户行为。

4.6.3 基本性能评估

表 4-2 兴趣点推荐的性能比较，其中最佳性能以粗体显示。

Method	Year	NYC				TKY				CA			
		ACC@1	ACC@5	ACC@10	MRR	ACC@1	ACC@5	ACC@10	MRR	ACC@1	ACC@5	ACC@10	MRR
MF	2009	0.0368	0.0961	0.1522	0.0672	0.0241	0.0701	0.1267	0.4861	0.0110	0.0442	0.0723	0.0342
FPMC	2010	0.1003	0.2126	0.2970	0.1701	0.0814	0.2045	0.2746	0.1344	0.0383	0.0702	0.1159	0.0911
LSTM	2014	0.1305	0.2719	0.3283	0.1857	0.1335	0.2728	0.3277	0.1834	0.0665	0.1306	0.1784	0.1201
PRME	2015	0.1159	0.2236	0.3105	0.1712	0.1052	0.2278	0.2944	0.1786	0.0521	0.1034	0.1425	0.1002
ST-RNN	2016	0.1483	0.2923	0.3622	0.2198	0.1409	0.3022	0.3577	0.2212	0.0799	0.1423	0.1940	0.1429
STGN	2020	0.1716	0.3381	0.4122	0.2598	0.1689	0.3391	0.3848	0.2422	0.0810	0.1842	0.2579	0.1675
STGCN	2020	0.1799	0.3425	0.4279	0.2788	0.1716	0.3453	0.3927	0.2504	0.0961	0.2097	0.2613	0.1712
PLSPL	2020	0.1917	0.3678	0.4523	0.2806	0.1889	0.3523	0.4150	0.2542	0.1072	0.2278	0.2995	0.1847
STAN	2021	0.2231	0.4582	0.5734	0.3253	0.1963	0.3798	0.4464	0.2852	0.1104	0.2348	0.3018	0.1869
GETNext	2022	0.2435	0.5089	<u>0.6143</u>	0.3621	0.2254	0.4417	0.5287	0.3262	0.1357	0.2852	0.3590	0.2103
STHGCN	2023	<u>0.2625</u>	<u>0.5226</u>	0.6117	<u>0.3798</u>	<u>0.2905</u>	<u>0.5184</u>	<u>0.5969</u>	<u>0.3951</u>	<u>0.1652</u>	<u>0.3405</u>	<u>0.4177</u>	<u>0.2491</u>
Ours	-	0.2694↑	0.5449↑	0.6213↑	0.3908↑	0.2962↑	0.5219↑	0.5971↑	0.3997↑	0.1658↑	0.3478↑	0.4173↑	0.2503↑

整体性能。表 4-2 总结了兴趣点推荐的整体性能比较结果。为确保公平性，本文报告了 10 次运行的平均结果，并对最佳性能结果进行了加粗。以下是实验观察和分析：

(1). 方法对比分析。在相同的神经网络结构下，ExNext 在所有数据集上均表现出色，明显优于现有的 STHGCN 及其他经典兴趣点推荐方法。尤其是在 ACC@1、ACC@5 和 MRR 指标上，ExNext 均取得了最佳结果。这表明，通过结合信息瓶颈理论，ExNext 能够有效去除冗余信息，保留最关键信息，从而提高推荐质量。此

外, ExNext 能够更好地适应不同类型的轨迹, 特别是在长轨迹推荐任务中表现尤为突出。这证实了我们的初始假设, 即消除与任务无关的信息能够有效解决冗余性问题, 从而提升推荐性能。

(2). 数据集对比分析。进一步分析 NYC、TKY 和 CA 数据集的结果, 我们发现 ExNext 在 NYC 和 TKY 数据集上比 CA 数据集取得了更显著的性能提升。这主要是由于 NYC 和 TKY 中的兴趣点 (POIs) 比 CA 更具冗余性, 其兴趣点密度分别为 4.199、3.575 和 0.024。由于 CA 数据集的 POI 分布较为稀疏, 用户的签到行为相对较少, 信息瓶颈的效果不如在 NYC 和 TKY 数据集上明显。然而, 即便在 CA 数据集上, ExNext 仍然取得了最优结果, 说明 ExNext 仍然能够在低密度场景下提取最关键的信息, 提高推荐精度。这些改进也与最初的假设相符, 即 ExNext 可以通过减少冗余来提高准确性。我们可以通过信息论中的香农第三定理来解释这一点, 该定理指出, 通过确定每个符号在信道上传输所需的最小比特数 (ExNext 中的 T_{IB}), 可以在接收端近似重建源 (标签 Y), 且不会超过失真阈值。

(3). 信息瓶颈的作用。ExNext 通过信息瓶颈理论进行特征提取, 能够有效过滤掉无关特征, 仅保留最具预测价值的信息。特别是在 NYC 和 TKY 数据集上, 我们观察到 ExNext 在 MRR 指标上的提升最为明显, 这表明信息瓶颈不仅能够提高预测精度, 还能更好地对兴趣点的重要性进行建模, 从而提升模型的可解释性。

(4). 与最优基线的对比。ExNext 在所有数据集上的整体性能均优于 STHGCN, 这表明 ExNext 能够更有效地建模兴趣点的关联性, 并利用信息瓶颈理论进行信息筛选, 从而提升推荐的精度和鲁棒性。特别是在 NYC 和 TKY 数据集上, 我们观察到 ExNext 在 ACC@1 和 MRR 指标上显著超越 STHGCN, 说明其在冷启动场景下也具备更强的泛化能力。

综上所述, 实验结果验证了 ExNext 结合信息瓶颈理论在兴趣点推荐任务中的有效性。ExNext 不仅在整体推荐精度上领先, 而且能够更好地适应不同轨迹长度和数据密度场景, 使得推荐结果更加准确和可解释。

4.6.4 结构及特征可解释

可解释性分析。图 4-3 展示了不同 β 值对模型可解释性的影响。 β 作为控制参数, 决定了模型在信息压缩过程中的松紧程度, 进而影响模型的可解释性。随着 β 值的增大, ExNext 在生成可解释结果时, 会更倾向于保留信息贡献度较高的签到记录和特征, 而逐渐去除信息贡献度较低的部分。这种趋势在图 4-3 (a)-(c) 和 (d)-(f) 的对比中可以清晰地观察到。具体而言:

(1) 当 $\beta = 10^{-3}$ (图 4-3 (a), (d)), 信息压缩较少, 用户签到记录的子序列仍然较




图 4-3 可解释结果。ExNext 会根据更高的 β 值生成更简洁、更中肯的解释。

图中展示了具有四十个兴趣点的签到记录经过信息压缩后的子序列和特征。

长，许多签到点被保留下来，同时特征重要性分析结果显示多个维度的贡献度较为均衡。这种设置可能导致模型在解释时包含较多冗余信息，增加了解释的复杂度。

(2) 当 $\beta = 10^{-2}$ (图 4-3 (b), (e))，模型的可解释性得到优化，一些低贡献度的签到记录和特征被去除，仅保留信息贡献度较高的部分，使得模型的输出更加清晰，解释更加直观。

(3) 当 $\beta = 10^{-1}$ (图 4-3 (c), (f))，信息压缩达到较高水平，模型保留的签到记录和特征较少，仅包含核心信息。这种情况下，模型的可解释性最强，但过度的信息压缩可能导致丢失部分关键信息，从而影响模型的泛化能力。

总的来说， β 作为可解释性控制参数，能够调节模型在信息压缩和可解释性之间的权衡。随着 β 的增加，只有最重要的签到记录和特征（大于非负阈值 $\eta=0.5$ ）会被保留下来。较小 β 值 (10^{-3}) 会保留更多签到点和特征，适用于数据分析和深入解释，但可能包含冗余信息。较大 β 值 (10^{-1}) 更倾向于信息压缩，仅保留核心信息，有助于去除冗余信息，使解释更具概括性，适用于模型决策透明化和用户可视化分析，但可能丢失部分关键信息。适当调节 β 可以在可解释性和信息保留之间找到平衡，使模型解释更加符合实际需求，有助于开发人员和用户更清晰地理解模型是如何得出其推荐结果的。因此，ExNext 可以通过拉格朗日乘数 β 来微调信息压缩的程度。也就是说，通过调整 β ，可以控制模型的可解释性，使其更符合不同应用场景的需求。

4.6.5 冷启动性能评估

表 4-3 冷启动表现（纽约数据集）

轨迹类型	模型	ACC@1	ACC@5	ACC@10	MRR
短轨迹	STHGCN	0.2489	0.4823	0.5632	0.3541
中轨迹	STHGCN	0.2684	0.5307	0.6120	0.3849
长轨迹	STHGCN	0.2835	0.5514	0.6679	0.4077
短轨迹	Ours	0.2501	0.4858	0.5637	0.3666
中轨迹	Ours	0.2704	0.5403	0.6141	0.3862
长轨迹	Ours	0.2866	0.6345	0.6717	0.4118

为有效评估 ExNext 的冷启动性能，本文在测试集中按轨迹长度重新排序，区分了短轨迹、中轨迹和长轨迹。针对短轨迹的预测是下一个 POI 推荐中的另一个挑战。短轨迹中信息的缺乏反映在其有限的时空背景中，尤其是当轨迹中已知的签到次数仅为一两次时。本文根据数据集动态定义短轨迹，具体而言，按长度对测试集中的轨迹进行排序，并将前 15% 标记为长轨迹，将后 15% 标记为短轨迹。表4-3显示了 ExNext 和 STHGCN 在 NYC 数据集的三个轨迹组上的表现。ExNext 在短轨迹和长轨迹的推荐性能上没有表现出显著差异。例如，短轨迹和长轨迹的 top-1 准确率分别为 25.06% 和 28.66%，短轨迹的 top-10 准确率为 56.37%。值得注意的是，ExNext 在短、中、长轨迹组中的性能均优于基线模型，这表明 ExNext 具有从轨迹中消除无关信息、提升表示质量的强大能力。

4.6.6 复杂度及敏感性分析

计算复杂性分析。图4-4(a)展示了 ExNext 以及两种表示模型的训练时间。与两种图增强模型相比，集成可解释性框架后的后的时间效率更高。然而，这与最初的假设不同，即源于具体松弛的加权全连接序列在计算上会很昂贵。这可以通过 ExNext 掩码来解释，它会屏蔽小于非负阈值 ($\eta = 0.5$) 的元素。显著的效率提升超过了计算复杂度略有增加这一微不足道的代价。

拉格朗日算子权衡预测与压缩。首先通过控制拉格朗日算子 β 对模型平衡准确性和信息压缩的影响。如图4-4(b)显示，随着 β 数值的变化，推荐性能总体上保持稳定。起初，随着 β 的增加，信息被压缩得更紧凑，准确率略有提升。然而，当压缩过度时，与任务相关的信息被消除，准确率随之下降。这种“驼峰”现象可以用香农信息论中的核心观点来解释，即“信息的本质是消除不确定性”，当大部分无关信息被去除后，继续进行信息压缩会减少与预测结果密切相关的关键信息，从而降低准确率。ExNext 的性能优势意味着神经网络架构可以通过学习更有效、




图 4-4 三个数据集上的计算复杂度和参数敏感度。(a) ExNext 与之前研究工作的训练时间比较。(b) ExNext 在指标 $ACC@1$ 的 β 值变化范围从 10^{-5} 到 10^{-1} 和 0 (即去除掉 ST-Explainer 框架)。

更合适的特征掩码来提高表示质量。

4.7 本章小结

在本章中, 本文提出了一种新颖的先验、自我可解释和灵活的人类移动学习框架——ExNext, 用于解决下一兴趣点推荐 (Next POI Recommendation) 任务。该方法的核心思想是利用信息瓶颈理论 (Information Bottleneck, IB) 来同时提升模型的可解释性和准确性, 并减少签到数据和特征表示中的冗余和噪声。

首先, 为了提高模型的可解释性, ExNext 通过构造变分信息瓶颈 (Variational Information Bottleneck, VIB) 对签到记录进行特征选择和压缩。本文采用了一种基于掩码矩阵的学习机制, 使得模型能够自动识别最具信息量的签到记录, 并有效去除无关或冗余数据。特别地, ExNext 通过可学习的拉格朗日乘数 β 来控制信息瓶颈的约束程度, 从而在信息保留与信息压缩之间实现动态平衡。这一机制不仅能够增强模型对签到数据的理解能力, 还能提升其对用户移动模式的建模能力, 从而生成更具可解释性的推荐结果。

其次, 为了提高推荐的准确性, ExNext 在保持预测性能的同时, 减少了由于噪声和冗余信息带来的干扰。ExNext 通过构造变分后验分布, 使模型能够自适应地调整签到记录的权重, 从而优化兴趣点的推荐策略。此外, ExNext 还结合了时空关系建模, 使得模型能够更精准地刻画用户的移动行为模式。实验结果表明, ExNext 在多个公开数据集上均取得了最佳性能, 并在 $ACC@1$ 、 $ACC@5$ 、 $ACC@10$ 和 MRR 指标上显著超越现有方法。

在实验部分, 本文详细分析了 ExNext 在不同数据集 (NYC、TKY 和 CA) 上

的表现，并重点探讨了信息瓶颈理论在 POI 推荐任务中的作用。研究表明，ExNext 在高密度数据集（如 NYC 和 TKY）上的提升尤为显著，表明信息瓶颈能够有效去除冗余签到记录，从而提高推荐精度。此外，在短轨迹推荐任务中，ExNext 同样表现出色，这验证了其在复杂移动轨迹建模中的适应性和鲁棒性。

综上所述，ExNext 在轨迹预测任务中展现了显著的优势。通过引入信息瓶颈理论，ExNext 不仅能够在保持高准确率的同时提高可解释性，还能够通过拉格朗日乘数实现信息压缩的动态调节。实验结果验证了 ExNext 在不同轨迹长度和数据密度场景下的有效性，表明其在推荐系统中的广泛应用潜力。下一章，我们将进一步探讨基于 ExNext 进行可信可解释时空预测系统设计与实现，并结合现实应用场景对其进行优化和扩展。

第五章 可信可解释时空预测系统设计与实现

在第三章中,本文专注于可信网络实体地理定位的研究,设计了一种基于星型图和不确定性感知的地理定位模型-StarGeo,该模型能通过用户的IP地址挖掘出其实际地理信息,并在多个公开数据集中取得较好的表现。在第四章中,为解决现有轨迹预测模型面临的 用户不信任 挑战,本文引入了信息论中的信息瓶颈理论,设计并实现了一种在准确预测人群移动轨迹的同时,还能够对本次预测给出解释的架构-ExNext,有利于增强模型决策过程的透明性,使之在关键领域如智慧城市规划、犯罪预测中能够真正适用。本章在第三章和第四章工作的基础上,对可信可解释时空表征模型的应用进行了设计,并致力于构建和实现可信可解释时空预测系统。该系统具有实时定位、用户移动性偏好预测、数据可视化等功能,同时,利用可信可解释时空预测系统,在用户端可增强其信任度,在社交平台服务端可助力其精准投放用户偏好,在城市规划甚至公共安全部门也可以助其更好地完成城市管理职能。

5.1 可信可解释时空预测系统需求分析

海量时空数据催生了大量的基于位置服务的移动应用,例如,以高德地图、百度地图为代表的基于电子地图的移动导航应用,在全球定位系统(如北斗系统)的支持下,通过移动端电子地图为用户提供路径规划、实时导航等丰富功能;以微信、微博和抖音为代表的基于位置社交网络应用,为用户提供了丰富的文本分享、视频发布、社交交互等功能,用户可以发布含有地理位置标签的内容,并与其他人进行分享。这一背景下,本文在可信网络实体地理定位(StarGeo)和可解释轨迹预测(ExNext)工作的基础上设计并实现可信可解释时空预测系统(Trustworthy Spatiotemporal Prediction System, T-STPS),致力于构建一个集实时定位、用户移动性偏好预测、数据可视化等功能于一体的综合性平台,旨在利用人工智能技术,特别是深度学习和图神经网络(GNN),对海量时空数据进行高效、可靠的分析和预测。该系统能够提供精准的地理位置识别、人群移动轨迹预测,并支持可解释的时空学习框架,助力社交平台、移动应用运营商、城市管理者及公共安全部门做出更科学的决策。为实现增强用户对预测结果的信任度,使其在关键领域具有更高的适用性和决策透明度的核心目标,平台应至少满足以下需求:

(1) T-STPS 需支持高效存储和管理多种类型的时空数据,包括签到数据(Check-in Data)、用户轨迹数据(Trajectory Data)、社交网络数据(Social Network

Data)、地理信息 (Geospatial Data) 等, 并采用分布式存储架构和优化检索机制, 保障数据的高效处理与访问。

(2) 系统需具备精准的地理位置推理能力, 结合邻域兴趣点信息、用户历史轨迹和社交关系, 提高位置预测的准确性, 并通过分层建模提升模型的泛化能力, 使其适用于不同精度需求的地理定位任务。

(3) T-STPS 需能够准确预测用户未来的移动轨迹, 综合考虑轨迹流模式、个性化偏好和时空上下文信息, 采用时间感知嵌入 (Time-aware Embedding) 方法增强模型在不同时间尺度下的预测能力, 提升预测结果的准确性。

(4) 系统需提供透明化的预测过程, 采用变分信息瓶颈 (VIB) 理论减少冗余信息, 并结合注意力机制 (Attention Mechanism) 分析轨迹预测的影响因素, 使用户能够理解预测过程, 增强其对系统决策的信任度。

(5) T-STPS 应支持多种实际应用场景, 包括智能社交推荐、城市交通预测、公共安全等, 为社交平台、城市管理者和公共安全部门提供精准的时空分析能力, 优化资源调度和安全管理。

(6) 系统界面设计应简洁直观, 具备高度可视化的数据展示和分析工具, 使用户能够快速上手, 并在数据处理与分析过程中高效掌握操作流程, 提高整体使用体验和交互效率。

5.1.1 功能性需求分析

可信可解释时空预测系统按照系统需求分析的描述, 将功能性需求划分成可视化模块、时空数据中心模块、网络实体定位模块、时空轨迹预测模块、可解释学习模块和用户管理模块, 如图 5-1, 下面将具体介绍各模块负责功能:




图 5-1 系统用例图

(1) 时空轨迹分析模块。该模块主要负责展示用户轨迹分析、兴趣点偏好、出

行习惯等数据，并提供直观的可视化图表，帮助用户理解时空数据的趋势和特征。主要功能包括：时空关联分析：提供如时间-频率直方图、兴趣点类别偏好、移动距离偏好等可视化图表。热力图分析：展示用户出行频率的热力图，分析不同时间段的用户活跃度。数据总览：包括用户总数、时空轨迹总数、新增签到兴趣点等关键指标统计。

（2）时空数据中心模块

该模块支持时空轨迹数据及地理定位数据的批量上传、存储和管理。数据集上传管理：用户可选择上传时空轨迹数据或地理定位数据。批量操作：支持数据的批量导入和批量删除，提高数据管理的效率。数据预处理：系统可进行基本的时空数据清理、格式转换等处理，以便后续分析。

（3）网络实体定位模块

该模块提供 IP 地址的地理定位服务，帮助用户解析 IP 地址的具体地理位置。主要功能包括：IP 地址解析：通过输入 IP 地址查询其对应的地理位置信息，如国家、城市、经纬度等。全球定位地图：用户可以在地图上查看 IP 地址的地理位置。详细 IP 信息查询：包括 IP 类型（如住宅、商业）、精度等级（如国家、省、市、街道）、波动半径等信息。

（4）时空轨迹预测模块

该模块基于用户历史轨迹和兴趣点偏好，预测其未来可能去往的兴趣点。主要功能包括：轨迹输入与查询：用户可输入兴趣点 ID、坐标、时间等信息，系统据此进行轨迹预测。路径预测：系统基于历史行为分析用户的潜在出行路线，并生成全局轨迹流图，展示用户的移动趋势。下一个兴趣点预测：结合用户历史偏好，预测用户的下一个可能访问的地点。

（5）可解释学习模块

该模块提供 AI 预测结果的可解释性分析，帮助用户理解预测背后的逻辑。主要功能包括：轨迹预测解释：系统会分析预测结果的关键因素，例如某用户的历史轨迹为家—公园—书店—咖啡厅—地铁站…，最终预测他最可能前往酒吧。关键历史轨迹分析：系统突出影响预测的历史行为。关键特征提取：系统分析影响预测的主要特征，如兴趣点类别、坐标、时间、轨迹 ID 等，并提供可视化解释。

（6）用户管理模块

用户管理模块负责用户权限的管理，确保系统的安全性和可控性。管理员可以通过该模块创建新用户、删除不再需要的用户以及修改用户的权限和个人信息，以便灵活适应系统需求。管理员还可为新用户提供必要的信息、初始密码和权限设置，确保系统用户管理的高效性和规范性。

5.1.2 非功能性需求分析

可信可解释时空预测系统需要具备一系列非功能性需求，具体如下：

（1）可用性：系统需要保证全时可用，确保其年度可用性不低于 99%，并具备强大的负载均衡和冗余设计，以确保在高负载下稳定运行。

（2）可靠性：系统应具备高可靠性，能够有效抵御故障，故障率应低于 1%。并配备实时监控和自动修复机制，在发生故障时迅速恢复继续提供服务，以保障系统的稳定运行。

（3）可维护性：系统应具有清晰的代码结构和完善的文档，以便于后期的维护与升级。系统的更新和问题修复流程应高效，旨在减少维护成本并提升开发人员的工作效率。所有模块的功能和接口应提供详尽的注释和解释，确保易于理解。

（4）可扩展性：系统应支持灵活扩展，能适应未来需求接入。新增数据源与接口时应平稳过渡，减少对现有功能的影响，快速集成新设备和数据格式。

（5）安全性：系统应实施严格的身份验证、角色管理和权限控制措施，确保患者数据的机密性、完整性和可用性。所有数据的传输与存储必须遵循行业标准和法规要求，防止未经授权的访问和数据泄露。

（6）响应时间：系统操作响应时间应小于 500 毫秒，数据加载白屏时间不超过 3 秒，数据导入和存储响应时间不超过 10 秒。操作过程中应通过加载动画或骨架屏提示用户。

（7）模型关键性指标：为了保障预测模块在实际应用中的表现效果，系统对模型性能提出了明确的量化指标要求，以确保预测的准确性、响应速度与可解释性。在预测准确性方面，Top-K 准确率（Top@10 Recall）要求不低于 50%，即用户实际访问的兴趣点应包含在模型预测的前十个候选结果中。在地理定位精度方面，模型的平均误差应控制在半径 2km 以内，衡量实际轨迹与预测轨迹之间的空间偏差，体现预测的空间合理性。

5.2 架构设计

本文旨在构建一个可信可解释时空预测系统，以满足时空轨迹分析、网络实体地理定位、轨迹预测及可解释性分析的需求。系统架构采用分层设计思想，如图 5-2 所示，自上而下划分为用户层、平台层和数据层，并引入权限控制机制以确保数据安全与访问管理。

用户层：负责提供用户交互界面，并支持主要的业务功能模块，包括时空轨迹分析模块、时空数据中心模块、网络实体定位模块、时空轨迹预测模块和可解释学习模块。此外，该层还包括用户管理模块，用于管理系统用户及其访问权限。




图 5-2 系统总体架构图

平台层：作为系统的核心计算层，主要承担业务逻辑处理、数据计算和模型评估。该层包括网络实体定位（星型图构建、图表示学习、地理定位）、时空轨迹预测（轨迹流图、兴趣点预测、可解释学习）、模型评估（地理定位准确度、轨迹预测精度、可解释性分析）及数据管理（网络实体数据、历史轨迹数据、后台个人数据）等核心功能，支持用户层的计算需求。

数据层：主要用于数据存储和管理，包括网络测量数据、网络属性知识、用户历史轨迹及用户个性化数据。该层的数据通过分布式存储架构进行组织，确保高效存储与访问。

为满足系统的高效性、稳定性和可扩展性需求，本系统采用现代化前后端分离架构，如图 5-3 所示，主要包括前后端服务、算法支持及数据存储三部分。

前端服务：基于 Vue3 作为核心框架，结合 AntdV 进行 UI 组件开发，以保证界面交互的响应速度和可用性。Echarts 用于构建动态图表，DataV 用于构建数据可视化看板，Less 负责样式管理，Axios 负责前后端数据通信，以确保系统数据交互的高效性与稳定性。

后端服务：采用 Spring Boot 作为基础框架，并结合 Spring MVC 实现前后端分离。为了增强系统安全性，引入 Spring Security 进行权限管理，使用 JWT 进行用户认证。Swagger 被用于 API 文档生成与测试，Fastjson 负责高效数据解析，Log4j2 用于日志管理，以确保系统运行状态可追踪，易于维护。




图 5-3 前后端技术框架

算法支持：系统集成多种时空数据建模和深度学习算法，包括轨迹流图（Trajectory Flow Map）、星型图（Star Graph）、注意力机制（Attention Mechanism）、时空图神经网络（ST-GNN）、深度概率建模（Deep Probabilistic Modeling）、时空 Transformer（Spatial-temporal Transformer）、图表示学习（Graph Representation Learning）及信息瓶颈理论（Information Bottleneck Theory）等，以支持精准的轨迹预测和可解释学习。

数据存储：采用多模式存储架构，包括 MySQL 作为结构化数据存储，Redis 作为缓存以加速数据查询，Doris 作为大规模列式存储以优化复杂查询和时空分析，Kettle 作为 ETL 数据处理工具，Zookeeper 用于分布式协调，以确保系统的高可用性与一致性。

5.3 详细设计

5.3.1 时空轨迹分析模块

时空轨迹分析模块用于解析用户的历史轨迹数据，提取关键行为模式，并通过可视化方式展示不同时间尺度下的移动偏好。该模块采用前后端分离架构，前端利用 Echarts 和 DataV 进行可视化渲染，后端基于 Spring Boot 提供数据查询 API，并结合 Redis 进行缓存优化，提高查询效率。

数据的获取与可视化渲染流程如图 5-4 所示，主要包含以下步骤：

- (1). 用户进入时空轨迹分析界面，前端通过 Axios 发送 GET 请求至后端 API，指定查询参数（用户 ID、时间范围等）。
- (2). 服务器首先查询 Redis 缓存，若缓存中存在该用户的轨迹统计信息，则直接返回缓存结果，以提高查询效率。

(3). 若缓存未命中, 则后端通过 SQL 查询数据库, 计算不同分析维度的轨迹统计数据, 并存储至缓存中, 减少后续重复查询的计算开销。

(4). 服务器将分析后的统计数据以 JSON 格式返回前端, 前端解析数据并进行可视化渲染。

(5). 采用 Echarts 生成柱状图、散点图、热力图等可视化组件, 以直观方式呈现轨迹分析结果。

数据获取与可视化渲染时序图 5-4 展示了前端、后端和数据库之间的数据交互流程。




图 5-4 时空轨迹分析数据获取与可视化渲染时序图

前端可视化展示包括: 时空关联关系分析-柱状图, 展示不同时段访问兴趣点的频率。兴趣点移动距离分布-散点图, 展示兴趣点间的移动范围。兴趣点类别偏好分析-热力图, 分析用户对不同兴趣点类别的访问偏好。周内出行模式分析-热力图, 展示用户在一周内的活跃情况。

本模块基于以下关键技术实现: Vue3 框架, 结合 Echarts 和 DataV 进行数据可视化, Axios 进行数据请求。Spring Boot 提供 API 服务, MySQL 存储用户轨迹数据, Redis 缓存热点数据以优化查询性能。

本模块基于前后端分离架构, 结合 Redis 进行缓存优化, 采用 Echarts 进行可视化渲染, 实现高效、直观的轨迹数据分析功能。通过优化数据获取流程, 提高系统查询效率, 并提供多维度的轨迹分析, 为用户提供有价值的时空行为洞察。

5.3.2 时空数据中心模块

时空数据中心模块负责系统中轨迹数据、社交网络数据及地理位置信息的接入、存储与管理。该模块支持多种数据格式的导入，并结合分布式存储架构，以提高数据处理的灵活性、存取效率和查询性能。数据中心的核心功能包括数据采集、转换、存储和索引管理，如图 5-5 所示。




图 5-5 时空数据导入设计图

在数据导入与解析方面，该模块支持结构化的时空轨迹数据（xls、xlsx、csv 格式）和非结构化的社交网络数据（jpg、jpeg、png 格式）。时空轨迹数据包含用户签到记录、兴趣点访问情况和轨迹路径，而社交网络数据主要包含用户分享的位置信息及相关社交互动数据。为了高效处理这些数据，系统采用 EasyExcel 解析结构化数据，提取用户 ID、签到时间、兴趣点分类、经纬度等关键信息，并转换为标准格式后存入数据库。对于社交网络数据，系统利用 OpenCV 进行处理，提取图像中的 GPS 元数据，并进行预处理后存储。

在数据转换与存储方面，为了实现跨源数据的统一存储，系统采用 Kettle 进行数据转换和调度控制。Kettle 作为 ETL（Extract-Transform-Load）工具，负责数据的清洗、转换和存储管理。转换后的数据依据其结构特点存入不同的数据库，其中 MySQL 用于存储结构化的轨迹数据、地理位置信息和社交网络基本数据，提供高效的事务管理和查询能力；Doris 分布式仓库用于存储大规模历史轨迹数据、时空行为模式数据以及模型训练所需的长期存储数据，支持高吞吐查询和批量计算。

在数据管理与索引优化方面，系统对不同类型的数据构建了专门的索引机制，以提高查询效率。轨迹数据采用基于 R-tree 或 Quad-tree 结构的时空索引，提高数据的检索速度。图像数据则采用内容索引机制，通过特征提取方法建立高效索引，实现对特定场景或兴趣点的快速搜索。

在数据访问与安全性方面，为保障数据安全性和访问控制，系统采用基于角色的访问控制（RBAC）模型，确保不同级别用户只能访问相应权限数据。同时，

系统通过数据加密与脱敏机制防止轨迹数据中个人隐私信息的泄露。结合 Redis 缓存机制，系统能够加速高频查询请求，提高数据访问效率，减少数据库负载。

时空数据中心模块集成了数据解析、转换、存储、索引优化及访问控制等关键功能，确保数据管理的高效性和安全性。该模块不仅为系统提供了稳定的数据存储支持，还为轨迹预测、网络实体定位等核心功能提供了高质量的数据基础。

5.3.3 网络实体定位模块



图 5-6 网络实体定位流程

网络实体定位模块旨在提供基于 IP 地址的精确地理定位能力，以支持社交平台、公共安全及网络管理等应用场景。该模块采用基于星型图和深度概率建模进行 IP 地址的地理推理，并结合外部数据库资源，如 IP-to-Location 数据库、自治系统信息库及网络拓扑结构，以提高定位的精度和可信度。

在系统架构上，该模块采用前后端分离设计，前端通过 Vue3 结合 AntdV 和 Echarts 提供交互界面，支持地理位置信息的可视化展示。用户可通过搜索框输入 IP 地址或批量上传 IP 列表，系统将自动调用后端接口执行地理定位查询。查询结果以表格形式呈现，包含 IP 地址、国家、省份、城市、经纬度、所属 AS 号及网络服务提供商等信息，同时在地图组件中直观地展示定位结果，并提供多层次的可信度评分。

后端采用 Spring Boot 框架，基于 RESTful API 提供 IP 解析服务。查询请求首先检查 Redis 缓存，以减少重复查询的开销并提高响应速度。若缓存未命中，系统将根据 IP 地址提取对应的 ASN 信息，并结合历史定位数据计算其初步地理位置。

随后，基于星型图模型计算 IP 地址与已知地理位置的关系，通过深度概率建模方法进行优化，以最大化地理推理的置信度。最终，系统整合来自多源数据的定位信息，并以标准化格式返回至前端。

数据存储层采用 MySQL 结合 Doris 进行结构化和分布式数据存储。MySQL 主要用于存储 IP 地址解析历史记录及用户查询日志，而 Doris 负责管理大规模网络测量数据及地理分布模式，以支持快速索引和查询优化。此外，系统通过 Kettle 进行数据抽取和转换，定期从第三方 IP-to-Location 数据源更新数据库，以确保地理定位信息的准确性和时效性。

为了提升系统的可靠性与可扩展性，该模块支持基于 Kafka 的异步处理机制，以应对大规模 IP 查询任务，并支持负载均衡调度。此外，系统引入了可信度评分机制，综合计算 IP 地址的地理定位可信度，包括数据来源一致性、历史查询稳定性及星型图推理置信度等因素，为用户提供更可靠的地理位置推理结果。

本模块的设计不仅提升了网络实体定位的精度与效率，同时保证了系统在大规模数据环境下的稳定性，为可信可解释时空预测系统提供了可靠的地理位置解析能力。

5.3.4 时空轨迹预测模块

时空轨迹预测模块的主要目标是基于用户的历史轨迹数据、兴趣点偏好以及时空关系信息，预测用户未来可能访问的地点。该模块广泛应用于个性化推荐、智慧城市规划和公共安全等领域，能够有效支持用户移动行为建模和趋势分析。



图 5-7 轨迹预测流程

如图 5-6, 系统采用前后端分离架构, 前端基于 Vue3 结合 AntdV 实现交互界面, 并通过 Echarts 可视化预测结果。用户可输入查询条件, 包括兴趣点 ID、时间戳和用户标识等, 系统将自动获取历史轨迹数据, 并通过后端预测算法计算用户下一可能兴趣点。前端展示轨迹流图、全局轨迹流网络和兴趣点预测结果, 并支持可视化地图交互, 以提升用户体验。

后端采用 Spring Boot 框架, 提供 RESTful API 服务。请求流程如下: 首先, 前端通过 API 接口提交预测请求, 后端从 MySQL 数据库中检索用户历史签到数据, 并结合 Redis 进行缓存优化, 以提高数据查询效率。随后, 系统利用图神经网络对用户历史轨迹进行建模, 构建轨迹流图, 并结合 Transformer 模型进行时空建模, 以捕捉轨迹序列中的时空依赖性。

数据存储层采用 MySQL 和 Doris 进行分层存储。MySQL 主要存储结构化的用户轨迹数据, 包括签到记录、兴趣点信息等, 而 Doris 负责存储大规模历史轨迹数据, 以支持高效查询和大规模分析任务。此外, Kettle 用于数据抽取和转换, 确保系统能够定期更新历史轨迹数据, 并结合 Kafka 进行异步任务调度, 提高系统的并发处理能力。

系统采用 Transformer 结合 ST-GNN 进行轨迹预测, 确保预测结果具备高准确性和时空一致性。具体而言, ST-GNN 通过空间关系建模用户的轨迹移动模式, 而 Transformer 负责捕捉轨迹的时间动态特征, 模型输出包含下一兴趣点的预测分数。

为了提升系统的可扩展性, 模块支持批量轨迹预测和个性化预测模式。批量预测模式可对多个用户同时进行轨迹推理, 以支持大规模应用场景; 个性化预测模式则基于用户的个体特征和历史行为习惯, 提供精准的个性化轨迹推荐。系统还提供预测历史记录功能, 用户可查看过往预测结果, 并进行轨迹分析对比, 以优化预测策略。本模块的设计充分结合了时空数据挖掘技术和深度学习模型, 确保轨迹预测结果具备高精度, 为社交平台、交通管理、智能推荐等应用提供强有力的支持。

5.3.5 可解释学习模块

可解释学习模块旨在为时空轨迹预测结果提供可解释性分析, 帮助用户理解模型决策的关键因素, 提高系统的可信度。该模块通过分析历史轨迹、用户行为模式及环境特征, 生成可视化解释, 以支持智能推荐、交通管理及公共安全等应用场景。可解释性分析主要从关键历史轨迹和关键属性两个方面展开, 为用户提供轨迹预测的详细推理过程。

本模块采用前后端分离架构, 前端基于 Vue3, 结合 Echarts 进行可视化渲染。

用户可查看影响轨迹预测的核心因素，包括历史轨迹压缩对比分析、重要兴趣点及其类别、时间相关特征等。系统提供交互式可视化组件，支持用户调整解释粒度，以便更灵活地理解预测逻辑。

后端采用 Spring Boot 框架，提供 API 接口服务，接收用户请求并返回可解释性分析结果。具体流程如下：首先，前端向后端提交轨迹预测的解释请求，后端通过 MySQL 查询用户历史签到数据，并结合 Redis 进行缓存优化，以提高数据查询效率。随后，系统基于变分信息瓶颈方法，对用户的轨迹数据进行压缩，筛选出最具信息量的历史轨迹。通过计算轨迹点的熵值和互信息，系统评估各轨迹点对预测结果的贡献度，并筛选出最关键的历史轨迹点，以可视化方式呈现高低压缩程度下的轨迹信息。

同时，系统采用注意力机制和变分信息瓶颈理论计算轨迹预测的关键属性。具体而言，系统从 POI ID、POI 类别、签到次数、签到时间、社交关系等多个维度提取特征，并计算其对预测结果的贡献度。通过可视化解释界面，用户可查看影响轨迹预测的核心特征，并调整特征权重，以分析不同因素对预测结果的影响。

数据存储层采用 MySQL 和 Doris 进行分层存储。MySQL 主要存储用户签到记录、POI 信息和轨迹历史数据，而 Doris 负责存储大规模的时空数据，以支持高效的查询和分析。Redis 用于缓存高频查询数据，确保系统的实时响应能力。

可解释学习模块结合信息瓶颈理论和注意力机制，实现轨迹预测的透明化分析，使用户能够直观理解预测结果的来源及其影响因素。系统支持多粒度可解释性分析，包括轨迹级、兴趣点级和属性级解释，满足不同应用场景下的需求。通过提供可解释的轨迹预测分析，该模块有效增强了系统的可信性，并提升了用户对预测结果的理解和信任。

5.3.6 用户管理模块

用户管理模块负责管理系统用户的基本信息、权限分配及身份验证，旨在确保系统的安全性和高效管理能力。该模块通过 MySQL 数据库存储用户基本信息、角色及权限，同时结合 Redis 进行用户会话管理和登录状态维护，以提高系统的响应速度与并发处理能力。此外，为了提升安全性，用户管理模块采用基于 JWT（JSON Web Token）的双 Token 机制，确保用户身份验证的可靠性，并支持长时间的安全会话。该模块还提供了完善的权限管理体系，使管理员可以直观地进行用户的增、删、改、查等操作，实现对系统用户的高效管理。

用户管理模块的核心功能由多个类组成，图 5-8 展示了各类间的关联，其中主要包括 UserManager 类、SessionManager 类和 Authorization 类。




图 5-8 用户管理模块 UML 设计

UserManager 类负责用户信息的管理，包括用户的创建、更新、删除及查询操作。其主要方法如下：`addUser()`：用于添加新用户，将用户基本信息存储到 MySQL 数据库中，并同步更新权限表。`updateUser()`：用于修改用户信息，包括用户名、密码、角色等，并更新数据库。`deleteUser()`：删除用户记录，同时移除其会话信息，确保用户账户不可访问。`queryUser()`：根据用户 ID 或用户名查询用户信息，并返回符合条件的用户数据。

SessionManager 类负责用户会话管理，利用 Redis 进行身份存储和快速检索。主要包括：`storeSession()`：将用户的登录会话存储到 Redis，以便后续身份验证时快速访问。`retrieveSession()`：从 Redis 获取用户的会话信息，确保每次请求都能进行身份认证。

Authorization 类负责用户身份验证和权限控制，基于 JWT 进行 Token 生成和管理。其主要方法如下：`generateToken()`：用于生成 AccessToken 和 RefreshToken，保证用户的持续登录状态。`validateToken()`：验证 AccessToken 的有效性，若过期，则使用 RefreshToken 进行更新，确保安全认证的持续性。

通过上述设计，用户管理模块确保了系统的安全性、可扩展性和高效性，能够有效地管理用户信息和访问权限。同时，利用 Redis 进行会话缓存，减少数据库

访问负担，提高系统的并发处理能力。

5.4 系统实现

本系统基于可信可解释时空预测框架，结合图神经网络（GNN）、星型图架构、深度概率建模和信息瓶颈理论（IB）等理论构建了一个高效、可扩展的时空预测平台。系统采用前后端分离的架构，前端使用 Vue3 搭配 AntdV、Echarts 和 DataV，实现动态交互和可视化展示；后端基于 Spring Boot 框架，整合 Spring Security、JWT 认证机制，提供安全、高效的 API 服务。同时，系统采用多层存储方案，结合 MySQL 进行结构化存储，Redis 进行高效缓存，Doris 进行大规模数据分析，确保了系统的高可用性和可扩展性。具体代码见 <https://github.com/bridgeyangk/ExGeo>。




图 5-9 时空轨迹分析模块

时空轨迹分析模块的主要功能是对用户历史轨迹数据进行深度分析，并以可视化方式呈现轨迹移动特征，为用户提供轨迹模式识别、兴趣点偏好分析和移动规律挖掘等功能。该模块支持对不同时间段的轨迹分布进行统计，包括不同时段的签到频率、兴趣点类型偏好、移动距离特征等分析。系统首先从数据中心提取用户的签到数据，并通过数据预处理模块进行去重、归一化和缺失值填补等操作。然后，系统利用时序分析方法计算轨迹点的时间分布，结合地理信息分析用户对不同地点的偏好程度。最终，分析结果通过 Echarts 组件进行可视化展示，包括直方图、散点图、热力图等形式，以帮助用户直观理解其行为模式。

时空数据中心模块的核心功能是提供高效的数据存储、管理和查询能力，支持系统各模块对多源异构数据的访问。系统支持两类数据的存储与管理，一类



图 5-10 时空数据中心模块

是结构化数据，如签到数据、兴趣点信息、社交网络关系等，这部分数据存储于 MySQL 数据库，并提供索引优化以加速查询；另一类是半结构化或非结构化数据，如用户上传的社交媒体图像等，这部分数据存储于分布式存储 Doris，并结合 Redis 进行缓存管理，以支持高频数据访问。系统提供批量数据导入功能，支持 xls、xlsx、csv 等格式的签到数据上传，并使用 EasyExcel 进行解析。对于社交网络数据，系统采用 OpenCV 进行图像解析，并存储相关的元数据以便后续处理。同时，系统提供 RESTful API，支持前端模块进行数据查询和更新操作，以满足时空轨迹分析、轨迹预测等模块的功能需求。




图 5-11 网络实体定位模块

网络实体定位模块的主要功能是基于 IP 地址进行精确的地理位置推测，支持用户查询特定 IP 地址的归属地信息，包括国家、省份、城市、经纬度及定位置信度。系统采用基于星型图的深度概率建模方法，结合 IP 地址与自治系统（ASN）、地理邻近关系等信息，实现高精度的 IP 归属地预测。系统支持两种查询方式，一种是直接查询本地数据库，若目标 IP 已有存储，则返回查询结果；另一种是对于未存储的 IP，系统调用图神经网络模型进行预测，并结合多源信息计算地理位置。定位结果以表格和地图可视化的方式呈现，用户可在前端界面中查看 IP 归属地详情，并支持批量导出查询结果。




图 5-12 实体定位结果

实体定位结果在地图上进行可视化展示，通过对 IP 地址的精准匹配与预测，计算出该地址所属的区域、城市、经纬度等详细信息。系统根据不同的定位精度（如街道级别或城市级别）提供详细的定位分析，并对定位结果的可信度进行评级。通过分析 IP 的波动半径和区域代码等信息，系统能够进一步确认该 IP 的真实位置，并通过地图可视化展示该位置，方便用户直观了解其地理分布。最终，系统在前端展示精确到街道的地理位置信息，支持用户根据不同需求调整定位精度，以查看不同粒度的定位结果。

时空轨迹预测模块的主要功能是预测用户未来可能访问的兴趣点，并提供轨迹流向的可视化分析。系统基于用户的历史签到记录，利用深度学习和图神经网络技术，建模用户的轨迹模式，并在给定当前状态下预测下一步可能的移动地点。系统首先提取用户历史轨迹数据，构建轨迹流图（Trajectory Flow Graph），然后采用时空 transformer 进行轨迹建模，结合注意力机制计算不同轨迹点的重要性。模




图 5-13 时空轨迹预测

型预测出用户下一步最可能访问的兴趣点。预测结果在前端通过地图和轨迹流向图的方式呈现，用户可以查看预测的兴趣点及其可能性，同时系统支持不同时间尺度下的轨迹预测，以提高预测的适应性。



图 5-14 可解释学习

可解释学习模块的核心功能是为时空轨迹预测结果提供可解释性分析，帮助用户理解预测结果的关键影响因素。系统采用基于信息瓶颈理论的 ST-Explainer 方法，对轨迹预测进行解释，并提供不同粒度的可解释性分析，以增强用户对模型预测结果的信任。系统分析用户的历史轨迹数据，提取对预测结果影响最大的

子轨迹集合，并计算轨迹点的重要性得分。同时，系统利用注意力机制识别轨迹预测过程中最重要的时间窗口和地理位置，并评估不同因素对预测结果的贡献度。最终，系统在前端以可视化方式呈现解释结果，包括关键历史轨迹点、主要影响因素，并支持用户调整解释粒度，以查看不同压缩程度下的轨迹解释结果。

5.5 系统测试

在系统开发和部署过程中，测试工作是确保系统稳定性、功能性和性能的关键步骤。本测试方案包括了多个环节，涵盖了单元测试与集成测试、功能测试和性能测试三个方面，旨在验证系统是否能够按照设计要求完成各项任务。

5.5.1 测试环境配置

本系统测试运行环境如下所示：

- 操作系统：Windows 10
- 数据库系统：MySQL 8.0, Apache Doris 1.2, Redis 7
- 开发语言：Python 3.10, Java 17
- 前端框架：Vue.js 3, ECharts
- 测试工具：PyTest、unittest、Selenium、Postman、JMeter

5.5.2 单元测试与集成测试

单元测试主要针对系统的核心功能模块，验证各模块的独立功能是否符合预期。测试采用 JUnit 和 PyTest 作为测试框架，模拟输入数据，并检查输出结果的正确性。以“时空轨迹分析模块”为例，设计如下测试用例：

```
def test_trajectory_visualization():
    # 输入数据
    input_data = {
        "user_id": 123,
        "trajectory": [{"lat": 41.9191, "lng": -87.7634,
        "timestamp": "2025-04-14T10:03:22"}]
    }
    expected_output = {"status": "success",
    "visualization": "trajectory_map"}
    # 调用时空轨迹分析模块
    response = client.post("/api/visualize_trajectory", json=input_data)
```

```
# 检查响应
assert response.status_code == 200
assert response.json()["status"] == expected_output["status"]
```

表 5-1 单元测试结果

测试模块	测试点	测试预期	测试结果
时空轨迹分析	轨迹可视化图表渲染	确保轨迹分布、时空关系图正确显示	通过
时空数据中心	数据上传解析	xls、csv 格式的数据可正确解析并存储	通过
网络实体定位	IP 地址地理定位	根据 IP 查询可正确返回地理位置	通过
时空轨迹预测	用户轨迹预测	输入用户 ID，能正确预测下一兴趣点	通过
可解释学习	关键影响因素计算	计算并可视化轨迹预测的关键影响因素	通过

首先，对时空轨迹分析模块，测试轨迹数据的预处理，包括时间格式转换、异常值过滤和轨迹点去重等功能，确保数据清理逻辑的正确性。其次，对时空数据中心模块，测试数据库的数据读写操作，检查 MySQL 和 Doris 的数据一致性，以及 Redis 缓存是否能有效减少数据库查询负载。对于网络实体定位模块，验证 IP 地址地理定位模型的精度，确保查询结果的返回时间满足系统需求，并测试星型图网络模型在不同数据规模下的推理时间。在时空轨迹预测模块中，测试轨迹建模与预测逻辑，包括数据输入、图神经网络计算和预测结果的输出，检查预测准确率，并验证不同时间尺度下的预测稳定性。对于可解释学习模块，测试 ST-Explainer 解释生成流程，包括关键轨迹点筛选、特征重要性计算，以及解释结果的可视化展示，确保生成的解释合理且符合用户理解。

集成测试围绕模块间数据流进行设计，以下是具体场景：

- 场景 1：从数据中心上传 CSV 数据，验证是否自动清洗并同步进入分析模块
- 场景 2：预测模块依赖轨迹分析结果和 IP 地理信息，验证是否能正确协同生成预测结果
- 场景 3：可解释模块调用预测输出，生成图形可视化解释

所有集成测试脚本通过 Postman 脚本编排和 Selenium 模拟前端交互完成，支持自动化回归测试。集成测试关注系统各个模块之间的数据交互，确保模块能够协同工作。表 5-2 展示了系统集成测试的测试用例。

在时空轨迹分析与数据中心集成测试中，验证分析模块是否能正确从数据库读取轨迹数据，并在数据更新时能自动刷新可视化结果。在网络实体定位与数据中心集成测试中，确保 IP 地址数据能正确存储和更新，前端查询时能实时获取最新定位信息。在轨迹预测与数据存储集成测试中，测试预测模块是否能正确加载历史轨迹数据，模型是否能在推理完成后将预测结果存入数据库，并确保预测结

表 5-2 集成测试

模块 A	模块 B	测试预期	测试结果
时空数据中心模块	轨迹分析模块	上传的数据可正确解析并用于轨迹分析	通过
网络实体定位模块	轨迹预测模块	IP 定位信息可作为预测输入参数	通过
轨迹分析模块	预测模块	轨迹数据可正确传递至预测模块	通过
预测模块	可解释学习模块	预测结果可输入至可解释学习模型	通过

果能在前端正确展示。在可解释学习与轨迹预测集成测试中，验证可解释性模块是否能正确解析预测结果，提取关键特征，并提供可视化解释信息。

5.5.3 功能测试

功能测试确保系统的每个功能按照需求正常运行。表 5-3 展示了系统功能测试的测试用例。

表 5-3 功能测试

功能模块	测试点	测试预期	测试结果
轨迹分析	选择时空轨迹文件	轨迹数据正确显示，并生成时空关联图	通过
数据管理	上传数据	数据成功存储，并可查询	通过
网络实体定位	查询 IP 地址位置	显示 IP 所在的国家、城市、经纬度等信息	通过
轨迹预测	用户历史轨迹输入	用户历史轨迹可加载，并生成预测结果	通过
可解释学习	轨迹预测解释	关键历史轨迹点和影响因素可视化显示	通过

对于用户管理功能，测试用户注册、登录、权限管理是否正常，确保不同用户角色能正确访问不同功能模块。对于数据管理功能，测试数据的导入、存储、查询和更新，确保系统能正确处理不同格式的数据文件，并支持高效查询。对于时空轨迹分析功能，测试不同用户的轨迹数据分析能力，包括签到点统计、时间分布分析、兴趣点偏好分析等。对于网络实体定位功能，测试系统是否能正确解析 IP 地址，返回正确的地理位置信息，并支持批量查询。对于轨迹预测功能，测试不同用户的轨迹预测是否准确，预测结果是否能及时更新，并确保预测置信度合理。对于可解释学习功能，测试可解释性分析结果是否符合预期，关键影响因素的提取是否合理，确保解释结果的透明度和可用性。

5.5.4 性能测试

性能测试旨在评估系统在不同负载下的响应时间、吞吐量和资源消耗情况，确保系统能在高并发场景下稳定运行。表 5-4 展示了系统性能测试的测试用例。

在系统负载测试中，使用 JMeter 模拟不同数量的并发用户访问系统，观察数据库查询、轨迹分析、IP 归属地查询、轨迹预测等功能在高负载下的响应时间。

表 5-4 性能测试

测试项	测试方法	测试标准	测试结果
数据存储性能	上传 100 万条轨迹数据	数据库存储成功, 响应时间 < 2s	通过
轨迹预测性能	同时请求 100 个用户预测	预测结果返回时间 < 3s	通过
IP 地址解析性能	查询 10 万条 IP 地址	查询正确率 > 99%, 响应时间 < 2s	通过
并发访问测试	500 用户同时访问	系统响应稳定, 无崩溃	通过

测试结果表明, 在 1000 并发用户的情况下, 系统平均响应时间保持在 1.2 秒以内, 满足性能要求。在数据库查询性能测试中, 测试 MySQL、Doris 和 Redis 的查询性能, 评估缓存优化对查询效率的影响。实验表明, 使用 Redis 作为缓存后, 常见查询操作的响应时间降低了 60%。在预测模型推理性能测试中, 评估时空轨迹预测模型在不同数据规模下的推理速度, 测试 ExNext 在 10 万条轨迹数据上的计算时间, 确保预测任务在 1 秒内完成。在可解释性分析性能测试中, 测试 ST-Explainer 计算解释结果的时间, 确保解释过程不会显著影响系统性能。实验结果表明, 在 5 万条轨迹数据集上, 解释生成时间低于 2 秒, 满足实时可视化要求。

通过上述单元测试、集成测试、功能测试和性能测试, 验证了可信可解释时空预测系统各个模块的正确性、可用性和稳定性。所有测试均通过, 系统能够在轨迹分析、数据存储、地理定位、轨迹预测和可解释性分析等方面提供高效、可靠的服务。

5.6 本章小结

本章围绕可信可解释时空预测系统的设计与实现展开, 系统性地介绍了系统的架构、各功能模块的技术细节及实现过程。首先, 本文基于前后端分离的设计思想, 构建了一个高效、稳定、可扩展的时空预测系统。系统采用 Vue3、Echarts、Spring Boot、Redis、MySQL 等技术, 实现了前端交互、数据存储、服务调度与计算优化等功能。与此同时, 引入深度学习、图神经网络和信息瓶颈理论等先进算法, 提升系统对时空数据的预测能力和可解释性。

其次, 本章详细阐述了系统的五个核心功能模块, 包括时空轨迹分析模块、时空数据中心模块、网络实体定位模块、时空轨迹预测模块和可解释学习模块。在时空轨迹分析模块中, 系统采用可视化方法直观展示用户轨迹分布、兴趣点偏好等信息, 为后续分析提供基础支持。时空数据中心模块则实现了多源异构数据的高效存储和管理, 支持轨迹数据、社交网络数据及地理信息数据的接入。网络实体定位模块基于星型图构造方法, 结合不确定性建模, 提升了 IP 地址地理位置识别的精度。时空轨迹预测模块通过时空 transformer 建模用户的历史行为, 提供精

准的兴趣点预测结果。可解释学习模块借助信息瓶颈理论和注意力机制，为预测结果提供透明的可解释性分析，增强系统的可信度。

最后，为了验证系统的稳定性和可用性，本章设计并实施了一系列测试，包括单元测试、集成测试、功能测试和性能测试。测试结果表明，系统在各项指标上均满足预期，能够高效处理大规模时空数据，并在预测精度、系统响应速度和并发能力等方面表现良好。

综上所述，本章完成了可信可解释时空预测系统的设计与实现，构建了从数据存储、地理定位、轨迹预测到可解释分析的完整工作流。

第六章 全文总结与展望

6.1 全文总结

本研究围绕可信可解释的时空数据表征学习展开，针对网络实体地理定位与人群移动性预测中的关键挑战，提出了一系列创新性的深度学习方法与系统实现方案。在理论层面，本文结合深度概率建模方法构建了基于星型图的网络实体定位方法，以提高地理定位的准确性和鲁棒性，并结合信息瓶颈理论优化轨迹预测任务的可解释性，实现预测精度与模型透明性的有效平衡。在系统层面，本文设计并实现了可信可解释时空预测系统，该系统集成了时空轨迹分析、时空数据存储与管理、网络实体定位、轨迹预测及可解释性分析等核心模块，能够在复杂的时空环境中提供高效、透明、稳定的预测能力。

首先，针对地理定位任务中面临的噪声影响与数据稀疏问题，本文提出了一种结合深度概率建模和星型图架构的可信网络实体地理定位方法。通过不确定性感知机制，该方法能够有效评估预测位置的不确定性，并利用星型图建模网络节点关联关系，以增强数据的表征能力，提高模型在低数据量和高噪声环境下的鲁棒性。实验结果表明，该方法在多个真实世界数据集上的性能优于传统定位方法，能够在减少节点稀疏性问题影响的同时，提高位置预测的准确性。

其次，为了解决轨迹预测任务中复杂的语义结构和全局移动模式建模难度，本文提出了一种基于图增强学习的轨迹预测模型。通过构建轨迹流图，该模型能够有效提取个体移动模式的全局转换关系，并结合个性化偏好、时空上下文及时间感知类别嵌入，实现高效的时空轨迹预测。同时，本文基于信息瓶颈理论设计了一种可解释轨迹预测方法，筛选轨迹中的关键子序列，从而提取最具信息量的特征表示，提高模型的可解释性。实验表明，该方法在准确性和可解释性方面均有较大提升，尤其是实现了领域内后验可解释到先验可解释的突破，同时还在“模型压缩”与“准确预测”间取得平衡，为可信轨迹分析提供了新的研究视角。

最后，本文进一步探索了可信可解释时空预测系统的工程实现，设计并构建了一个集成多种深度学习模型的预测系统。系统采用模块化架构，包含数据管理、轨迹分析、网络实体定位、轨迹预测及可解释学习等核心功能模块，并结合前后端分离的技术方案，提高了系统的可扩展性与适用性。实验评估表明，该系统能够在多个应用场景中实现高效、透明的时空预测，为智能交通、城市规划及公共安全等领域的决策提供了技术支持。

综上所述，本文围绕可信可解释时空数据表征学习，针对不同的时空学习任

务提出了新的建模方法，并通过系统实现验证了其实际应用价值。研究表明，本文提出的模型和系统不仅在理论上具有创新性，同时在实际应用中也展现出了广泛的适用性和可靠性。

6.2 后续工作展望

尽管本文在可信可解释时空数据表征学习方面取得了一定的进展，但仍然存在诸多值得进一步研究和优化的方向。未来的研究可以围绕以下几个方面展开：

第一，进一步提升地理定位和轨迹预测的可扩展性。在大规模用户群体和复杂城市环境下，时空预测模型可能面临计算复杂度较高的问题。因此，可以探索基于联邦学习或自监督学习的分布式建模方法，以减少数据依赖，提高模型的泛化能力和扩展性。

第二，增强对动态时空模式的建模能力。目前的轨迹预测模型在建模长期依赖关系时仍然存在一定的局限性，未来可以考虑结合图神经网络与 Transformer 结构，进一步优化时空依赖关系的建模。此外，可以探索基于强化学习的动态轨迹生成方法，以更好地适应复杂时空环境下的个体行为变化。

第三，优化可解释性建模方法。目前，基于信息瓶颈理论的可解释方法在复杂轨迹模式中的适用性仍需进一步验证。未来可以引入因果推理或注意力机制优化等方法，提升可解释性分析的精细化程度。同时，还可以探索人机交互机制，以结合专家知识，提高可解释性结果的可读性和应用价值。

第四，扩展可信可解释时空预测系统的应用场景。尽管本文的系统已经在地理定位、轨迹预测等任务上展现了较好的性能，但其在智能交通、公共安全、疫情防控等领域的进一步应用仍值得深入研究。未来的工作可以围绕不同场景需求，对系统进行功能扩展，并结合边缘计算与物联网技术，实现更低时延、更高效的数据处理能力。

总的来说，可信可解释时空学习仍然是一个充满挑战和前景的研究方向。随着数据规模的不断增长和深度学习技术的持续发展，未来的研究将致力于提升模型的准确性、泛化性和公平性，实现一个更加具备可信度的时空预测系统，以促进其在现实世界中的广泛应用。

参考文献

- [1] Wang S, Cao J, Philip S. Y. Deep learning for spatio-temporal data mining: A survey[J]. IEEE transactions on knowledge and data engineering, 2020, 34(8): 3681-3700.
- [2] Silva T. H, Viana A. C, Benevenuto F, et al. Urban computing leveraging location-based social network data: a survey[J]. ACM Computing Surveys (CSUR), 2019, 52(1): 1-39.
- [3] Atluri G, Karpatne A, Kumar V. Spatio-temporal data mining: A survey of problems and methods[J]. ACM Computing Surveys (CSUR), 2018, 51(4): 1-41.
- [4] Zheng Y. Trajectory data mining: an overview[J]. ACM Transactions on Intelligent Systems and Technology (TIST), 2015, 6(3): 1-41.
- [5] Xia L, Huang C, Xu Y, et al. Spatial-temporal sequential hypergraph network for crime prediction with dynamic multiplex relation learning[C]. IJCAI, 2021, 1631-1637.
- [6] 中华人民共和国中央人民政府. 国务院关于印发新一代人工智能发展规划的通知, 2017.
- [7] Cheng T, Haworth J, Anbaroglu B, et al. Spatio-temporal data mining[J]. Handbook of regional science, 2021, 1691-1709.
- [8] Hamdi A, Shaban K, Erradi A, et al. Spatiotemporal data mining: a survey on challenges and open problems[J]. Artificial Intelligence Review, 2022, 1-48.
- [9] Maciąg P. S. A survey on data mining methods for clustering complex spatiotemporal data[C]. International conference: beyond databases, architectures and structures, 2017, 115-126.
- [10] Lv Y, Duan Y, Kang W, et al. Traffic flow prediction with big data: A deep learning approach[J]. Ieee transactions on intelligent transportation systems, 2014, 16(2): 865-873.
- [11] Soua R, Koesdwiady A, Karray F. Big-data-generated traffic flow prediction using deep learning and dempster-shafer theory[C]. 2016 International joint conference on neural networks (IJCNN), 2016, 3195-3202.
- [12] Yu H, Xu X, Zhong T, et al. Overcoming forgetting in fine-grained urban flow inference via adaptive knowledge replay[C]. Proceedings of the AAAI Conference on Artificial Intelligence, 2023, 5393-5401.
- [13] Ke J, Yang H, Zheng H, et al. Hexagon-based convolutional neural network for supply-demand forecasting of ride-sourcing services[J]. IEEE Transactions on Intelligent Transportation Systems, 2018, 20(11): 4160-4173.

- [14] Liang Y, Ouyang K, Jing L, et al. Urbanfm: Inferring fine-grained urban flows[C]. Proceedings of the 25th ACM SIGKDD international conference on knowledge discovery & data mining, 2019, 3132-3142.
- [15] Zhang J, Zheng Y, Qi D, et al. Dnn-based prediction model for spatio-temporal data[C]. Proceedings of the 24th ACM SIGSPATIAL international conference on advances in geographic information systems, 2016, 1-4.
- [16] Zhu Q, Chen J, Zhu L, et al. Wind speed prediction with spatio-temporal correlation: A deep learning approach[J]. Energies, 2018, 11(4): 705.
- [17] Feng J, Li Y, Zhang C, et al. Deepmove: Predicting human mobility with attentional recurrent networks[C]. Proceedings of the 2018 world wide web conference, 2018, 1459-1468.
- [18] Jiang R, Song X, Fan Z, et al. Deep roi-based modeling for urban human mobility prediction[J]. Proceedings of the ACM on Interactive, Mobile, Wearable and Ubiquitous Technologies, 2018, 2(1): 1-29.
- [19] Liang Y, Ke S, Zhang J, et al. Geoman: Multi-level attention networks for geo-sensory time series prediction[C]. IJCAI, 2018, 3428-3434.
- [20] Xu K, Qin Z, Wang G, et al. Collision-free lstm for human trajectory prediction[C]. MultiMedia Modeling: 24th International Conference, MMM 2018, Bangkok, Thailand, February 5-7, 2018, Proceedings, Part I 24, 2018, 106-116.
- [21] Shi Y, Tian Y, Wang Y, et al. Sequential deep trajectory descriptor for action recognition with three-stream cnn[J]. IEEE Transactions on Multimedia, 2017, 19(7): 1510-1520.
- [22] Wang Z, Li Q, Song J, et al. Towards ip-based geolocation via fine-grained and stable webcam landmarks[C]. Proceedings of the web conference 2020, 2020, 1422-1432.
- [23] Moore D, Periakaruppan R, Donohoe J, et al. Where in the world is netgeo. caida. org[C]. Proc. of the INET, 2000, 2000.
- [24] Padmanabhan V. N, Subramanian L. An investigation of geographic mapping techniques for internet hosts[C]. Proceedings of the 2001 conference on Applications, technologies, architectures, and protocols for computer communications, 2001, 173-185.
- [25] Guo C, Liu Y, Shen W, et al. Mining the web and the internet for accurate ip address geolocations[C]. IEEE INFOCOM 2009, 2009, 2841-2845.
- [26] Liu H, Zhang Y, Zhou Y, et al. Mining checkins from location-sharing services for client-independent ip geolocation[C]. IEEE INFOCOM 2014-IEEE conference on computer communications, 2014, 619-627.

- [27] Wang Y, Zhu H, Wang J, et al. Xlboost-geo: An ip geolocation system based on extreme landmark boosting[J]. arXiv preprint arXiv:2010.13396, 2020.
- [28] Gueye B, Ziviani A, Crovella M, et al. Constraint-based geolocation of internet hosts[C]. Proceedings of the 4th ACM SIGCOMM conference on Internet measurement, 2004, 288-293.
- [29] Katz-Bassett E, John J. P, Krishnamurthy A, et al. Towards ip geolocation using delay and topology measurements[C]. Proceedings of the 6th ACM SIGCOMM conference on Internet measurement, 2006, 71-84.
- [30] Wang Y, Burgener D, Flores M, et al. Towards Street-Level Client-Independent IP geolocation[C]. 8th USENIX Symposium on Networked Systems Design and Implementation, 2011, 1-14.
- [31] Laki S, Mátray P, Hága P, et al. Spotter: A model based active geolocation service[C]. 2011 Proceedings IEEE INFOCOM, 2011, 3173-3181.
- [32] Eriksson B, Barford P, Sommers J, et al. A learning-based approach for ip geolocation[C]. Passive and Active Measurement: 11th International Conference, PAM 2010, Zurich, Switzerland, April 7-9, 2010. Proceedings 11, 2010, 171-180.
- [33] Dan O, Parikh V, Davison B. D. Ip geolocation using traceroute location propagation and ip range location interpolation[C]. Companion Proceedings of the Web Conference 2021, 2021, 332-338.
- [34] Jiang H, Liu Y, Matthews J. N. Ip geolocation estimation using neural networks with stable landmarks[C]. 2016 IEEE conference on computer communications workshops (INFOCOM WKSHPS), 2016, 170-175.
- [35] Wang Z, Zhou F, Zeng W, et al. Connecting the hosts: Street-level ip geolocation with graph neural networks[C]. Proceedings of the 28th ACM SIGKDD conference on knowledge discovery and data mining, 2022, 4121-4131.
- [36] Ding S, Luo X, Wang J, et al. Gnn-geo: a graph neural network-based fine-grained ip geolocation framework[J]. IEEE Transactions on Network Science and Engineering, 2023, 10(6): 3543-3560.
- [37] Hochreiter S, Schmidhuber J. Long short-term memory[J]. Neural computation, 1997, 9(8): 1735-1780.
- [38] Cho K, Merriënboer B. V, Gulcehre C, et al. Learning phrase representations using rnn encoder-decoder for statistical machine translation[J]. arXiv preprint arXiv:1406.1078, 2014.
- [39] Liu Q, Wu S, Wang L, et al. Predicting the next location: A recurrent model with spatial and temporal contexts[C]. Proceedings of the AAAI conference on artificial intelligence, 2016, 30.

- [40] Zhao P, Luo A, Liu Y, et al. Where to go next: A spatio-temporal gated network for next poi recommendation[J]. IEEE Transactions on Knowledge and Data Engineering, 2020, 34(5): 2512-2524.
- [41] Wu Y, Li K, Zhao G, et al. Personalized long-and short-term preference learning for next poi recommendation[J]. IEEE Transactions on Knowledge and Data Engineering, 2020, 34(4): 1944-1957.
- [42] Yu F, Cui L, Guo W, et al. A category-aware deep model for successive poi recommendation on sparse check-in data[C]. Proceedings of the web conference 2020, 2020, 1264-1274.
- [43] Zhao K, Zhang Y, Yin H, et al. Discovering subsequence patterns for next poi recommendation.[C]. IJCAI, 2020, 3216-3222.
- [44] Sun H, Xu J, Zheng K, et al. Mfnp: A meta-optimized model for few-shot next poi recommendation[C]. IJCAI, 2021, 3017-3023.
- [45] Xue H, Salim F, Ren Y, et al. Mobtcast: Leveraging auxiliary trajectory forecasting for human mobility prediction[J]. Advances in Neural Information Processing Systems, 2021, 34: 30380-30391.
- [46] Zhang M, Yang Y, Abbas R, et al. Snpr: A serendipity-oriented next poi recommendation model[C]. Proceedings of the 30th ACM International Conference on Information & Knowledge Management, 2021, 2568-2577.
- [47] Gao Q, Zhou F, Trajcevski G, et al. Predicting human mobility via variational attention[C]. The world wide web conference, 2019, 2750-2756.
- [48] Miao C, Luo Z, Zeng F, et al. Predicting human mobility via attentive convolutional network[C]. Proceedings of the 13th international conference on web search and data mining, 2020, 438-446.
- [49] Chen Y, Long C, Cong G, et al. Context-aware deep model for joint mobility and time prediction[C]. Proceedings of the 13th international conference on web search and data mining, 2020, 106-114.
- [50] Liu X, Liu Y, Li X. Exploring the context of locations for personalized location recommendations[C]. IJCAI, 2016, 1188-1194.
- [51] Gao Q, Zhou F, Zhang K, et al. Identifying human mobility via trajectory embeddings[C]. IJCAI, 2017, 1689-1695.
- [52] Mikolov T, Chen K, Corrado G, et al. Efficient estimation of word representations in vector space[J]. arXiv preprint arXiv:1301.3781, 2013.

- [53] Feng S, Cong G, An B, et al. Poi2vec: Geographical latent representation for predicting future visitors[C]. Proceedings of the AAAI Conference on Artificial Intelligence, 2017, 102-108.
- [54] Rao X, Chen L, Liu Y, et al. Graph-flashback network for next location recommendation[C]. Proceedings of the 28th ACM SIGKDD Conference on Knowledge Discovery and Data Mining, 2022, 1463-1471.
- [55] Lim N, Hooi B, Ng S.-K, et al. Stp-udgat: Spatial-temporal-preference user dimensional graph attention network for next poi recommendation[C]. Proceedings of the 29th ACM International conference on information & knowledge management, 2020, 845-854.
- [56] Zhou F, Dai Y, Gao Q, et al. Self-supervised human mobility learning for next location prediction and trajectory classification[J]. Knowledge-Based Systems, 2021, 228: 107214.
- [57] Tan H, Yao D, Huang T, et al. Meta-learning enhanced neural ode for citywide next poi recommendation[C]. 2021 22nd IEEE International Conference on Mobile Data Management (MDM), 2021, 89-98.
- [58] Cranmer M, Gonzalez A. S, Battaglia P, et al. Discovering symbolic models from deep learning with inductive biases[J]. Advances in Neural Information Processing Systems, 2020, 33: 17429-17442.
- [59] Wencel-Delord J, Glorius F. C–h bond activation enables the rapid construction and late-stage diversification of functional molecules[J]. Nature chemistry, 2013, 5(5): 369-375.
- [60] Yuan H, Yu H, Gui S, et al. Explainability in graph neural networks: A taxonomic survey[J]. IEEE transactions on pattern analysis and machine intelligence, 2022, 45(5): 5782-5799.
- [61] Ying Z, Bourgeois D, You J, et al. Gnnexplainer: Generating explanations for graph neural networks[J]. Advances in neural information processing systems, 2019, 32.
- [62] Luo D, Cheng W, Xu D, et al. Parameterized explainer for graph neural network[J]. Advances in neural information processing systems, 2020, 33: 19620-19631.
- [63] Bahdanau D, Cho K, Bengio Y. Neural machine translation by jointly learning to align and translate[J]. arXiv preprint arXiv:1409.0473, 2014.
- [64] Serrano S, Smith N. A. Is attention interpretable?[J]. arXiv preprint arXiv:1906.03731, 2019.
- [65] Yu J, Xu T, Rong Y, et al. Graph information bottleneck for subgraph recognition[J]. arXiv preprint arXiv:2010.05563, 2020.
- [66] Miao S, Liu M, Li P. Interpretable and generalizable graph learning via stochastic attention mechanism[C]. International Conference on Machine Learning, 2022, 15524-15543.

- [67] Schuster M, Paliwal K. K. Bidirectional recurrent neural networks[J]. IEEE transactions on Signal Processing, 1997, 45(11): 2673-2681.
- [68] Yang C, Sun M, Zhao W. X, et al. A neural network approach to jointly modeling social networks and mobile trajectories[J]. ACM Transactions on Information Systems (TOIS), 2017, 35(4): 1-28.
- [69] Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need[J]. Advances in neural information processing systems, 2017, 30.
- [70] Sahili Z. A, Awad M. Spatio-temporal graph neural networks: A survey[J]. arXiv preprint arXiv:2301.10569, 2023.
- [71] Li M, Zhu Z. Spatial-temporal fusion graph neural networks for traffic flow forecasting[C]. Proceedings of the AAAI conference on artificial intelligence, 2021, 4189-4196.
- [72] Jiang R, Yin D, Wang Z, et al. DI-traff: Survey and benchmark of deep learning models for urban traffic prediction[C]. Proceedings of the 30th ACM international conference on information & knowledge management, 2021, 4515-4525.
- [73] Li Y, Yu R, Shahabi C, et al. Diffusion convolutional recurrent neural network: Data-driven traffic forecasting[J]. arXiv preprint arXiv:1707.01926, 2017.
- [74] Li Z, Huang C, Xia L, et al. Spatial-temporal hypergraph self-supervised learning for crime prediction[C]. IEEE 38th International Conference on Data Engineering (ICDE), 2022, 2984-2996.
- [75] Zheng C, Fan X, Wang C, et al. Gman: A graph multi-attention network for traffic prediction[C]. Proceedings of the AAAI conference on artificial intelligence, 2020, 1234-1241.
- [76] Smuha N. A. The eu approach to ethics guidelines for trustworthy artificial intelligence[J]. Computer Law Review International, 2019, 20(4): 97-106.
- [77] Dai E, Zhao T, Zhu H, et al. A comprehensive survey on trustworthy graph neural networks: Privacy, robustness, fairness, and explainability[J]. Machine Intelligence Research, 2024, 21(6): 1011-1061.
- [78] Abdar M, Pourpanah F, Hussain S, et al. A review of uncertainty quantification in deep learning: Techniques, applications and challenges[J]. Information fusion, 2021, 76: 243-297.
- [79] Kiureghian A. D, Ditlevsen O. Aleatory or epistemic? does it matter?[J]. Structural safety, 2009, 31(2): 105-112.
- [80] Amini A, Schwarting W, Soleimany A, et al. Deep evidential regression[J]. Advances in neural information processing systems, 2020, 33: 14927-14937.
- [81] Springenberg J. T, Klein A, Falkner S, et al. Bayesian optimization with robust bayesian neural networks[J]. Advances in neural information processing systems, 2016, 29.

- [82] Gal Y, Ghahramani Z. Dropout as a bayesian approximation: Representing model uncertainty in deep learning[C]. international conference on machine learning, 2016, 1050-1059.
- [83] Lakshminarayanan B, Pritzel A, Blundell C. Simple and scalable predictive uncertainty estimation using deep ensembles[J]. Advances in neural information processing systems, 2017, 30.
- [84] Malinin A, Gales M. Predictive uncertainty estimation via prior networks[J]. Advances in neural information processing systems, 2018, 31.
- [85] Tishby N, Zaslavsky N. Deep learning and the information bottleneck principle[C]. 2015 ieee information theory workshop (itw), 2015, 1-5.
- [86] Wu T, Ren H, Li P, et al. Graph information bottleneck[J]. Advances in Neural Information Processing Systems, 2020, 33: 20437-20448.
- [87] Wu B, Bian Y, Zhang H, et al. Trustworthy graph learning: Reliability, explainability, and privacy protection[C]. Proceedings of the 28th ACM SIGKDD conference on knowledge discovery and data mining, 2022, 4838-4839.
- [88] Chandrasekhar V, Andrews J. G. Spectrum allocation in tiered cellular networks[J]. IEEE transactions on communications, 2009, 57(10): 3059-3068.
- [89] Liu J, Li T, Ji S, et al. Urban flow pattern mining based on multi-source heterogeneous data fusion and knowledge graph embedding[J]. IEEE Transactions on Knowledge and Data Engineering, 2021, 35(2): 2133-2146.
- [90] Cheng R, Emrich T, Kriegel H.-P, et al. Managing uncertainty in spatial and spatio-temporal data[C]. 2014 IEEE 30th International Conference on Data Engineering, 2014, 1302-1305.
- [91] Liu S, Wang S. Trajectory community discovery and recommendation by multi-source diffusion modeling[J]. IEEE Transactions on Knowledge and Data Engineering, 2016, 29(4): 898-911.
- [92] Kalnis P, Ghinita G, Mouratidis K, et al. Preventing location-based identity inference in anonymous spatial queries[J]. TKDE, 2007, 19(12): 1719-1733.
- [93] Zhang F, Liu F, Luo X. Geolocation of covert communication entity on the internet for post-steganalysis[J]. EURASIP Journal on Image and Video Processing, 2020, 2020: 1-10.
- [94] Tai W, Chen B, Zhou F, et al. TrustGeo: Uncertainty-aware dynamic graph learning for trustworthy IP geolocation[C]. Proceedings of the 29th ACM SIGKDD Conference on Knowledge Discovery and Data Mining, 2023, 4862-4871.
- [95] Chen Jning, Liu Flin, Shi Yfeng, et al. Towards ip location estimation using the nearest common router[J]. Journal of Internet Technology, 2018, 19(7): 2097-2110.

- [96] Dan O, Parikh V, Davison B. D. Ip geolocation through geographic clicks[J]. ACM Transactions on Spatial Algorithms and Systems (TSAS), 2022, 8(1): 1-22.
- [97] Ke G, Meng Q, Finley T, et al. Lightgbm: A highly efficient gradient boosting decision tree[J]. Advances in neural information processing systems, 2017, 30.
- [98] Arik S. Ö, Pfister T. Tabnet: Attentive interpretable tabular learning[C]. AAAI, 2021, 6679-6687.
- [99] Tai W, Chen B, Zhong T, et al. Ripgeo: Robust street-level ip geolocation[C]. 2023 24th IEEE International Conference on Mobile Data Management (MDM), 2023, 138-147.
- [100] Abdul-Azim H. A, Hemayed E. E. Human action recognition using trajectory-based representation[J]. Egyptian Informatics Journal, 2015, 16(2): 187-198.
- [101] Rudenko A, Palmieri L, Herman M, et al. Human motion trajectory prediction: A survey[J]. The International Journal of Robotics Research, 2020, 39(8): 895-935.
- [102] Islam M. A, Mohammad M. M, Das S. S. S, et al. A survey on deep learning based point-of-interest (poi) recommendations[J]. Neurocomputing, 2022, 472: 306-325.
- [103] Rendle S, Freudenthaler C, Schmidt-Thieme L. Factorizing personalized markov chains for next-basket recommendation[C]. Proceedings of the 19th international conference on World wide web, 2010, 811-820.
- [104] Cheng C, Yang H, Lyu M. R, et al. Where you like to go next: Successive point-of-interest recommendation.[C]. IJCAI, 2013, 2605-2611.
- [105] Koren Y, Bell R, Volinsky C. Matrix factorization techniques for recommender systems[J]. Computer, 2009, 42(8): 30-37.
- [106] Lian D, Zhao C, Xie X, et al. Geomf: joint geographical modeling and matrix factorization for point-of-interest recommendation[C]. Proceedings of the 20th ACM SIGKDD international conference on Knowledge discovery and data mining, 2014, 831-840.
- [107] Zhong T, Zhang S, Zhou F, et al. Hybrid graph convolutional networks with multi-head attention for location recommendation[J]. World Wide Web, 2020, 23: 3125-3151.
- [108] Gao Q, Zhou F, Zhong T, et al. Contextual spatio-temporal graph representation learning for reinforced human mobility mining[J]. Information Sciences, 2022, 606: 230-249.
- [109] Yang S, Liu J, Zhao K. Getnext: trajectory flow map enhanced transformer for next poi recommendation[C]. Proceedings of the 45th International ACM SIGIR Conference on research and development in information retrieval, 2022, 1144-1153.

- [110] Yan X, Song T, Jiao Y, et al. Spatio-temporal hypergraph learning for next poi recommendation[C]. Proceedings of the 46th International ACM SIGIR Conference on Research and Development in Information Retrieval, 2023, 403-412.
- [111] Alemi A. A, Fischer I, Dillon J. V, et al. Deep variational information bottleneck[C]. International Conference on Learning Representations, 2017, .
- [112] Ash R. B. Information theory[M]. Courier Corporation, 2012.
- [113] Graves A, Graves A. Long short-term memory[J]. Supervised sequence labelling with recurrent neural networks, 2012, 37-45.
- [114] Feng S, Li X, Zeng Y, et al. Personalized ranking metric embedding for next new poi recommendation[C]. Proceedings of the 24th International Conference on Artificial Intelligence, 2015, 2069-2075.
- [115] Luo Y, Liu Q, Liu Z. Stan: Spatio-temporal attention network for next location recommendation[C]. Proceedings of the web conference 2021, 2021, 2177-2185.